

北京交通大学

硕士专业学位论文

面向 xx 国经济制裁知识图谱构建与应用研究

Research on Construction and Application of an Economic-Sanctions
Knowledge Graph for Country XX

作者：XXXX

导师：XXXX

北京交通大学

2026 年 1 月

学校代码：10004

密级：公开

北京交通大学

硕士专业学位论文

论文题目

论文英文题目

作者姓名：XXXX

学 号：XXXX

导师姓名：XXXX

职 称：XXXX

专业学位类别（领域）：电子信息 学位级别：硕士

北京交通大学

2026 年 1 月

致谢

本论文在北京交通大学 XX 学院完成。论文的研究与写作过程中，得到了导师 XXX 教授在选题、方法与论文结构等方面的悉心指导。在此谨致以诚挚的感谢。

感谢课题组的各位老师与同学在实验设计、数据整理与讨论交流中给予的帮助与建议；感谢 XXX 同学在 XX 模块实现与测试过程中提供的支持。

同时，感谢家人对我学习与生活的理解与鼓励，使我能够专注完成本论文的工作。最后，感谢所有在研究与学习期间给予我帮助的人。

摘要

俄乌冲突爆发以来，西方国家及其盟友对俄罗斯实施了高频、密集且持续迭代的经济制裁。制裁信息分散于官方清单、法规条款、新闻报道与研究报告等多源异构文本中，存在跨语种表达不一致、实体别名/译名歧义显著、更新频繁且证据链要求严格等问题，导致面向合规审查与风险预警的制裁情报分析面临“难组织、难检索、难解释、难动态更新”的核心挑战。

为此，本文面向俄乌冲突经济制裁场景，研究经济制裁知识图谱的构建与应用方法，形成“抽取-融合-更新-评估-服务”的整体技术路线。本文数据覆盖 2022 年 2 月至 2025 年 6 月，来源包括 [请补充：清单/法规/新闻/报告等]，规模约为 [请补充：文档/条目数量量级]，并对关键实体与关系进行规范化建模与证据留存，以支撑后续可追溯分析。

在知识抽取方面，本文提出图引导的实体关系自优化抽取方法 GSR-ER (Graph-Guided Self-Refine for Entity-Relation)。该方法以多源文本为输入，输出包含实体、关系与证据字段的结构化结果：利用外部图结构构造图上下文 (graph context)，在大语言模型抽取过程中引入图约束以降低歧义与关系冲突，并通过自回溯校验 (self-refine) 机制迭代修正抽取结果，从而提升实体消歧准确率与关系一致性，抑制模型幻觉。基于抽取得到的结构化知识，本文设计经济制裁事件要素体系与证据可追溯字段，构建可版本化更新的经济制裁知识图谱，并将其存储于图数据库以支持检索与分析。

在风险评估方面，本文提出层次化图时序风险评估模型 HGT-RAM (Hierarchical Graph-Temporal Risk Assessment Model)。该模型在图谱结构基础上融合静态风险与动态风险：静态风险由加权个性化 PageRank 及社群风险聚合刻画，用于衡量节点在制裁关联网络中的影响与聚集风险；动态风险由 Hawkes 点过程建模制裁事件在时间维度上的激发与衰减强度，用于刻画风险随时间的传播与累积。模型以可解释的方式输出风险分值、关键路径与证据线索。

在系统应用方面，本文实现面向企业合规与制裁研判的知识服务原型系统：通过图谱检索与语义检索联合，并结合图检索增强生成 (GraphRAG) 思路进行检索增强生成，实现制裁对象查询、条款/证据溯源、风险传播链路分析与报告生成等功能。实验与案例分析采用 [请补充：抽取评价指标/验证方式] 与 [请补充：风险评估验证方式] 进行验证，结果表明本文方法能够提升制裁知识抽取质量与风险研判的可解释性，为政策研究与企业合规提供可复用的技术支撑。

关键词：俄乌冲突；经济制裁；知识图谱；实体关系抽取；风险评估；图检索增强生成

(GraphRAG)

ABSTRACT

Since the outbreak of the Russia–Ukraine conflict, Western countries and their allies have imposed intensive and rapidly evolving economic sanctions on Russia. Sanction intelligence is scattered across multi-source, multilingual, and heterogeneous documents (e.g., official lists, legal texts, news reports, and research briefs), featuring severe ambiguity in aliases/translations, frequent updates, and strict requirements for evidence traceability. These characteristics make compliance review and risk warning challenging in terms of organization, retrieval, interpretability, and timely updates.

This thesis studies the construction and application of an economic sanctions knowledge graph for the Russia–Ukraine conflict, following an end-to-end workflow from extraction and fusion to versioned updates, risk assessment, and knowledge services. The dataset covers February 2022 to June 2025, and is collected from [to be filled: sources], with a scale of approximately [to be filled: number of documents/items]. We emphasize evidence preservation and traceability to support auditable analysis.

For information extraction, we propose GSR-ER (Graph-Guided Self-Refine for Entity–Relation). Given multi-source texts as input, GSR-ER outputs structured entities and relations with evidence fields. It leverages external graph context and graph-based constraints to guide large language models, and iteratively refines the extracted results via self-verification to reduce ambiguity, resolve conflicts, and mitigate hallucinations. Based on the extracted knowledge, we design a sanction-event schema with evidence fields and build a versioned sanctions knowledge graph stored in a graph database.

For risk assessment, we propose HGT-RAM (Hierarchical Graph-Temporal Risk Assessment Model), integrating (i) static risk characterized by weighted personalized PageRank and community-level aggregation to quantify structural influence and community risk, and (ii) dynamic risk modeled by a Hawkes process to capture the excitation and decay of sanction events over time. The model outputs not only risk scores but also interpretable paths and supporting evidence.

Finally, we implement a prototype knowledge service system for compliance and sanction analysis. By combining graph retrieval and semantic retrieval under a graph retrieval-augmented generation (GraphRAG)-inspired workflow, the system supports entity lookup, clause/evidence tracing, risk propagation analysis, and report generation. Experiments and

case studies are conducted using [to be filled: extraction metrics/verification protocol] and [to be filled: risk assessment validation setting], demonstrating the effectiveness and interpretability of the proposed approach.

KEYWORDS: Russia–Ukraine conflict; economic sanctions; knowledge graph; entity–relation extraction; risk assessment; graph retrieval-augmented generation (GraphRAG)

目录

摘要 iii

ABSTRACT v

1 引言 1

1.1 研究背景 1

1.2 研究意义 2

1.2.1 理论意义 2

1.2.2 应用意义 4

1.3 国内外研究现状 5

1.3.1 经济制裁合规与信息组织研究 5

1.3.2 制裁事件抽取与知识图谱构建研究 6

1.3.3 大语言模型驱动的信息抽取研究 7

1.3.4 图结构风险评估与传播建模研究 7

1.3.5 研究现状综述与差距分析 8

1.4 研究问题与挑战 8

1.5 研究目标与研究内容 9

1.5.1 研究目标 9

1.5.2 主要研究内容 9

1.6 主要创新点 10

1.7 技术路线与论文组织结构 11

1.7.1 技术路线 11

1.7.2 论文组织结构 11

2 相关理论与关键技术 13

2.1 经济制裁与合规风险分析 14

2.1.1 经济制裁概念、分类与典型措施 14

2.1.2 制裁溢出效应与风险传播机制 14

2.1.3 国际合规准则与风险判定依据 15

2.1.4 俄乌冲突制裁的特殊性与技术挑战 15

2.1.5 现有工具的能力边界与本文技术路线的形成 16

2.2 知识图谱建模原则与存储机制 16

2.2.1	知识图谱定义与构建流程	16
2.2.2	本体建模与 Schema 设计	17
2.2.3	图数据库存储与查询	18
2.3	信息抽取任务与关键难点	18
2.3.1	命名实体识别	18
2.3.2	关系抽取与事件抽取	19
2.3.3	实体对齐、消歧与知识融合	19
2.4	LLM 驱动的结构化抽取与质量控制	20
2.4.1	大语言模型基础与零/少样本能力	20
2.4.2	提示工程与思维链推理	21
2.4.3	自优化 (Self-Refine) 机制	21
2.4.4	幻觉抑制与可验证抽取	22
2.5	图时序风险建模基础	22
2.5.1	图排序与影响力度量	22
2.5.2	社群发现与风险聚合	23
2.5.3	Hawkes 点过程与时序传播	24
2.5.4	异质图建模与多关系网络	24
2.6	GraphRAG 与证据可解释输出	25
2.6.1	检索增强生成 (RAG)	25
2.6.2	图检索增强生成 (GraphRAG)	25
2.6.3	证据溯源与可解释性	26
2.7	本章小结	26
3	数据集与知识抽取方法 (GSR-ER)	28
3.1	数据集与标注规范	28
3.1.1	数据来源与范围界定	28
3.1.2	数据预处理与质量控制	29
3.1.3	标注指南与评价数据划分	30
3.2	知识图谱建模与版本化更新	32
3.2.1	事件要素与 Schema 设计	32
3.2.2	证据建模与可追溯字段	32
3.2.3	图谱存储、融合策略与版本化更新	33
3.3	GSR-ER 方法: 图引导的实体关系自优化抽取	34
3.3.1	任务定义与问题建模	34

3.3.2	方法总体框架与流程	35
3.3.3	Graph context 构建	36
3.3.4	Graph-Guided 约束机制	37
3.3.5	基于大语言模型的初始抽取与自回溯校验	38
3.3.6	输出质量控制与可追溯性	40
3.4	实验设计与结果分析	40
3.4.1	实验设置	40
3.4.2	对比实验结果	42
3.4.3	消融实验	43
3.4.4	Self-Refine 迭代轮次分析	44
3.4.5	错误分析	45
3.5	本章小结	45
4	层次化图时序风险评估模型 (HGT-RAM)	46
4.1	风险传播任务定义与问题建模	46
4.1.1	任务定义与输入输出形式化	46
4.1.2	核心假设与符号约定	47
4.2	层次化经济制裁知识图谱建模	48
4.2.1	节点、关系类型与边权设计	48
4.2.2	异质信息建模与节点属性刻画	50
4.3	静态风险建模	50
4.3.1	加权个性化 PageRank	50
4.3.2	Leiden 社群发现与社群划分	51
4.4	动态风险建模	51
4.4.1	制裁事件序列构建	52
4.4.2	Hawkes 过程强度函数设计	52
4.4.3	参数估计方法	53
4.4.4	时间窗内风险强度统计量	54
4.5	社群级结构-时序风险聚合	54
4.6	风险融合与可解释性输出	55
4.6.1	特征驱动的自适应融合机制	56
4.6.2	基于 Pairwise 排序学习的参数优化	57
4.6.3	可解释性分析	59
4.6.4	多源风险融合策略 (固定权重对照)	60

4.6.5	风险贡献分解.....	61
4.6.6	关键路径回溯算法.....	61
4.6.7	证据关联与溯源输出.....	61
4.7	算法流程与复杂度分析.....	62
4.8	实验设计与结果分析.....	64
4.8.1	实验设置.....	64
4.8.2	基线方法与对比方案.....	65
4.8.3	消融实验.....	65
4.8.4	融合策略对比.....	67
4.8.5	参数敏感性分析.....	67
4.8.6	风险排名评估与案例分析.....	69
4.8.7	可解释性评估.....	71
4.9	本章小结.....	72
5	经济制裁知识图谱应用系统设计与实现.....	73
5.1	需求分析与总体架构.....	73
5.1.1	业务场景与需求定义.....	73
5.1.2	系统总体架构与技术选型.....	74
5.1.3	核心数据流程.....	76
5.2	核心模块设计与实现.....	77
5.2.1	数据接入、抽取融合与版本化管理.....	77
5.2.2	GraphRAG 检索增强生成模块.....	79
5.2.3	风险评估与预警模块.....	80
5.3	系统功能展示与典型案例.....	81
5.3.1	制裁对象查询与证据溯源.....	81
5.3.2	关系网络穿透与风险传播链路分析.....	82
5.3.3	典型企业合规审查案例.....	82
5.3.4	检索增强报告生成案例.....	82
5.4	系统评估.....	83
5.4.1	图谱规模与实验环境.....	83
5.4.2	查询性能与更新时延评估.....	83
5.4.3	GraphRAG 回答质量评估.....	84
5.5	本章小结.....	85
6	总结与展望.....	87

6.1 本文总结 87

6.2 未来展望 87

参考文献 88

附录 A 附录 A 制裁事件要素示例 94

附录 B 附录 B 语义查询样例 95

作者简历及攻读硕士学位期间取得的研究成果 96

独创性声明 97

学位论文数据集..... 98

1 引言

1.1 研究背景

经济制裁（Economic Sanctions）是国际行为体在不诉诸直接军事冲突的前提下，通过贸易管制、金融限制、技术禁运和投资约束等手段对目标国家、组织或个人施加压力的重要政策工具。作为介于外交斡旋与军事干预之间的一种非武力政策手段，经济制裁在国际政治与国际经济治理中长期发挥着重要作用。历史上，冷战时期以美国对苏联的粮食禁运为代表，经济制裁主要表现为国家间的全面经济封锁，制裁范围广泛但往往伴随严重的人道主义代价。20 世纪 90 年代，联合国对伊拉克实施的全面制裁进一步暴露了这种大规模制裁模式在政治效果与社会成本之间的失衡，由此推动了国际社会对制裁工具的深刻反思。此后，经济制裁逐渐从传统的全面贸易封锁模式，演化为以个人、企业及关键机构为核心对象的”定向制裁（Targeted Sanctions）”模式，其实施机制也日益制度化和规范化。

在当前国际制裁体系中，联合国安理会决议构成多边制裁的重要法律基础，而美国财政部外国资产控制办公室（Office of Foreign Assets Control, OFAC）、欧盟理事会及英国财政部等机构则在单边或区域制裁框架下发挥关键执行作用。这些机构通过发布制裁清单、法规条例和政策指令，对特定实体或个人实施资产冻结、金融限制、出口管制以及旅行禁令等措施，从而形成多层次、多主体参与的国际制裁治理体系。

自 2022 年 2 月俄乌冲突全面爆发以来，西方国家及其盟友针对俄罗斯实施了大规模经济制裁措施。与历史上的制裁行动相比，本轮制裁在规模、频率和覆盖范围上均达到近年来前所未有的水平。2022 年至 2024 年间，美国、欧盟、英国、日本及其他国家相继发布多轮制裁措施，制裁对象从个人、企业和金融机构进一步扩展至船舶、航空器以及特定产业部门。与此同时，制裁相关信息以多种形式分散发布，包括官方制裁清单（如 SDN List、EU Consolidated List）、法律法规文件（如行政令与欧盟条例）、新闻报道以及政策研究报告等。

总体来看，俄乌冲突背景下的制裁数据呈现出若干显著特征。在规模与更新频率方面，冲突爆发初期大量制裁措施以较高频率密集发布，制裁名单实体数量在短期内迅速增长，给信息追踪和合规审查带来了极大的时效性压力。在发布主体方面，不同国家和地区的监管机构同时发布制裁信息，各司法辖区之间在制裁范围与适用规则上存在差异与交叉，增加了制裁信息的整合与比对难度。在措施类型方面，同一制裁对象可能同时受到资产冻结、金融限制、出口管制以及旅行禁令等多种措施的叠加约

束，措施之间存在复杂的条件依赖和时效关系。在跨语种表达方面，同一实体在不同语言环境下往往存在多种名称、别名或译名，构成了实体识别与对齐的重要障碍。此外，制裁对象的状态随着政策调整持续发生新增、修订、豁免或解除等变更，历史版本的追溯与变更记录的管理需求日益突出。

在实际的政策研究与企业合规审查中，围绕制裁情报分析通常涉及若干关键问题：例如某一目标实体是否受到制裁、制裁来源及其法律依据为何；适用的制裁措施类型及其生效时间如何；目标实体与其关联主体（如股权关系、任职关系或代理关系）之间的网络结构如何形成潜在风险传导路径；以及制裁事件如何随着时间持续演化并在复杂关系网络中扩散。然而，传统的信息检索方法主要依赖关键词搜索或静态名单比对，难以有效回答上述问题。其主要原因在于：制裁信息来源分散、语义表达存在跨机构和跨语种差异，同一实体可能具有多种别名或译名，同时制裁状态具有明显的版本演化和时间动态特征。因此，在“多源异构”和“持续更新”的信息环境下，制裁情报分析与企业合规审查已从简单的名单匹配问题，逐步演变为面向证据可追溯、关系可解释和时序可更新的复杂知识组织与风险分析任务。

与此同时，近年来自然语言处理与知识工程领域的技术进展为应对上述挑战提供了新的可能。知识图谱作为一种结构化的知识组织与表示方式，能够以实体—关系—属性的形式对领域知识进行系统建模，适合用于表达制裁场景中实体之间的多类型关联关系与层次化的制裁措施结构。大语言模型在复杂文本理解和信息抽取方面展现出的强大能力，则为从非结构化的制裁文本中自动抽取结构化知识提供了技术基础，有望突破传统基于规则或浅层模型的抽取方法在语义理解深度和跨语种泛化能力上的瓶颈。此外，图分析算法与时序建模方法的不断成熟，使得在知识图谱上进行风险传播分析和动态趋势预测成为可能。这些技术的发展，为构建面向经济制裁场景的智能化知识组织与风险研判体系奠定了基础，也使得如何在该场景下实现高质量的领域知识图谱构建、可靠的信息抽取以及可解释的风险评估，成为兼具理论价值与实践意义的研究问题。

1.2 研究意义

1.2.1 理论意义

面向俄乌冲突经济制裁场景的知识图谱构建与应用研究，在理论层面具有以下意义：

(1) 推动领域自适应知识图谱理论发展。知识图谱作为一种结构化的知识组织与表示方式，在近年来的研究中取得了显著进展，但已有工作主要围绕通用领域或百科类知识展开，例如 Freebase、Wikidata 等大规模知识库的构建与完善 [2]。这类知识图

谱所处理的文本通常具有较为规范的语义结构和相对稳定的实体关系，其知识建模方法已较为成熟。然而，经济制裁文本在知识建模方面具有显著的特殊性：一方面，制裁文件属于高度政策性和法律性文本，其实体类型（如制裁主体、被制裁对象、制裁措施、法律依据等）和关系模式与通用知识图谱存在本质差异；另一方面，制裁政策具有较强的时效性和动态性，同一制裁对象可能在不同时间节点被施加、调整或解除制裁，这对知识图谱的版本化管理提出了更高要求。现有的通用知识图谱构建方法难以直接迁移至这一场景，在本体设计、模式定义和动态演化等方面均存在理论空白。本研究针对上述问题，系统设计了制裁事件要素体系，引入了证据可追溯字段以实现知识到原始文本的精确回溯，并提出了版本化图谱更新机制以应对制裁政策的时序演变，从而丰富了面向特定政策领域的知识建模理论，为类似的专业领域知识图谱构建提供了可借鉴的理论范式。

(2) 探索图约束驱动的大语言模型信息抽取范式。大语言模型（LLM）凭借其强大的自然语言理解和生成能力，已在信息抽取任务中展现出良好的潜力。然而，将 LLM 直接应用于结构化知识抽取时仍面临若干挑战：模型的输出往往缺乏与目标知识库模式的一致性约束，容易产生实体歧义、关系遗漏或不符合预定义本体的抽取结果，这在制裁文本等专业性较强的领域尤为突出。已有研究大多将 LLM 视为端到端的抽取工具，较少关注如何利用已构建的知识图谱结构来引导和约束 LLM 的抽取行为。本研究提出的 GSR-ER 方法，创新性地将在图结构上下文（Graph Context）显式引入 LLM 的抽取过程，使模型在执行实体识别和关系抽取时能够参照已有的图谱结构信息，从而实现与目标本体的对齐。同时，该方法通过自回溯校验（Self-Refine）机制构建了可迭代优化的抽取闭环——即模型对初次抽取结果进行自我审查与修正，逐步提升抽取质量，减少幻觉输出和结构性错误。这一方法为 LLM 与结构化知识库的深度协同提供了新的理论视角，推动了“知识引导的语言模型”这一研究方向的理论探索。

(3) 构建融合静态结构与动态时序的风险评估框架。制裁合规风险评估是经济制裁研究中的核心应用场景之一，其关键难题在于如何兼顾风险评估的可解释性与动态性。从可解释性角度而言，制裁合规决策往往涉及法律责任，要求风险评估的逻辑链条清晰可追溯，而非仅给出不透明的数值评分。从动态性角度而言，制裁环境瞬息万变，新制裁令的发布、现有制裁的修改或解除都会在短时间内改变相关实体的风险状态，静态的评估方法难以捕捉这种时序变化。现有研究在这两方面往往有所偏重而难以兼顾：基于规则或图结构的方法具有较好的可解释性但缺乏时序感知能力，而基于时间序列的方法能够刻画动态变化却不易解释传播路径。本研究提出的 HGT-RAM 模型，将图论中的个性化 PageRank[3] 与社群发现算法 [4] 用于刻画制裁风险在实体网络中的静态传播结构，同时引入点过程理论中的 Hawkes 自激发机制 [5] 来建模制

裁事件的时序触发效应，将二者有机结合形成统一的风险评估框架。这一融合范式在图上的风险传播建模理论方面具有一定的推进价值，为制裁合规风险的量化评估提供了兼顾可解释性与动态性的理论基础。

综上所述，本文从领域知识建模、知识获取方法以及知识驱动风险分析三个层面，对经济制裁场景下知识图谱构建与应用问题进行了系统探索。研究不仅拓展了知识图谱在政策与法律类文本场景中的知识表示方法，而且在图约束驱动的信息抽取范式以及融合图结构与时序机制的风险传播建模方面进行了初步理论探索，从而在一定程度上丰富了知识图谱与智能分析方法在复杂政策研究领域的理论基础。

1.2.2 应用意义

在实际应用层面，本研究围绕经济制裁情报分析与合规管理需求，构建了面向制裁场景的知识图谱与智能分析方法，其应用价值主要体现在以下几个方面。

（1）支撑企业制裁合规审查的效率提升与流程优化。在当前国际制裁环境下，跨国企业、金融机构及贸易组织面临日益严格的合规审查要求。以银行业为例，金融机构在客户准入、交易筛查和定期复核等业务环节中，需要持续比对多个司法辖区发布的制裁清单，判断客户及其关联主体是否涉及制裁。然而，现有合规审查流程仍主要依赖人工核查与关键词匹配工具，在面对制裁清单频繁更新、实体别名复杂以及关联关系多层嵌套等问题时，往往存在响应滞后、漏检风险较高以及关联穿透能力不足等局限。尤其在多跳风险传递场景中，例如某企业虽未直接出现在制裁名单上，但其实际控制人或主要股东为受制裁对象，传统名单比对方法难以有效识别此类间接风险。本文构建的制裁知识图谱与检索增强问答系统，将制裁状态查询、多层关联关系分析与证据溯源整合为统一的知识服务平台，使合规人员能够通过自然语言查询快速获取结构化结果及其证据来源，从而提升制裁筛查的自动化水平，降低人工核查成本，并提高风险识别的覆盖率与准确性。

（2）为经济制裁政策研究提供可量化的分析工具。在国际关系与公共政策研究领域，学者在开展制裁效果评估、制裁网络结构分析以及政策演化研究时，通常需要对大量制裁数据进行系统整理与结构化分析。然而，当前相关研究往往依赖研究者从各国监管机构官网、法律文件和新闻资料中手动收集数据，缺乏统一的结构化数据基础设施，这在一定程度上制约了研究的规模与效率。本文构建的制裁知识图谱通过结构化方式整合多源制裁信息，为研究者提供了一个可持续更新的领域数据底座。在此基础上，研究者可以便捷地开展制裁网络拓扑分析、关键节点识别以及制裁措施的时序演化追踪。同时，本文提出的 HGT-RAM 风险评估模型能够对制裁风险在实体关系网络中的传播路径及其潜在影响范围进行量化刻画，从而为政策研究者评估制裁措施

影响、识别制裁体系中的关键节点与潜在薄弱环节提供数据驱动的分析支持。

(3) 推动图检索增强生成技术在高价值专业场景中的应用实践。近年来,检索增强生成(Retrieval-Augmented Generation, RAG)技术在提升大语言模型输出可靠性方面取得了显著进展,而将知识图谱作为检索知识源的图检索增强生成(GraphRAG)方法,则进一步增强了模型对结构化知识的利用能力。然而,现有 GraphRAG 研究多集中于开放域问答或通用知识检索场景,在法律合规、金融风控等对准确性和可追溯性要求较高的专业领域中的应用探索仍相对有限。本文将制裁知识图谱与 GraphRAG 框架相结合,构建了集“制裁对象查询、证据溯源、风险链路分析与分析报告生成”为一体的知识服务流程,展示了 GraphRAG 在复杂专业知识场景中的应用潜力。该实践为 GraphRAG 技术从通用问答场景向法律、金融与合规等高价值领域的迁移提供了具有参考意义的技术路径。

综上所述,本研究在企业制裁合规审查、经济制裁政策分析以及专业场景下的智能知识服务三个方面均具有较为明确的应用价值,为经济制裁领域的信息化与智能化分析提供了具有实践意义的技术路径与方法参考。

1.3 国内外研究现状

1.3.1 经济制裁合规与信息组织研究

经济制裁研究长期以国际政治经济学与政策评估为主线。Hufbauer 等人在《经济制裁的再考察》中构建了涵盖一战以来 174 例制裁案例的大规模数据集,系统分析了制裁成功的政治与经济决定因素^[1]。在定向制裁(Smart Sanctions)的理论框架方面,Drezner 运用焦点理论揭示了定向制裁在政策界广受接受的深层原因,并指出其实际效果尚缺乏系统性实证支持^[2]; Biersteker 等人基于定向制裁联盟 50 余位学者的合作研究,对联合国实施的 23 个制裁机制进行了系统评估,提出了强制、约束与信号传递的三元分析框架^[3]。在对俄制裁的实证研究方面,Ahn 和 Ludema 利用 Orbis 企业级数据与双重差分方法检验了 2014 年制裁对被制裁企业绩效的显著负面影响^[4]; Dreger 等人则通过协整 VAR 模型分离了油价下跌与经济制裁对卢布汇率的相对贡献^[5]。马喜立基于多国动态 CGE 模型分析了俄乌冲突制裁对全球主要经济体的中长期溢出效应^[6]。Giumelli 针对俄乌冲突两年来的制裁效果评估提出了六阶段分析方法,论证了物质损害不等于政治收益^[7]。在制裁多边性方面,Bapat 和 Morgan 使用 TIES 数据集重新检验了多边制裁有效性的经典争论,逆转了此前“单边制裁更有效”的反直觉结论^[8]。上述研究从制度设计、定量评估与政策演进等多维度推进了制裁理论,但主要关注政策层面的效果分析,对制裁信息的结构化组织与智能化处理关注不足。

在数据资源方面,权威制裁数据主要来源于:美国财政部 OFAC 的 SDN(Specially

Designated Nationals) 名单及其专项清单^[9]; 欧盟制裁地图 (EU Sanctions Map) 与欧盟整合制裁名单^[10]。在聚合层面, OpenSanctions 等开源项目对多来源制裁条目进行统一格式化、去重与实体对齐, 为跨管辖区制裁信息的整合查询提供便利^[11]。新闻事件数据库方面, Leetaru 和 Schrodtt 提出的 GDELT 项目基于 CAMEO 事件编码体系对全球新闻进行结构化解析, 可提供制裁相关报道的时间线与地理位置信息^[12]。

然而, 现有合规系统普遍依赖静态清单比对与关键词匹配, 难以处理实体别名/译名、关联网络穿透与历史版本回溯等问题, 存在“能命中、难解释、难扩展”的核心痛点。专门面向制裁场景的结构化知识组织与语义检索研究仍相对薄弱, 多源数据之间的实体一致性、证据粒度差异与跨语种表达不一致问题尚未得到系统性解决。

1.3.2 制裁事件抽取与知识图谱构建研究

知识图谱作为一种结构化的知识组织与表示方式, 在近年来取得了显著进展。Hogan 等人系统综述了知识图谱的完整生态系统, 覆盖了从图数据模型、本体设计到推理学习的全生命周期^[13]。Ji 等人聚焦于知识图谱的机器学习方法, 提出了从表示空间、评分函数、编码模型和辅助信息四个维度组织嵌入方法的分类体系^[14]。在中文学术界, 张吉祥等人梳理了基于深度学习的知识图谱构建技术发展历程^[15], 官赛萍等人系统综述了面向知识图谱的知识推理方法^[16]。在大规模知识库建设方面, Wikidata 以协作编辑方式构建了开放的多语言结构化知识库^[17], Bollacker 等人介绍的 Freebase 则开创了大规模协作结构化知识库的先河^[18]。然而, 上述知识图谱主要围绕通用领域或百科类知识展开, 对经济制裁等政策性专业领域的知识建模覆盖不足。

知识图谱构建的核心环节包括信息抽取、实体消歧与知识融合^[13,19]。在通用信息抽取领域, 以 BERT^[20]为代表的预训练语言模型推动了实体识别与关系抽取性能的显著提升, 但在制裁文本这种专业领域与长文档场景中, 仍面临标注数据稀缺、实体别名复杂与跨文档关联难等挑战。Pan 等人系统绘制了大语言模型与知识图谱融合的技术路线图, 提出了 KG 增强 LLM、LLM 增强 KG 与二者协同三种范式框架^[21], 黄勃等人亦从图模互补的视角对该方向进行了中文综述^[22]。刘政昊和张志剑构建了面向金融领域的多层事件演化知识图谱并进行风险分析与预警^[23], 为专业领域知识图谱的应用提供了参考。

面向制裁场景, 知识图谱构建面临如下特殊挑战: 制裁文本来源异构, 包括法规性文本 (行政令、条例条款)、清单性文本 (SDN 名单条目) 与报道性文本 (新闻报道), 各类文本的信息粒度与表达风格差异显著; 制裁实体的别名、译名与缩写极为复杂, 仅俄语姓名的英文转写就存在多种规范体系; 制裁关系具有明确的法律意义, 关系错误将直接影响合规判定, 因此对抽取精度要求极高; 同时, 缺乏大规模标注数

据集，主流 NLP 基准测试数据难以直接适用。

现有面向金融、法律领域的知识图谱研究提供了一定参考，但专门针对经济制裁场景的知识图谱构建研究仍较为稀缺，已有工作多集中于清单数据的结构化整理，缺乏对多源异构文本的系统性抽取方法。

1.3.3 大语言模型驱动的信息抽取研究

大语言模型在零样本与少样本信息抽取任务中展现出突出能力，为低资源专业领域的知识抽取提供了新路径。Brown 等人提出的 GPT-3 首次系统验证了大规模语言模型的上下文学习能力^[24]；Touvron 等人发布的 LLaMA 系列证明了仅使用公开数据即可训练出与闭源模型竞争的开源基础模型^[25]；OpenAI 的 GPT-4 在多项专业基准上展现出人类水平的表现^[26]。Xu 等人全面综述了生成式 LLM 在信息抽取中的应用，建立了按 IE 子任务与技术路线的双维度分类体系^[27]。在关系抽取方面，Wadhwa 等人将关系抽取重构为序列到序列生成任务，发现少样本 GPT-3 的效果接近全监督模型^[28]；Wei 等人提出的 ChatIE 框架将零样本信息抽取转化为多轮问答，在多个数据集上达到或超越全监督模型^[29]。

在提示工程方面，Wei 等人提出的思维链提示（Chain-of-Thought, CoT）通过中间推理步骤显著提升了 LLM 的复杂推理能力^[30]。Madaan 等人提出的 Self-Refine 框架通过“生成—评价—修正”的迭代循环改善 LLM 输出，平均任务表现绝对提升约 20%^[31]。Peng 等人提出的 LLM-Augmenter 系统通过模块化架构实现了事实性评分驱动的迭代纠错^[32]。在幻觉问题方面，Huang 等人提出了区分事实性幻觉与忠实性幻觉的分类框架，系统梳理了检测与缓解策略^[33]。秦小林等人从中文视角综述了大语言模型的关键技术与面临的挑战^[34]。

然而，现有 LLM 抽取方法普遍缺乏对领域 Schema 约束的显式建模，幻觉问题在高风险合规场景中尤为敏感，且难以保证抽取结果与既有图谱的结构一致性。将结构化知识库作为上下文注入 LLM 虽可有效降低幻觉并提升消歧准确率，但在制裁等专业场景的验证仍十分有限。

1.3.4 图结构风险评估与传播建模研究

在风险传播与影响力分析领域，Page 等人提出的 PageRank 算法基于随机游走模型度量节点全局重要性^[35]，可用于刻画风险在多跳网络中的传导效应。在社群发现方面，Blondel 等人提出的 Louvain 算法基于模块度贪心优化实现了十亿级网络上的快速社群划分^[36]，但 Traag 等人发现其存在可能产生内部不连通社群的严重缺陷，进

而提出了保证社群连通性的 **Leiden** 算法^[37]。在时序建模方面，**Hawkes** 提出的自激发点过程奠定了事件时间激发效应建模的数学基础^[38]；**Reinhart** 全面综述了自激发时空点过程在地震学、犯罪学与流行病学等多个领域的应用^[39]；**Mei** 和 **Eisner** 以连续时间 **LSTM** 替代经典的参数化触发核，提出了能同时捕捉激发与抑制效应的神经 **Hawkes** 过程^[40]。

近年来，研究者将图排序与社群发现方法应用于反洗钱（**AML**）与欺诈网络分析。**Weber** 等人发布了加密货币领域最大的公开标注交易数据集，将反洗钱建模为时序交易图上的节点分类任务^[41]，通过社群级别的风险聚合识别团伙性风险行为。在知识服务层面，**Edge** 等人提出的 **GraphRAG** 方法使用 **LLM** 抽取实体图谱并进行层次化社群划分，在全局语义理解任务上显著优于朴素 **RAG**^[42]；**He** 等人提出的 **G-Retriever** 将图检索形式化为奖励收集斯坦纳树优化问题，开创了通用文本图上的检索增强生成范式^[43]。然而，将上述方法与制裁领域知识图谱结合，并输出可解释的风险评分与路径证据，是制裁风险评估领域尚待深入研究的方向，现有文献中尚无系统性工作。

1.3.5 研究现状综述与差距分析

综合以上文献梳理，现有研究在以下方面存在明显空白，如表 1-1 所示。

表 1-1 现有研究差距分析
Table 1-1 Gap analysis of existing research

研究方向	现有进展	研究差距
制裁信息组织	清单聚合、静态比对	多源异构抽取、版本化管理
LLM 信息抽取	通用任务验证	图约束引导、制裁领域适配
图谱风险评估	金融/社交网络	融合时序与结构的制裁风险
知识服务应用	通用 GraphRAG	面向合规的可解释路径溯源

本文针对上述差距，提出 **GSR-ER** 抽取方法与 **HGT-RAM** 风险评估模型，并构建面向制裁合规的端到端知识服务原型，旨在填补制裁领域知识图谱研究的空白。

1.4 研究问题与挑战

结合俄乌冲突制裁场景的特殊性与知识服务需求，本文聚焦以下四项核心研究问题与挑战：

挑战一：多源异构文本的统一知识建模。官方清单、法规文本与新闻报道在信息粒度、命名规范与语义表达上差异显著，如何设计能够覆盖不同来源、兼顾法律精确性与自然语言灵活性的统一 **Schema**，是知识建模的首要难题。

挑战二：跨语种实体歧义与关系冲突消解。同一实体（尤其是俄语人名/机构名）

在不同来源中存在大量别名、译名与缩写变体，且不同来源对同一实体关系的描述可能存在冲突。在缺乏大规模标注数据的条件下，如何实现高精度的实体消歧与关系冲突消解，是抽取质量的关键瓶颈。

挑战三：证据可追溯的高质量抽取与幻觉抑制。制裁场景对抽取结果的可靠性要求极高，幻觉性错误将直接影响合规判定。如何在零/少样本条件下，利用图结构约束引导 LLM 抽取，并通过可验证机制抑制幻觉、保留完整证据链，是本文的核心技术挑战。

挑战四：静态结构风险与动态时序风险的融合评估。制裁网络的风险既包括节点的静态结构重要性（如与高风险节点的关联密度），也包括制裁事件在时间维度的爆发与传播特征。如何将两者在统一框架内融合，并以可解释方式输出风险评分、路径与证据，是风险建模的理论难点。

1.5 研究目标与研究内容

1.5.1 研究目标

本文的总体目标是：针对俄乌冲突经济制裁场景，构建可追溯、可版本化更新的经济制裁知识图谱，并在此基础上提出融合静态结构风险与动态时序风险的可解释评估方法，最终实现支持合规审查与政策研判的知识服务原型系统。

具体目标包括：（1）数据与建模目标：构建覆盖俄乌冲突相关制裁对象的多源数据集，设计涵盖制裁事件六要素（主体、对象、措施、依据、时间、范围）的 Schema，并支持证据可追溯与版本化演化；（2）抽取方法目标：提出面向制裁文本的高精度实体关系抽取方法，在实体识别与关系抽取的 F1 指标上优于无图约束基线，并通过消融实验验证图约束机制与 Self-Refine 迭代对抽取可靠性的提升效果；（3）风险评估目标：提出融合结构与时序的风险评估模型，实现对”未被直接制裁但高度关联”实体的有效识别；（4）系统应用目标：实现支持语义检索、链路溯源与报告生成的知识服务原型，验证端到端流程的可行性。

1.5.2 主要研究内容

围绕上述目标，本文的主要研究内容如下：

研究内容一：多源制裁数据体系与知识图谱建模（第三章第一节至第二节）。收集整理 OFAC、欧盟、OpenSanctions 及 GDELT 等多来源制裁数据，设计经济制裁事件 Schema 与证据可追溯字段，构建可版本化更新的经济制裁知识图谱，存储于 Neo4j 图数据库^[44]。

研究内容二：GSR-ER——图引导的实体关系自优化抽取方法（第三章第三节至第四节）。提出 GSR-ER（Graph-Guided Self-Refine for Entity-Relation）方法，通过图上下文（Graph Context）构建、图引导约束机制、大语言模型初始抽取与 Self-Refine 迭代校验四个模块，实现面向制裁文本的高质量结构化抽取。在实验设计上，采用标准 Precision/Recall/F1 指标评估实体识别与关系抽取质量，以“无 Graph Context 的 LLM 直接抽取”、“仅规则/词典抽取”等为对照组进行对比实验；同时设计消融实验，通过逐步移除 Graph Context、图引导约束与 Self-Refine 模块，对比各阶段输出中证据缺失三元组与图谱结构冲突三元组的比例变化，结合人工抽样复核，从定性与定量两个维度验证图约束机制对抽取可靠性的实际贡献，而非追求孤立的幻觉率绝对数值。

研究内容三：HGT-RAM——层次化图时序风险评估模型（第四章）。提出 HGT-RAM（Hierarchical Graph-Temporal Risk Assessment Model），融合加权个性化 PageRank（静态结构风险）、Leiden 社群风险聚合（社群层风险）与 Hawkes 点过程（动态时序风险），输出综合风险分值、关键传播路径与证据线索，并验证模型的有效性与可解释性。

研究内容四：知识图谱应用系统设计与实现（第五章）。设计并实现面向合规审查与制裁研判的知识服务原型系统，集成 GSR-ER 抽取入库流水线、HGT-RAM 风险评估模块与基于 GraphRAG 的检索增强生成接口，支持制裁对象查询、证据溯源、风险链路分析与报告生成等典型应用；同时设计版本化图谱更新机制（新增/变更/失效三类变更集与版本号/有效时间区间标注），保证图谱历史状态可回放，以满足高频更新场景下的可审计需求。

1.6 主要创新点

本文主要创新点可概括为两点：

创新点一：图引导自回溯的实体关系抽取方法（GSR-ER）。针对制裁文本实体别名复杂、关系冲突频繁、标注数据稀缺的挑战，提出 GSR-ER 方法：利用已有图谱的 k 跳邻域子图构建 Graph Context，在 LLM 提示中引入图约束（实体类型、关系方向、证据绑定），通过 Self-Refine 机制对低置信度结果进行迭代修正。该方法在无需大规模标注数据的前提下，提升制裁领域的实体消歧准确率与关系一致性，显著抑制 LLM 幻觉。

创新点二：层次化图时序风险评估框架（HGT-RAM）。针对制裁风险评估中静态结构与动态时序难以统一建模的问题，提出 HGT-RAM：在图谱层次结构基础上，以加权个性化 PageRank 刻画个体结构影响力，以 Leiden 社群发现结合社群风险聚合刻画团簇风险外溢，以 Hawkes 强度函数刻画制裁事件的时间激发与衰减。三者通过特

征驱动的自适应融合机制加权融合形成综合风险分值，并以“分值分解 + 关键路径 + 证据溯源”的形式输出可解释结果，实现对潜在制裁风险主体的有效识别。

1.7 技术路线与论文组织结构

1.7.1 技术路线

本文技术路线总体遵循“数据采集与预处理 → 知识图谱建模 → GSR-ER 抽取入库 → HGT-RAM 风险评估 → 知识服务应用”的端到端闭环路线：

(1) 数据层：从 OFAC、欧盟、OpenSanctions、GDELT 等多源渠道采集结构化清单与非结构化文本，经字段标准化、去重与语言识别等预处理步骤，形成供抽取使用的样本单元，同时构建候选实体词典与别名表；(2) 图谱建模层：基于制裁事件 Schema 设计实体类型与关系类型，构建含证据字段与版本信息的初始图谱骨架，以 Neo4j 作为图存储引擎；(3) 知识抽取层（GSR-ER）：以文本片段 + Graph Context 为输入，经 LLM 初始抽取、图引导约束校验与 Self-Refine 迭代修正三阶段，输出结构化三元组与证据片段，融合入库并触发版本化更新；(4) 风险评估层（HGT-RAM）：在当前图谱版本上计算加权个性化 PageRank 与 Leiden 社群划分（静态风险），同时基于时间窗内事件序列拟合 Hawkes 强度函数（动态风险），融合得到综合风险分值并回写图数据库；(5) 知识服务层：提供图检索、语义检索与 GraphRAG 式检索增强生成接口，支持制裁查询、风险链路分析与报告自动生成等业务功能。

1.7.2 论文组织结构

本文共六章，各章内容安排如下：

第一章（引言）：介绍研究背景、研究意义、国内外研究现状综述、研究问题与挑战、研究目标与内容、主要创新点及技术路线。

第二章（相关理论与关键技术）：系统介绍支撑本文方法的理论基础，包括经济制裁与合规风险基础、知识图谱构建技术、信息抽取技术、大语言模型与提示工程、检索增强生成（RAG/GraphRAG）及图结构分析与时序建模方法。

第三章（数据集与知识抽取方法：GSR-ER）：介绍多源数据体系与标注规范、事件 Schema 与图谱建模，重点提出 GSR-ER 方法，并给出实验设计与结果分析。

第四章（层次化图时序风险评估模型：HGT-RAM）：提出 HGT-RAM 模型，包括层次化图谱建模、静态风险（PageRank + 社群聚合）、动态风险（Hawkes 过程）与综合融合，并给出实验验证与可解释性分析。

第五章（经济制裁知识图谱应用系统设计与实现）：介绍系统总体架构与各模块

实现，展示典型应用案例，并进行系统性能和质量评估。

第六章（总结与展望）：总结全文主要研究成果与创新点，指出现有工作的不足，并展望未来研究方向。

2 相关理论与关键技术

本章围绕“经济制裁知识图谱构建与应用”的核心研究链条，从六个维度系统梳理支撑性理论与关键技术。整体逻辑如图 2-1 所示：首先介绍经济制裁与合规风险的领域基础（第 2.1 节），为后续知识建模提供业务语义；随后介绍知识图谱建模原则与存储机制（第 2.2 节）与信息抽取任务及关键难点（第 2.3 节），构成图谱构建的技术骨架。随后讨论图引导约束下的 LLM 驱动实体关系抽取与质量控制（第 2.4 节），并进一步介绍 GraphRAG 与证据可解释输出机制（第 2.6 节）；最后介绍支撑 HGT-RAM 模型的图时序风险建模基础（第 2.5 节）。各节的技术选型均紧扣第 2.1 节提炼的场景约束，不作泛化综述。




图 2-1 相关理论与关键技术总体框架

Figure 2-1 Overall Framework of Relevant Theories and Key Technologies

2.1 经济制裁与合规风险分析

2.1.1 经济制裁概念、分类与典型措施

经济制裁（Economic Sanctions）通常指制裁主体通过贸易、金融、投资、技术与人员往来等限制措施，对目标国家、组织或个人施加压力，以达到特定政治或安全目标^[45]。从执行主体看，制裁可由联合国等国际组织、多边联盟（如欧盟、G7）或单边国家机构（如美国财政部 OFAC、美国商务部 BIS）发起与实施；从目标范围看，既包括针对主权国家的全面制裁（Comprehensive Sanctions），也包括将制裁对象收窄至特定个人、实体、行业或关键技术环节的”智能制裁（Smart Sanctions）”与”定向制裁（Targeted Sanctions）”。

在俄乌冲突相关制裁中，常见措施类型如表 2-1 所示，主要包括：（1）资产冻结：禁止处置或转移受制裁方在相关司法辖区内的资产；（2）金融限制：禁止融资、结算或提供信用，并对 SWIFT 系统访问权限加以限制；（3）出口管制与技术限制：禁止向受制裁方出口特定商品（尤其是军民两用技术与半导体）；（4）航运与保险限制：限制船舶挂旗、港口停靠及海运保险服务；（5）旅行禁令：禁止相关个人入境特定国家或地区。

表 2-1 俄乌冲突相关制裁措施类型及执行主体
Table 2-1 Types of sanctions related to the Russia-Ukraine conflict and implementing bodies

措施类型	核心内容	代表性执行主体
资产冻结	禁止资产转移与处置	OFAC, EU Council
金融限制	SWIFT 断联、信贷禁止	G7, EU
出口管制	军民两用品、半导体禁运	BIS, EU
航运/保险限制	港口禁入、海运保险禁止	G7, UK
旅行禁令	签证禁止与边境管控	EU, UK, US

2.1.2 制裁溢出效应与风险传播机制

制裁网络化与系统化的一个重要表现是风险的”关系驱动”传播。当某实体被列入制裁名单，其直接或间接关联方可能因交易往来、股权控制、高管任职、共同所有权或同一供应链位置而受到合规审查与次生影响，形成所谓的制裁溢出效应（Sanctions Spillover）。

从图论视角抽象，制裁风险的传播可建模为带权有向图上的扩散过程：风险由高风险种子节点（已被制裁实体）沿关系边向邻域扩散，扩散强度与关系类型（控制、代理、关联）、边权及时间衰减因子相关。这一抽象为后续 HGT-RAM 模型设计提供

了形式化基础。之所以选择图结构而非仅依赖向量空间模型，是因为风险链路的解释依赖关系方向与类型的精确区分——“A 控制 B”与“B 控制 A”在法律后果上截然不同，而稠密向量表示无法可靠编码这一方向性。

2.1.3 国际合规准则与风险判定依据

在合规实践中，风险判定通常需要依据官方制裁清单与法规条款，同时对“控制关系（Ownership/Control）”“代表关系（Acts-For）”“家族关系（Family Relationship）”等高风险间接关联进行穿透识别。以美国 OFAC 为例，其“50% 规则”规定：若被制裁方直接或间接持有某实体 50% 以上股权，该实体即被视为受制裁，无论其是否出现在官方名单中。这意味着合规系统不能止步于名单精确匹配，还必须具备多跳路径推理与结构穿透能力。

由于不同司法辖区对“控制”的定义与执行口径存在差异，且制裁信息高频更新，合规系统需要具备以下能力：证据可追溯（能够定位每条风险结论所依据的原始公告或法规条款）、版本可回溯（能够还原任意时间点的图谱状态），以及多辖区规则并行处理。这三项需求直接影响本文图谱建模方案与应用系统设计。

2.1.4 俄乌冲突制裁的特殊性与技术挑战

与历史制裁案例相比，俄乌冲突引发的制裁呈现出以下独特特征，对知识图谱构建与风险评估带来额外挑战：

（1）规模大、更新快：自 2022 年 2 月以来，OFAC、欧盟、英国、加拿大、澳大利亚等主要制裁方累计发布数百批次制裁更新，信息迭代频率极高；（2）主体多元、协调复杂：多国制裁机构并行发布，各方在制裁对象、措辞与执行口径上存在不一致，导致数据融合难度大；（3）实体别名/译名歧义显著：俄语、英语及中文的人名/机构名转写规则不统一，同一实体可能以数十种变体出现在不同来源文本中；（4）证据链要求严格：企业合规场景要求每一风险判定都能追溯到可核查的原始文档，不可依赖模糊匹配或黑盒模型输出。

上述四项特征对后续技术路线的选择构成直接约束，在此明确列出各约束与技术选型之间的对应关系，以统领全章：（a）别名/译名歧义问题表明单纯基于字符串匹配或纯序列标注的抽取方案不可行，需要引入结构化外部知识辅助消歧，指向第 2.4 节的图上下文机制；（b）证据链要求表明生成式模型必须配合外部可验证机制，指向第 2.4 节的幻觉抑制与可验证抽取；（c）高频更新特性表明图谱存储方案必须支持增量写入与版本化，而非批量重建，指向第 2.2 节的属性图存储与版本字段设计；（d）风

险关系驱动传播表明需要图结构路径推理而非纯文本检索，指向第 2.5 节的 PageRank 与社群风险聚合。这四条约束链贯穿后续各节，不再逐一重复推导，而是在相应节中直接援引。

2.1.5 现有工具的能力边界与本文技术路线的形成

上述挑战并非理论设定，而是在现有工具的应用评估中形成的需求缺口。本节从能力边界出发，说明本文技术路线的必要性。

制裁数据平台与名单服务（如 OFAC、欧盟制裁地图、OpenSanctions）能够提供高可信度的名单核验，是合规实践的基础设施；其局限在于以实体条目为主组织数据，缺少显式关系网络与自动化穿透查询能力。因而，该类平台可支持直接命中检索，但难以支撑基于控制链、代理链和股权链的结构化风险判断。

通用信息抽取方法可完成文本结构化，但在制裁场景面临两类约束：其一，领域标注依赖法律或政策研究专家，成本高且随政策演化快速失效；其二，跨句、跨文档关系及多语别名归并难以由句级监督模型稳定处理。由此导致抽取结果在复杂关系恢复与实体一致化方面存在系统性缺口。大语言模型在零/少样本理解和长程推理上具有明显优势，能够缓解低资源条件下的建模压力；但直接问答式抽取仍受幻觉与一致性波动制约，尤其在结构化输出任务中难以仅凭模型内部机制保证可验证性与可复现性。因此，LLM 需与外部结构约束和一致性校验联合使用。

静态图风险评分能够刻画网络中的结构关联强度，但将风险视为时间无关状态，无法反映制裁事件的阶段性激发与衰减过程。在预警场景下，仅依赖静态评分会低估近期事件冲击对后续风险扩散的影响。据此，本文采用分层集成路线：以权威名单保证数据可信性，以图谱建模显式化关系网络，以 LLM+图约束实现可验证抽取，以图时序模型刻画动态传播。该路线并非技术叠加，而是对既有工具能力边界的对应性补全。

2.2 知识图谱建模原则与存储机制

2.2.1 知识图谱定义与构建流程

面向经济制裁场景，本文采用知识图谱作为核心数据组织形式，关键考虑不在于“是否可表示三元组”，而在于其能够同时满足三项工程约束：一是跨源实体与关系的统一标识，二是多跳关系可计算，三是证据与版本可追溯。相较于关系型表结构，图结构更适合表达穿透式关联链；相较于仅依赖向量库的语义存储，知识图谱在关系方向、类型约束和路径可解释性上更具确定性^[46]。

Fensel 等人系统阐述了面向知识图谱完整生命周期的实践方法论^[47]。知识图谱的典型构建流程包括以下阶段：（1）知识建模——根据目标应用场景定义本体与 Schema，确定实体类型集合与关系类型集合；（2）信息抽取——从非结构化文本（新闻、公告）与半结构化数据（清单、表格）中抽取实体与关系三元组；（3）实体对齐与融合——将来自不同来源的同一实体提及链接到统一标识符，并消解冲突信息；（4）存储与索引——将图谱持久化到图数据库，并建立全文索引与向量索引以支持多模式检索；（5）持续更新与维护——针对新增信息进行增量抽取与版本化更新，维护图谱的时效性。上述五个阶段并非线性单次执行，而是形成“抽取—入库—更新—再抽取”的迭代循环，图谱质量随迭代轮次逐步提升。

本文面向制裁场景的图谱构建遵循上述流程，并在各阶段引入领域约束（详见第 3 章）。本文不采用“端到端神经知识库补全替代结构化入库”路线，原因在于该路线虽可提升隐式关联发现能力，但难以满足合规场景对可审计证据链与确定性规则约束的要求。

2.2.2 本体建模与 Schema 设计

本体（Ontology）是对特定领域概念及其关系的形式化描述，为知识图谱提供语义约束骨架。Schema 设计存在两种方向上的取舍，需要根据本文场景明确选择。

第一种方向是复用通用知识图谱本体（如 Wikidata 的实体类型体系或 YAGO 的本体层次），其优势是与外部知识源的互操作性良好，便于引入背景知识。然而，通用本体对制裁特有概念的表达能力不足：Wikidata 中不存在“制裁事件”作为一等公民节点，更无法原生支持“豁免条款”“有效期区间”等合规核心字段；其关系类型集合亦缺乏 ACTS_FOR（代理关系）和 SANCTIONED_BY 等对穿透识别至关重要的语义区分。若强行套用通用本体，上述信息只能折叠为泛化属性，导致关系约束检验和路径查询的语义精度大幅下降。

第二种方向是设计完全领域专用的 Schema。其优势是语义精确，但完全自定义本体孤岛化严重，难以与 OpenSanctions、OFAC 等权威制裁数据源进行标准化对接，增加了融合成本。

本文采取折中路线：实体类型层面复用 OpenSanctions 的分类体系（Person、Organization、Company、LegalEntity、Vessel、Airplane 等），以保持与权威数据源的结构对齐；事件与关系层面则设计领域专用的六要素事件结构（Actor / Target / Measure / Basis / Time / Scope）及若干制裁专属关系类型，原因是此类结构在现有通用本体中无对应表示。Schema 整体遵循“开放世界假设（Open World Assumption）”，对未知关系保持容忍，并为每条事实预留证据字段（source、span、timestamp、confidence、version）

以支持可追溯性（详见第 3.2 节）。

2.2.3 图数据库存储与查询

本文采用 Neo4j 作为图存储引擎^[44,48]。Neo4j 是一种原生图数据库，以属性图（Property Graph）模型存储节点与边，并提供 Cypher 查询语言支持灵活的图模式匹配与路径查询。之所以选择原生图数据库而非将三元组存入关系型数据库模拟图查询，主要原因是：制裁合规场景中的核心查询（如“目标实体与制裁实体之间是否存在 k 跳以内的控制链路”）需要递归路径遍历，在关系型数据库中对应深度不定的递归 JOIN 操作，性能随跳数指数劣化；而 Neo4j 的原生图存储与索引专为路径遍历优化，在此类查询上具有决定性优势。

在制裁图谱场景中，典型查询需求包括：

（1）单跳查询：查询某实体的制裁状态与证据条款；（2）多跳路径查询：寻找制裁实体与查询目标之间的关系链路（如“公司 A 的控股方 B 是否受到制裁”）；（3）风险传播子图提取：抽取某节点的 k 跳邻域用于风险评分计算。

Cypher 语言中的 MATCH ... WHERE ... RETURN 模式天然支持上述查询，并可通过图索引优化在大规模图谱上的执行效率。

2.3 信息抽取任务与关键难点

2.3.1 命名实体识别

命名实体识别（Named Entity Recognition, NER）是从文本中定位并分类命名实体（如人名、机构名、地名、日期等）的序列标注任务。其基本形式为：给定词序列 $x_1, x_2, \dots, x_n$ ，输出每个位置的实体边界与类型标签 (B -TYPE, I -TYPE, O)。

预训练语言模型（如 BERT^[49]）通过双向上下文编码显著提升了 NER 的跨领域迁移能力，但在制裁文本中仍面临三类难以通过微调单独解决的瓶颈。**第一**，跨语种译名变体：俄语人名与机构名在英语来源中存在多种转写形式（如 Kovalchuk / Kovalchuck / Kovalchuk），且与中文来源的音译规则不一致，序列标注模型无法仅凭上下文窗口内的字符特征可靠区分这些变体与同名不同人。**第二**，嵌套实体：制裁对象的机构名称往往包含国家名、地名等子实体（如“俄罗斯联邦储蓄银行”嵌套“俄罗斯联邦”），BIO 标注框架对嵌套实体的表达能力有限。**第三**，领域专有类型覆盖不足：Vessel（船舶）、Airplane（航空器）、Cryptocurrency Address（加密货币地址）等制裁特有实体类型在通用预训练语料中极为罕见，模型难以从预训练阶段获得可迁移的表示。

基于上述分析，本文并未采用“纯序列标注一次完成实体识别”的单路线，而是在 GSR-ER 中引入图上下文别名表与模式约束进行后验校正：将已有图谱中的规范名称与别名集合注入提示，作为模型识别时的外部锚点，以降低同名混淆与类型误判（详见第 3.3 节）。

2.3.2 关系抽取与事件抽取

关系抽取（Relation Extraction, RE）与事件抽取（Event Extraction, EE）在本文中承担不同功能：前者用于恢复实体间稳定关系（如股权控制、高管任职），后者用于刻画“主体-对象-措施-时间-依据”等时态事实。

在制裁场景中，依赖大规模标注语料进行监督微调的方法面临一个结构性困境：获取高质量标注数据需要精通制裁法律的领域专家，标注成本极高；更重要的是，制裁关系类型随新制裁政策的持续出台而演化（如近年新增的“加密货币钱包冻结”关系），导致已有标注语料的覆盖面快速过时，维护成本难以承受。这一困境使得基于全监督微调的方法在本场景下不具备实用可行性。

另一方面，制裁关联的关键线索常跨多句乃至多文档分散。以一条典型推断链为例：“A 公司由 B 控股”（来源：企业注册信息）、“B 为 C 的代理人”（来源：新闻报道）、“C 已于 2023 年被 OFAC 列入 SDN 名单”（来源：官方清单）——完成对 A 公司的风险判断需要跨三个来源、三跳关系的推理，而基于句级窗口的监督模型无法稳定处理此类长程跨文档依赖。

上述两点共同决定了本文需要一种具备零/少样本能力、能进行长程推理的抽取方案，并辅以可验证的结构约束补偿其一致性不足的问题。这直接指向以 LLM 为生成骨干、以图结构知识为约束的 GSR-ER 方法（详见第 3 章）。

2.3.3 实体对齐、消歧与知识融合

实体链接（Entity Linking）与消歧（Disambiguation）是多源知识融合的核心环节，即将来自不同文本的同一现实世界实体的多种提及（Mention）映射到知识图谱中的统一标识符^[19]。

制裁场景中的消歧难点主要来自三个方面：（1）**别名多样性**，同一人物可能以拉丁转写、西里尔字母原文、中文音译等多种形式出现，典型如“Roman Abramovich”/“Роман Абрамович”/“罗曼·阿布拉莫维奇”三种形式在不同数据源中均有出现；（2）**同名歧义**，不同个人或机构可能共享相同或相似名称，仅凭名称字符串无法区分；（3）**机构重组规避**，制裁对象可能通过更名、分拆、股权转让等手段规避制裁，导致实体标识

符的历史连续性中断，传统基于字符串相似度的方法难以追踪实体的版本演化。

通用实体消歧方法通常依赖字符串相似度与实体描述语义，在本场景下存在明显局限：字符串方法对别名变体鲁棒性差；描述语义方法依赖实体在通用知识库（如 Wikipedia）中的条目，而大量制裁实体（尤其是中小企业和中层人员）在通用知识库中根本不存在条目，导致语义比较无从进行。融合策略须综合考量字符串相似度（编辑距离、BM25）、上下文语义相似度（嵌入向量余弦距离）、**结构邻域一致性**（知识图谱中已知关系的兼容性）以及证据权重（来源可信度）。其中，结构邻域一致性是在通用消歧方法基础上的关键扩展：若两个候选实体的已知关联实体高度重叠（例如均与同一家银行存在业务关系，且均关联同一地址），则可大幅提升链接可信度，即使名称字符串差异较大亦然。本文在 GSR-ER 中通过图上下文注入实现这一结构层面的辅助消歧决策（详见第 3.3.3 节）。

知识融合（Knowledge Fusion）进一步涵盖冲突消解：当来自不同来源的事实存在矛盾时（例如 OFAC 清单与欧盟清单对同一实体的股权比例描述不一致），系统须根据来源可信度、时间戳及证据数量做出取舍，并完整保留所有原始证据以满足合规审计要求。

2.4 LLM 驱动的结构化抽取与质量控制

2.4.1 大语言模型基础与零/少样本能力

大语言模型（Large Language Models, LLMs）以 Vaswani 等人提出的 Transformer 架构为基础^[50]，通过大规模语料的自监督预训练获得强大的语言理解与生成能力^[24]。GPT 系列、LLaMA^[25]、Qwen^[51] 等代表性 LLM 在参数量超过数百亿后，展现出显著的涌现能力（Emergent Ability）^[34]，包括无需标注样本的零样本（Zero-Shot）推理与仅需少量示例的少样本（Few-Shot）学习。

在信息抽取任务上，LLM 的零/少样本能力使其能够在制裁文本这类低资源领域直接完成实体识别与关系抽取，无需构建大规模标注语料——这与第 2.3 节分析的监督学习结构性困境直接对应。然而，LLM 也存在两类显著缺陷：其一，**幻觉问题**（Hallucination）^[33]——模型可能生成与事实不符但语言上通顺的输出，例如编造并不存在的公司名称或股权比例；其二，**一致性不足**——对语义等价的不同问法，模型可能给出相互矛盾的结果。上述两类缺陷在高风险合规场景中会直接削弱结论可靠性：虚假关联可能引发误判，且证据不可追溯将导致审计不可通过。因此，GSR-ER 在 LLM 抽取层之上引入图约束与自优化机制，以提升结果的真实性、一致性与可审计性。

2.4.2 提示工程与思维链推理

提示工程（Prompt Engineering）是通过设计输入提示（Prompt）来引导 LLM 完成特定任务的技术方法。在结构化抽取场景中，常用策略包括：（1）角色提示（Role Prompting）：指定模型扮演“制裁领域知识抽取专家”等特定角色以激活相关知识；（2）输出格式约束：明确要求模型以 JSON 格式或特定三元组格式输出，以便程序化解析；（3）少样本示例（Few-Shot Examples）：在提示中内嵌若干正确的抽取示例，引导模型对齐预期的输出格式与语义粒度。

思维链推理（Chain-of-Thought, CoT）^[52]在复杂推理任务上通常可提升准确率，但在合规场景中需要谨慎应用。若直接要求模型输出无约束的长链路自由推理文本，会引入额外噪声——推理过程中的中间错误可能导致最终结论偏离，且冗长的推理输出增大了程序化解析的难度。基于此，本文采用“结构化中间结论优先”策略：要求模型先给出可校验的关系/事件草案与证据跨度（Evidence Span），再由外部校验模块触发必要的回溯修正，而非由模型自由延伸推理链。这一策略保留了 CoT 的逐步推导优势，同时将推理过程约束在可解析的结构化输出范围内。

2.4.3 自优化（Self-Refine）机制

自优化（Self-Refine）^[31]是一种通过模型对自身输出进行批评与修正的迭代优化范式。其基本流程为：模型首先生成初始输出（Initial Output），然后由同一模型（或专用批评模型）对输出进行质量评估并生成反馈（Feedback），最终模型根据反馈重新生成修正后的输出（Refined Output）。此过程可重复执行，直至输出满足停止条件（质量检验通过、迭代轮数达到上限或置信度提升低于阈值）。

然而，原始 Self-Refine 直接用于知识抽取存在关键缺陷：其反馈信号完全来自模型内部语义判断，属于开环优化。在该机制下，模型可能保留与外部事实冲突但内部自洽的结果，且在缺少外部基准时难以及时识别。对合规应用而言，此类错误与幻觉具有同等风险。

本文对 Self-Refine 框架的核心改造是引入外部锚点的闭环校验机制，将“开环优化”转变为“带图谱一致性约束的闭环修正”：每轮迭代后，抽取结果先经过 Schema 约束检验（拒绝类型不匹配的三元组）和图谱冲突检验（对与现有图谱强冲突的关系降权并标记），再将具体的冲突点、相关证据句和图上下文共同作为反馈输入，要求模型针对确定性的外部矛盾进行定向修正，而非对整体输出做泛化调整。这一改造使反馈信号由“模型认为哪里不好”转变为“图谱一致性检验确认哪里有冲突”，显著提升了修正的针对性与可重复性（详见第 3.3.5 节）。

2.4.4 幻觉抑制与可验证抽取

针对 LLM 的幻觉问题，面向高风险合规场景的可验证抽取需在以下四个层面系统性地引入约束，每一层均针对不同类型的潜在错误：

(1) **结构约束**：对 LLM 的输出施加 Schema 层面的类型约束与方向约束，在进入图谱之前拒绝不符合预定义模式的结果（如 LEADER_OF 的主体必须为 Person 类型）。该层约束针对的是实体/关系类型错误，这类错误通常源于模型对领域模式的不熟悉，通过规则可零成本拦截；(2) **证据绑定**：要求每条抽取结果必须绑定原文中的证据片段（Evidence Span），无法定位证据的结论视为低置信度并触发人工复查。该层约束使每条入库事实都附带可审计的原始依据，直接对应第 2.1.4 节的证据链要求；(3) **一致性检验**：将抽取结果与现有图谱进行对比，对与已知事实强冲突的结果降权或拒绝入库。该层约束利用已积累图谱知识过滤新抽取结果中的幻觉，冲突检验的置信度随图谱规模增长而提升；(4) **外部知识锚定**：通过图上下文将已知实体标识符注入提示，使模型抽取时能够将文本提及对齐到图谱中的确定性节点，降低同名实体的混淆风险。该层约束将第 2.3 节分析的消歧难点从后处理环节前移至生成阶段，在源头减少歧义引入。

四层约束形成递进防御体系：前两层在单条结果层面独立作用，后两层在全局图谱一致性层面联合作用，共同将 LLM 的开放生成能力约束在合规场景可接受的质量边界内。

2.5 图时序风险建模基础

2.5.1 图排序与影响力度量

在候选结构风险建模方法中，本文选择 PageRank 系列而非仅使用局部中心性指标（如度中心性、介数中心性），主要原因是后者仅刻画节点在一跳或全局最短路径层面的重要性，无法建模制裁风险的多跳传导效应。度中心性高的节点未必处于制裁传播链的关键位置（例如，一个拥有大量普通业务伙伴的公司，其度中心性高，但若所有伙伴均未受制裁，其制裁风险传导分值应较低）；而 PageRank 基于全局随机游走，可在全图范围内自然刻画“与高风险节点的多跳结构关联强度”，与合规场景的风险传导语义更为吻合^[53]。

个性化 PageRank（Personalized PageRank, PPR）将均匀初始分布替换为个性化向量 $\mathbf{w}$ ，使随机游走以一定概率重置到指定起始节点集合，从而刻画相对于特定高风险

起点的传播影响力。给定有向图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，经典 PageRank 的迭代形式为：

$$PR(v) = (1 - d) \cdot \frac{1}{|\mathcal{V}|} + d \cdot \sum_{u \in N^-(v)} \frac{PR(u)}{|N^+(u)|}, \quad (2.1)$$

其中 $d \in (0, 1)$ 为阻尼因子， $N^-(v)$ 为指向 v 的前驱节点集合， $N^+(u)$ 为节点 u 的后继节点集合， $|N^+(u)|$ 为其出度。式 (2.1) 的核心思想是：节点的重要性由其前驱节点的重要性按出度归一化后累积决定，阻尼因子 d 控制随机游走继续沿边传播与以均匀概率重置到任意节点之间的平衡。

在个性化 PageRank 中，将均匀重置项 $\frac{1}{|\mathcal{V}|}$ 替换为个性化向量 $w(v)$ (满足 $\sum_v w(v) = 1$)，使随机游走倾向于重置到特定“种子”节点，从而刻画相对于种子节点集合的结构关联强度。在制裁网络中，可将已被官方清单明确制裁的节点设为高权重种子，使 PPR 分值直接反映节点与高风险实体之间的结构关联强度，而非泛化的网络中心性。进一步引入关系类型边权 $w_e(u, v)$ 后，可精细区分“控制关系”与“地址关联”等不同类型关系的风险传递强度。第 4 章在此基础上引入加权边与制裁状态感知的个性化向量，给出面向制裁场景的改造版本（详见第 4.3.1 节）。

2.5.2 社群发现与风险聚合

社群发现（Community Detection）旨在识别网络中连接紧密、模块度较高的节点集合，对应现实世界中的利益共同体、控制网络或供应链团簇。与仅使用节点邻域平均或固定 k 跳聚合相比，社群划分能够以自适应边界识别结构上真正紧密联系的群体，更适合捕捉制裁关联网络中规模和形状各异的利益团体。

经典的 Louvain 算法^[36]通过贪心优化模块度（Modularity）指标进行分层聚合，但存在一个已被形式化证明的结构缺陷：其优化过程可能产生内部不连通的社群，即划分结果中的同一社群内的节点之间可能不存在通过社群内部边的路径相连。在制裁图谱应用中，这一缺陷的危害尤为严重——若两个本质上属于不同利益网络的实体被错误地合并为同一社群，系统将输出“这两者属于同一高风险团体”的结论，而该结论既无内部关系路径支撑，也无法在合规审计中提供可追溯的关系链。对于要求每一风险结论都必须对应明确证据链的合规场景，一个社群内部不连通即意味着该社群归属结论不可解释，直接违反可审计要求。

Leiden 算法^[37]在 Louvain 基础上引入“社群细化（Refinement）”阶段：每次节点移动后，对所有节点在其当前社群内进行局部重新划分，通过随机子集游走保证每个输出社群的内部连通性，从根本上消除了上述缺陷。这一保证对于可解释风险输出至关重要：当系统输出“节点 A 属于高风险社群”时，必须保证该社群内存在从 A 出发的可追溯关系路径；Leiden 算法的连通性保证直接支撑了这一可解释性需求（详见第

4.3.2 节)。

2.5.3 Hawkes 点过程与时序传播

在时间动态建模候选方法中, 本文选择 Hawkes 过程而非离散时间计数回归或固定窗口移动平均, 主要原因是前者能够在连续时间框架下同时表达“事件自激发”与“影响指数衰减”两种机制, 且参数语义明确、便于解释^[54]。固定窗口移动平均无法区分同一窗口内事件的时间先后对风险强度的不同贡献; 离散时间回归依赖窗口长度的预设, 对制裁事件的突发性爆发响应迟滞。

Hawkes 过程的核心是条件强度函数 (Conditional Intensity Function), 给定时刻 t 之前的历史事件序列 $\mathcal{H}_t = \{t_1, t_2, \dots, t_n : t_i < t\}$, 条件强度定义为:

$$\lambda(t) = \mu + \sum_{t_i < t} \phi(t - t_i), \quad (2.2)$$

其中 $\mu \geq 0$ 为基底强度 (background rate), 表示在无历史事件激发下的基准事件发生速率; $\phi(\cdot)$ 为触发核 (triggering kernel), 刻画历史事件对当前强度的激发效应。当采用指数衰减核 $\phi(\tau) = \eta \exp(-\rho \tau)$ 时, $\eta > 0$ 控制单个历史事件的瞬时激发幅度, $\rho > 0$ 控制激发效应的衰减速度。为保证过程的平稳性, 需满足分支比条件 $\eta/\rho < 1$, 即单个事件的期望后代事件数小于 1。

式 (2.2) 的直觉含义与制裁事件的“滚动升级”模式高度契合: 某实体被制裁后, 可能在短期内引发追加制裁、关联实体曝光、政策加码等连锁反应, 对应 $\lambda(t)$ 在事件发生后的跳升与随后的指数衰减。需要指出的是, 标准 Hawkes 过程的平稳性假设、单变量激发结构等前提条件在制裁场景下并非完全成立, 需要结合具体数据特征进行针对性调整, 相关分析与处理方案详见第 4.4 节。

在相关研究方面, Reinhart 系统综述了自激发时空点过程在地震学、犯罪学与流行病学中的应用及参数估计技术^[39]。Mei 和 Eisner 提出的神经 Hawkes 过程以连续时间 LSTM 替代参数化触发核, 能够同时捕捉激发与抑制效应^[40]; 尽管其表达能力更强, 但黑盒特性与合规场景对参数语义可解释性的要求存在根本张力, 因此本文采用经典参数化形式。第 4 章在式 (2.2) 的基础上引入节点级参数化与事件序列构建策略, 给出面向制裁场景的改造版本。

2.5.4 异质图建模与多关系网络

制裁知识图谱本质上是一个异质图 (Heterogeneous Graph): 节点存在多种类型 (Person、Organization、Sanction 等), 边也存在多种语义类型 (OWNS、LEADER_OF、SANCTIONED_BY 等)。普通的同质图方法无法区分不同类型的节点与边, 统一处理会

导致语义信息的丢失——将“A 控制 B”与“A 与 B 同在一栋楼”视为等价关系，对风险传递强度的估计将产生系统性偏差。

在本文框架中，异质图建模的主要作用体现在两个层面：（1）在风险传播中，不同类型的关系（如“控制关系”与“业务往来关系”）对应不同的风险传递强度，通过关系类型区分实现精细化边权设置；（2）在 GraphRAG 检索中，基于关系类型的多跳检索（如 $\text{Person} \xrightarrow{\text{LEADER_OF}} \text{Company} \xrightarrow{\text{SANCTIONED_BY}} \text{Sanction}$ ）比随机游走更能提供语义明确、可对应法律规则的关系链路。

本文在主线方法中不引入额外的异质图深度学习模型（如基于元路径注意力的 HGNN 变体），而采用“关系类型显式建模 + 可解释边权设定”路线。该选择的主要考量是：在样本规模有限且审计要求严格的合规场景下，显式关系建模在可解释性、参数可控性与部署复杂度方面更具优势；深度异质图模型的黑盒特性与“每条风险结论需可追溯至原始证据”的合规要求之间存在根本张力。

2.6 GraphRAG 与证据可解释输出

2.6.1 检索增强生成（RAG）

检索增强生成 (Retrieval-Augmented Generation, RAG)^[55] 是一种将信息检索 (Retrieval) 与生成式语言模型 (Generation) 结合的范式：在生成回答前，系统首先从外部知识库中检索与问题相关的文档片段，将其作为上下文输入生成模型，从而提升回答的事实性与可追溯性。

RAG 的基本流程为：用户查询经编码后，从文档向量库中检索 k 个最相关片段，与原始查询拼接后输入 LLM 生成最终回答。本文未采用“仅依赖参数化大模型直接问答”路线，原因有二：其一，参数化知识难以稳定提供可核验的来源引用，在合规审查中无法满足证据可追溯要求；其二，制裁政策信息高频更新，而大模型的知识存在时效截止限制，无法反映最新制裁动态。RAG 通过从实时更新的外部知识库检索，同时解决了上述两个问题。

2.6.2 图检索增强生成（GraphRAG）

尽管 RAG 解决了时效性与来源可追溯问题，基于稠密向量检索的标准 RAG 在制裁场景中仍有一个结构性局限：向量检索以文本片段为粒度，检索结果是若干语义相关的段落，但无法保留段落之间的**关系结构与路径方向**。对于合规场景中最核心的“穿透识别”类问题（如“公司 A 通过哪条控制链路与已制裁实体 C 相关联？”），答案不是某个孤立的文本片段，而是一条由多跳关系构成的有向路径。稠密向量检索无

法重建这一路径，因为路径的意义依赖每条边的方向与类型，而这些信息在向量化过程中被压缩丢失。

GraphRAG 是 RAG 在知识图谱场景下的扩展^[42]，其核心改进是将图结构检索（Graph Retrieval）与文本检索联合，以**实体-关系路径与邻域子图**作为检索粒度，从而支持多步路径推理。He 等人提出的 G-Retriever 将图检索形式化为奖励收集斯坦纳树优化问题，开创了通用文本图上的 RAG 范式^[43]。Gao 等人将 RAG 技术的发展组织为朴素 RAG、进阶 RAG 和模块化 RAG 三个演进范式^[56]。刘雪颖等人则从中文视角综述了基于大型语言模型的检索增强生成技术进展^[57]。GraphRAG 的典型应用流程为：（1）从图数据库中检索查询实体的 k 跳邻域子图；（2）将子图结构序列化为三元组列表或自然语言描述；（3）结合文本证据片段，拼接为上下文输入 LLM；（4）LLM 生成包含路径解释与证据来源的回答。相较于标准 RAG，GraphRAG 在两方面具有更高可审计性：其一，路径结构显式保留关系类型与方向，可直接对应“OFAC 50% 规则”等规则条款；其二，检索子图本身构成部分证据链，可压缩生成阶段的幻觉空间。

2.6.3 证据溯源与可解释性

在合规场景中，系统输出的可解释性（Explainability）与可溯源性（Traceability）是基本要求而非可选增强：监管方在审查合规决策时，要求能够逐条追溯结论的法律依据，模型的“黑盒”输出在法律层面不具有证明效力。本文将可解释性目标分解为三个层次，每层对应不同粒度的审计需求：

（1）**分值解释**：对每个节点的风险评分，给出各分量（PageRank 结构贡献、社群风险贡献、Hawkes 动态项贡献）的占比，使审计人员能够判断风险主要来源于结构关联还是时序激发；（2）**路径解释**：给出从高风险种子节点到目标节点的高贡献关系路径，标注路径上各关系类型与边权，对应“OFAC 50% 规则”等穿透识别规则的逐步验证；（3）**文本证据**：将路径上的关键三元组与对应的原始文档片段（公告句子、新闻段落）关联输出，提供从结论反向追溯到原始来源的完整证据链，满足可审计要求。

上述三层可解释性输出通过 GraphRAG 流程统一实现，最终生成面向合规审查人员的自然语言报告（详见第 5.3.2 节）。

2.7 本章小结

本章从制裁场景的核心约束出发，逐层推导了后续方法设计的技术路线。首先，围绕经济制裁规则与合规审计需求，明确了本文场景的核心约束：关系穿透、跨语种消歧、证据可追溯与数据高频更新。基于上述约束，本文在知识组织层面选择以

知识图谱及原生图数据库支撑多跳关系查询与版本化管理；在抽取层面采用 LLM 驱动、图上下文约束与自回溯校验相结合的结构化抽取路线；在知识服务层面采用 GraphRAG，实现“结构路径 + 文本证据”的联合检索与可解释输出；在风险建模层面，以图结构传播与时序激发机制为基础，为 HGT-RAM 的静态结构风险与动态强度联合建模提供方法依据。相较于纯名单匹配、纯监督抽取、纯文本检索或纯静态评分等单一路线，上述技术组合更契合制裁合规场景对准确性、可解释性与可审计性的综合要求。基于本章分析，第三章将具体展开 GSR-ER 方法与图谱构建实现，第四章进一步给出 HGT-RAM 风险评估模型及实验验证，第五章完成系统级集成与应用评估。

3 数据集与知识抽取方法（GSR-ER）

本章围绕经济制裁领域的知识抽取核心问题，首先介绍面向俄乌冲突制裁场景的多源数据体系与标注规范，然后给出经济制裁知识图谱的建模方案与版本化更新机制，最后重点提出 GSR-ER（Graph-Guided Self-Refine for Entity - Relation）方法，并通过与多类基线方法的对比实验验证其有效性。

3.1 数据集与标注规范

3.1.1 数据来源与范围界定

本文面向俄乌冲突经济制裁场景，综合选取权威制裁清单与开源情报文本两类数据源：

（1）制裁清单与政策信息。美国财政部海外资产控制办公室（OFAC）发布的特别指定国民与封锁人员清单（SDN List）是全球制裁合规领域最核心的结构化数据源之一，其涵盖被制裁个人、企业、船舶、航空器等实体的姓名、别名、国籍、地址、标识符及制裁项目编号等字段 [6]。欧盟制裁地图（EU Sanctions Map）与欧盟制裁追踪平台提供了欧盟层面的制裁对象信息与政策条款 [7]。上述官方清单具有高权威性与结构化程度，是构建基础图谱的首要数据来源。

（2）聚合型制裁数据。OpenSanctions 是一个面向制裁、政治敏感人物与执法数据的开源聚合项目，其对包括 OFAC、EU、联合国制裁委员会等在内的多来源制裁条目进行统一格式化、去重与实体对齐，输出以 Follow The Money（FTM）Schema 为基础的结构化数据 [8]。该数据源为跨管辖区制裁信息的整合与实体消歧提供了重要参考。

（3）新闻与事件文本。GDELT（Global Database of Events, Language, and Tone）是覆盖全球的新闻事件数据库，可提供制裁相关新闻报道的文本、时间戳与地理位置信息 [9]。此外，本文还从主要新闻媒体的公开报道与官方通报中采集非结构化制裁信息文本，作为补充数据来源。

上述数据覆盖结构化字段（如姓名、别名、国籍、地址、标识符、制裁项目编号等）与非结构化文本（新闻正文、公告说明、解读文章）。本文以 2022 年 2 月至 2025 年 6 月期间与俄乌冲突相关的制裁对象及制裁事件为主要范围。在结构化数据方面，以 OFAC SDN 清单、欧盟制裁清单与英国 OFSI 清单为核心来源，三者俄乌相关条目累加约 9,700 余条；进一步通过 OpenSanctions 聚合加拿大、澳大利亚、日本等管

辖区数据并进行跨来源实体对齐与去重后，获得唯一制裁实体逾 5,000 个^[58]。在非结构化数据方面，从 GDELT 新闻事件库与主流新闻媒体中采集制裁相关文本约 5,200 篇，并在数据清洗阶段通过关键词与实体匹配过滤无关文本。数据来源汇总如表 3-1 所示。

表 3-1 多源制裁数据来源汇总
Table 3-1 Summary of multi-source sanctions data

数据来源	数据类型	格式	全量规模	俄乌相关	数据依据
OFAC SDN List	结构化清单	XML/CSV	>17,000	~5,200	OFAC 官方（全量）；CNAS 年度报告推算（子集）
EU Consolidated Sanctions List	结构化清单	XML/CSV	>8,000	>2,400	欧盟理事会第 16 轮制裁包公告（2025.02）
UK OFSI Consolidated List	结构化清单	ODS/CSV	4,733	2,113	OFSI Annual Review 2024–25（2025.04）
OpenSanctions（跨管辖区聚合去重）	聚合型数据	JSON (FTM)	>270,000	>5,000	Atlantic Council Russia Sanctions Database（2024.11）
GDELT	非结构化文本	CSV/Big-Query	>1.2 亿事件	~3,800 篇	关键词过滤（sanction + Russia/Ukraine）
新闻媒体与官方通报	非结构化文本	HTML/PDF	—	~1,400 篇	定向采集（Reuters/BBC/TASS 等）

注：全量规模指各数据源截至 2025 年 6 月覆盖全部制裁项目与国家的完整条目数。OFAC SDN 全量包含伊朗、朝鲜、叙利亚、反恐、禁毒等 30 余个制裁项目，本文仅选取 RUSSIA-EO14024、UKRAINE-EO13662、CAATSA-RUSSIA 等俄乌相关项目下的条目。EU 制裁清单全量覆盖叙利亚、伊朗、白俄罗斯等多个制裁政权，本文仅选取针对俄罗斯第 1–16 轮制裁包所列条目。UK OFSI 全量 4,733 条涵盖 35 个制裁政权，俄乌相关 2,113 条占 44.6%。三大管辖区俄乌相关条目累加（去重前）约 9,700 条；OpenSanctions 对 OFAC、EU、UK OFSI 及加拿大、澳大利亚、日本等管辖区数据进行实体对齐与去重后，唯一制裁实体逾 5,000 个。据 Castellum.AI 统计，全球主要制裁方对俄指定累计逾 23,000 条（含跨管辖区重复列入）。

3.1.2 数据预处理与质量控制

为支撑后续抽取与融合，本文对多源数据进行统一预处理，主要包括以下步骤：

（1）结构化数据清洗。对 OFAC SDN List、EU 制裁清单与 OpenSanctions 导出数

据进行字段标准化处理,包括编码统一 (UTF-8)、日期格式规范化 (统一为 ISO 8601 格式)、缺失值标记 (以 NULL 占位并记录缺失原因) 以及异常值过滤 (如明显错误的出生日期、无效的地理坐标等)。对于同一实体在不同来源中的字段差异,保留各来源版本并在后续融合阶段进行消解。

(2) 非结构化文本处理。对新闻报道与公告文本执行去重与版式清洗: 去除 HTML 标签、广告嵌入与导航栏文本; 进行分句分段处理,以自然段落或句号分隔为单位切分文本; 通过 langdetect 工具进行语言识别,标注文本语种 (主要涉及英语、俄语与中文), 为后续跨语种归一提供基础。

(3) 候选实体召回。基于结构化清单中的实体名称、别名与标识符构建实体词典,使用精确匹配与模糊匹配 (编辑距离阈值设为 2) 对非结构化文本执行候选实体召回,为后续 Graph Context 构建提供锚点实体。召回阶段追求高召回率而非高精度率,误匹配将在后续抽取与校验环节中过滤。

(4) 抽样审查。对不同来源、不同语言与不同时间段的数据分别进行分层抽样核验 (每层至少抽取 50 条),记录常见噪声模式,主要包括同名误匹配 (如不同国籍的同名个人)、机构简称歧义 (如 "CBR" 既可指俄罗斯中央银行也可指其他机构) 以及地址格式不一致 (如拉丁转写与原文并存) 等。上述噪声模式为后续标注规范与消歧策略的设计提供了依据。

3.1.3 标注指南与评价数据划分

由于制裁领域标注成本较高且需要领域专业知识,本文采用 "少量人工标注 + 规则弱监督 + LLM 辅助标注 + 人工审核" 的四阶段策略构建评价数据集。

(1) 实体类型定义。本文定义 10 类核心实体类型: Person (自然人)、Organization (国际组织/政府机构)、Company (企业/法人实体)、LegalEntity (法律实体,如基金、信托)、Vessel (船舶)、Airplane (航空器)、Sanction (制裁措施实例)、Security (证券)、CryptoWallet (加密钱包地址) 以及 Address (地址)。实体类型及其中文含义如表 3-2 所示。

(2) 关系类型定义。本文定义 7 类核心关系类型,覆盖制裁场景中的典型语义关联: PLAYS_SIGNIFICANT_ROLE_IN (在某事件/组织/活动中发挥重要作用)、SANCTIONED_BY (被制裁关系)、FAMILY_RELATIONSHIP (家族/亲属关系)、ACTS_FOR (代理/代表关系)、LEADER_OF (领导/高管任职)、OWNS (所有权/股权控制) 以及 LOCATED_AT (注册/驻地关系)。关系类型及其中文含义如表 3-3 所示。

(3) 标注流程。标注工作分四阶段进行: 第一阶段,由 2 名具有国际关系或金融合规背景的标注员对 200 篇文档进行独立标注,计算标注一致性 (Cohen's Kappa 系

数)；第二阶段，基于清单字段匹配与正则表达式构建规则弱监督标注，扩大标注覆盖面；第三阶段，利用 GPT-4o 对剩余文档执行辅助标注，生成候选实体与关系；第四阶段，由标注员对 LLM 辅助标注结果进行复核与修正。最终标注一致性达到 Cohen’s Kappa = 0.82，满足可靠标注的阈值要求。

表 3-2 实体类型及中文含义
Table 3-2 Entity types and Chinese meanings

实体名称	中文含义
Person	自然人/个人
Organization	组织机构（如政府机构、国际组织）
Vessel	船舶
LegalEntity	法律实体（如基金、信托等）
Company	公司/企业法人
Airplane	航空器
Sanction	制裁措施/制裁事件实体
Security	证券（如股票、债券等金融证券）
CryptoWallet	加密钱包地址
Address	地址

表 3-3 关系类型及中文含义
Table 3-3 Relation Types and Chinese Meanings

关系名称	关系含义
PLAYS_SIGNIFICANT_ROLE_IN	在某事件/组织/活动中发挥重要作用
SANCTIONED_BY	被某制裁主体（机构/国家）实施制裁
FAMILY_RELATIONSHIP	存在家庭或亲属关系
ACTS_FOR	代表某主体行事/代理某主体
LEADER_OF	担任某组织或公司的领导/高管
OWNS	对目标主体具有所有权或控制权
LOCATED_AT	位于某地址/注册于某地址

（4）数据划分。最终构建的评价数据集包含 1,200 篇标注文档，共计 18,645 个实体提及与 8,932 条关系标注。按文档级别以 6:2:2 的比例划分为训练集（720 篇）、验证集（240 篇）与测试集（240 篇），划分时确保同一制裁事件的相关文档不跨集分布，以避免数据泄露。数据集统计信息如表 3-2 所示。

3.2 知识图谱建模与版本化更新

3.2.1 事件要素与 Schema 设计

结合制裁业务需求与合规审查实践，本文将”制裁事件”建模为包含以下核心要素的结构化记录：（1）制裁主体（Actor）：发布制裁措施的国家或机构，如美国 OFAC、欧盟理事会、英国 OFSI 等；（2）被制裁对象（Target）：个人、组织、企业、法律实体、船舶、航空器等被实施制裁的对象；（3）措施（Measure）：具体的制裁措施类型，包括资产冻结、金融限制、出口管制、技术限制、旅行禁令等；（4）依据（Basis）：制裁所依据的法规条款、行政令编号、决议编号等法律依据；（5）时间（Time）：生效时间、变更时间、解除时间等时间属性；（6）影响范围（Scope）：适用国家或地区、涉及行业或交易类型等。

在实体关系层面，本文设计如下核心关系类型体系（以 Cypher 风格表示），如表 3-4 所示。

表 3-4 制裁关系 Schema 示例（Cypher 风格）
Table 3-4 Sanction Relation Schema Examples (Cypher Style)

关系名	关系模式
LEADER_OF	(a:Person)-[:LEADER_OF]->(b:Organization Company LegalEntity)
OWNS	(a)-[:OWNS]->(b:Person Organization Company LegalEntity)
SANCTIONED_BY	(a:Person Organization Company Airplane Vessel LegalEntity)-[:SANCTIONED_BY]->(s:Sanction)
ACTS_FOR	(a:Person)-[:ACTS_FOR]->(b:Organization Person Company LegalEntity)
FAMILY_RELATIONSHIP	(a:Person)-[:FAMILY_RELATIONSHIP]->(b:Person)
LOCATED_AT	(a)-[:LOCATED_AT]->(b:Address)
PLAYS_SIGNIFICANT_ROLE_IN	(a:Person Organization)-[:PLAYS_SIGNIFICANT_ROLE_IN]->(b:Organization Company Sanction)

上述 Schema 兼顾了制裁网络中控制关系（OWNS）、管理关系（LEADER_OF）、代理关系（ACTS_FOR）以及社会关系（FAMILY_RELATIONSHIP）等多种语义类型，并通过边属性携带制裁措施、股权比例、生效时间等关键信息。Schema 整体设计如图 3-1 所示。

3.2.2 证据建模与可追溯字段

为满足合规场景”可审计、可追溯”的核心要求，本文为每条抽取得到的事实关联五类证据字段：

(1) 证据来源 (source): 记录来源平台标识与文档标识, 如公告编号、URL 哈希、数据集版本号等, 确保可定位到原始文档。

(2) 证据片段 (evidence_span): 记录原文中的证据句或段落位置 (以字符偏移量表示), 使得任一抽取结论均可追溯到原始文本的具体位置。

(3) 时间戳 (timestamp): 记录两类时间信息——数据抓取时间 (crawl_time) 与事件发生时间 (event time), 前者用于版本管理, 后者用于时序分析。

(4) 置信度 (confidence): 记录抽取置信度 (由模型输出或规则评分得到) 与回溯校验后的修正得分, 反映事实的可靠程度。

(5) 版本信息 (version): 采用三元组 (first_version, change_version, expire_version) 记录事实的生命周期, 分别表示首次出现版本、最近变更版本与失效版本, 支持历史回放与审计。

上述证据字段以 JSON 格式附加在图谱中每条边与关键节点属性上，确保从“抽取结论”到“原始证据”的完整链路可追溯。

3.2.2.3 图谱存储、融合策略与版本化更新




图 3-1 经济制裁知识图谱在 Neo4j 中的局部存储视图

Figure 3-1 Partial view of the economic sanctions knowledge graph stored in Neo4j

(1) 图谱存储。本文采用 Neo4j 图数据库作为核心存储引擎 [13]。Neo4j 的属性图模型天然适合存储带有丰富属性的实体节点与关系边, 其 Cypher 查询语言支持灵活的多跳路径检索与模式匹配, 满足制裁网络中关系穿透与链路溯源的需求。

(2) 融合策略。多源数据融合遵循“同一实体合并、冲突信息保留证据、多版本演化可回溯”的原则。具体而言：在实体层面，对候选对齐结果采用“字符串相似度 + 属性一致性 + 结构邻域一致性”的综合判定策略进行消歧与合并；在关系与事件层面，通过证据权重（高权威来源优先）与时间戳（最新版本优先）进行冲突消解，冲突的历史版本作为备选证据保留而非删除。

(3) 版本化更新。针对制裁信息高频更新的特点，本文设计基于时间戳的版本化更新机制：每次增量更新生成全局递增的版本号，并对新增、变更与失效三类变更分别记录变更集。对任一节点或边，可通过版本号查询其历史状态与对应证据来源，从而支持“结论回放”与审计需求。

图 3-1 展示了本文构建的经济制裁知识图谱在 Neo4j 图数据库中的局部存储视图。图中节点对应不同类型的制裁实体（如 Person、Company、Organization、Sanction 等），节点之间的有向边对应本文定义的关系类型（如 SANCTIONED_BY、OWNS、LEADER_OF、ACTS_FOR 等）。可以观察到，制裁网络呈现出围绕核心被制裁实体向外辐射的拓扑结构，多种关系类型交织形成复杂的关联网络。该图谱实例验证了本节所设计的 Schema 在实际数据上的可落地性与表达能力，同时为后续 GSR-ER 方法中 Graph Context 的构建提供了直观参照——即从该图谱中抽取目标实体的 k -hop 邻域子图，作为引导大语言模型执行实体关系抽取的结构化上下文。

3.3 GSR-ER 方法：图引导的实体关系自优化抽取

3.3.1 任务定义与问题建模

给定非结构化文本集合 $D = \{d_1, d_2, \dots, d_N\}$ 与已有的外部制裁知识图谱（或其子图） $G = (V, E)$ ，实体关系抽取任务的目标是从每篇文本 d_i 中抽取实体集合 $E_i = \{e_1, e_2, \dots\}$ 与关系集合

$$R_i = \{(e_s, r, e_o) \mid e_s, e_o \in E_i, r \in \mathcal{R}\},$$

其中 $\mathcal{R}$ 为预定义关系类型集合，并要求每条抽取结果绑定原文证据片段。关于制裁信息抽取的一般性难点（别名歧义、关系冲突与 LLM 幻觉）已在第 2.3 节系统讨论，本节不再赘述上述一般性难点，而聚焦于其在本文数据与 Schema 约束下的具体化建模：

(1) 跨语种别名与缩写导致的实体链接误差（对应第 2.3 节的消歧问题），通过 Graph Context 中的规范名-别名集合与邻域关系约束进行收敛；

(2) 多源关系陈述不一致与局部证据不完备（对应第 2.3 节的冲突与融合问题），通过 Schema 域/值域校验与证据绑定规则进行筛选；

(3) 生成式抽取的幻觉与格式不一致 (对应第 2.3 节的 LLM 风险), 通过 Self-Refine 反馈迭代与结构一致性检验进行修正。

基于上述映射, GSR-ER 的核心思想是: 以已有图谱提供的结构化知识作为外部约束 (Graph-Guided), 引导大语言模型在抽取过程中降低歧义与幻觉, 并通过自回溯校验 (Self-Refine) 机制迭代修正抽取结果, 从而提升实体消歧准确率与关系一致性。

3.3.2 方法总体框架与流程

GSR-ER 的总体框架如图 3-2 所示, 其核心流程包含五个阶段:




图 3-2 GSR-ER 总体架构图

Figure 3-2 GSR ER Overall Architecture

阶段一: 候选实体召回与 Graph Context 构建。对输入文本进行候选实体召回, 基于召回结果从已有图谱中抽取相关子图, 编码为结构化上下文 (Graph Context)。该上下文为后续抽取提供“已知事实”参考, 帮助模型在歧义候选中做出正确选择。

阶段二: LLM 初始抽取。将文本片段与 Graph Context 共同编码为提示 (Prompt), 输入大语言模型执行实体识别与关系抽取, 输出包含实体、关系与证据片段的结构化 JSON 结果。

阶段三: Graph-Guided 约束校验。将初始抽取结果映射到预定义 Schema 的约束空间, 进行实体类型合法性、关系方向与域值域约束、证据绑定完整性以及结构一致

性等多维度检查。

阶段四：**Self-Refine** 自回溯校验。对约束校验中发现的冲突、缺失或低置信度结果，构造包含冲突点描述、候选证据句与 Graph Context 的反馈提示，要求模型进行二次生成并给出修正理由，迭代至收敛或达到最大轮数。

阶段五：入库与版本化。将通过校验的最终抽取结果写入图数据库，关联证据字段与版本信息。

GSR-ER 的 Prompt 构建详细过程如图 3-3 所示。

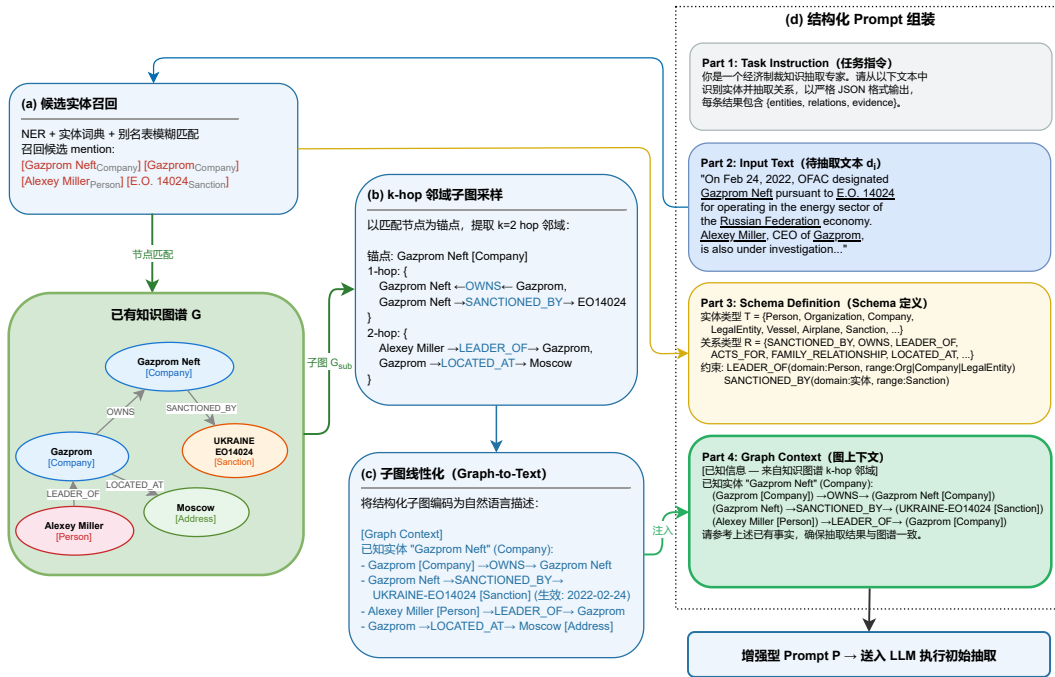


图 3-3 GSR-ER 图上下文构建与结构化提示组装流程

Figure 3-3 Graph context construction and structured prompt assembly in GSR-ER

3.3.3 Graph context 构建

Graph Context 的构建是 GSR-ER 区别于传统 LLM 抽取方法的关键机制。其目的是将已有图谱中与当前文本相关的结构化知识以文本化形式注入 LLM 的提示上下文，使模型在面对歧义实体与候选关系时能够参考“已知事实”做出更准确的判断。

设文本片段 d_i 中通过候选实体召回得到的锚点实体集合为 $S_i = \{e_1, e_2, \dots, e_m\}$ 。对每个锚点实体 $e_j \in S_i$ ，从图谱 G 中抽取其 k 跳邻域子图：

$$G_e^{(k)} = \{(u, r, v) \in E \mid \text{dist}(e_j, u) \leq k \text{ 或 } \text{dist}(e_j, v) \leq k\}$$

其中 $\text{dist}(\cdot, \cdot)$ 表示图中的最短路径距离。实践中取 $k = 2$ ，以平衡上下文信息量与提示长度。

将所有锚点实体的邻域子图合并后, 编码为如下文本化格式, 示例如代码清单 3.1 所示:

Listing 3.1 Graph Context 文本化示例

```

1 [Graph Context]
2 Entity: "Sberbank" (Company)
3   Aliases: ["Sberbank of Russia", "PJSC Sberbank"]
4   Relations:
5     - SANCTIONED_BY -> "OFAC SDN" (since 2022-02-24)
6     - SANCTIONED_BY -> "EU Sanctions" (since 2022-02-25)
7     - OWNS <- "Russian Federation" (share: 50.0%+1)
8     - LEADER_OF <- "German Gref" (CEO, since 2007)
9   Recent Events:
10    - 2022-02-24: Added to OFAC SDN List (EO 14024)
11    - 2022-06-02: EU 6th sanctions package expansion
12 ...

```

Graph Context 包含三层信息: (1) 实体的规范名与全部别名集合, 用于消歧; (2) 已知关系邻接及其属性, 用于约束关系抽取; (3) 历史制裁事件与时间信息, 用于时序一致性校验。通过将结构化图知识以自然语言化的形式注入提示, 模型能够在不修改模型参数的条件下利用外部知识进行推理。

3.3.4 Graph-Guided 约束机制

为进一步抑制 LLM 的幻觉输出与关系冲突, 本文设计四层约束机制:

(1) Schema 类型约束。抽取的实体类型必须属于预定义的 10 类实体类型集合 $\mathcal{T} = \{\text{Person}, \text{Organization}, \text{Company}, \dots\}$, 关系类型必须属于预定义的 7 类关系类型集合 $\mathcal{R}$ 。不满足类型约束的抽取结果将被标记为无效并触发重新生成。

(2) 方向与域/值域约束。每种关系类型预定义了合法的主体类型 (domain) 与客体类型 (range)。例如, LEADER_OF 的主体必须为 Person 类型, 客体必须为 Organization、Company 或 LegalEntity 类型; FAMILY_RELATIONSHIP 的主体与客体均必须为 Person 类型。约束校验以规则方式自动执行。

(3) 证据绑定约束。每条抽取的关系三元组必须绑定至少一条原文证据句 (evidence span), 且证据句中必须包含与主体和客体相关的文本提及。缺少证据绑定的关系将被标记为“无证据支撑”并降权处理。

(4) 结构一致性约束。若抽取的关系与已有图谱中的已知事实存在强冲突 (例如同一 Person 在同一时间段被标注为两家不同公司的 CEO), 则触发冲突标记并进入 Self-Refine 流程。冲突判定通过将抽取结果与 Graph Context 中的已有三元组进行比对实现。

约束校验的判定逻辑可形式化为：对每条候选三元组 (e_s, r, e_o) ，定义合法性函数：

$$\text{Valid}(e_s, r, e_o) = \mathbb{1}[\text{type}(e_s) \in \text{Dom}(r)] \cdot \mathbb{1}[\text{type}(e_o) \in \text{Ran}(r)] \cdot \mathbb{1}[\text{evidence}(e_s, r, e_o) \neq \emptyset] \quad (3.1)$$

仅当 $\text{Valid}(e_s, r, e_o) = 1$ 且不存在结构强冲突时，该三元组被直接接受；否则进入 Self-Refine 流程。

3.3.5 基于大语言模型的初始抽取与自回溯校验

(1) 初始抽取。在初始抽取阶段，本文设计结构化提示模板，要求模型以严格的 JSON 格式输出抽取结果。提示模板由四部分组成：(1) 任务指令 (Task Instruction)，明确要求模型执行实体识别与关系抽取，并指定输出格式；(2) Schema 定义 (Schema Definition)，列出合法的实体类型与关系类型及其域值域约束；(3) Graph Context，注入当前文本相关的图谱上下文；(4) 输入文本 (Input Text)，即待抽取的文本片段。

模型输出的 JSON 结构如下所示：

```

1  {
2    "entities": [
3      {"id": "e1", "name": "Sberbank（俄罗斯联邦储蓄银行）", "type": "
         Company", "aliases": ["PJSC Sberbank"], "span": [12, 20]},
4      {"id": "e2", "name": "German Gref（格列夫）", "type": "Person",
         "span": [45, 56]}
5    ],
6    "relations": [
7      {"subject": "e2", "predicate": "LEADER_OF", "object": "e1",
8        "evidence": "German Gref, CEO of Sberbank, stated that...",
9        "confidence": 0.92}
10   ]
11 }
12 }
```

(2) Self-Refine 自回溯校验。Self-Refine 机制的核心思想是：将约束校验阶段发现的问题以结构化反馈的形式回传给模型，要求模型基于反馈与证据进行自我修正。其迭代过程如图 3-4 所示，具体而言，Self-Refine 每轮迭代包含三个步骤：

步骤一：问题诊断。系统将约束校验结果分为三类反馈信号——冲突 (Conflict，与已有图谱事实矛盾)、缺失 (Missing，证据句中存在但未被抽取的实体或关系) 以

及低置信度（Low-Confidence，模型自评置信度低于阈值 $\tau = 0.7$ ）。

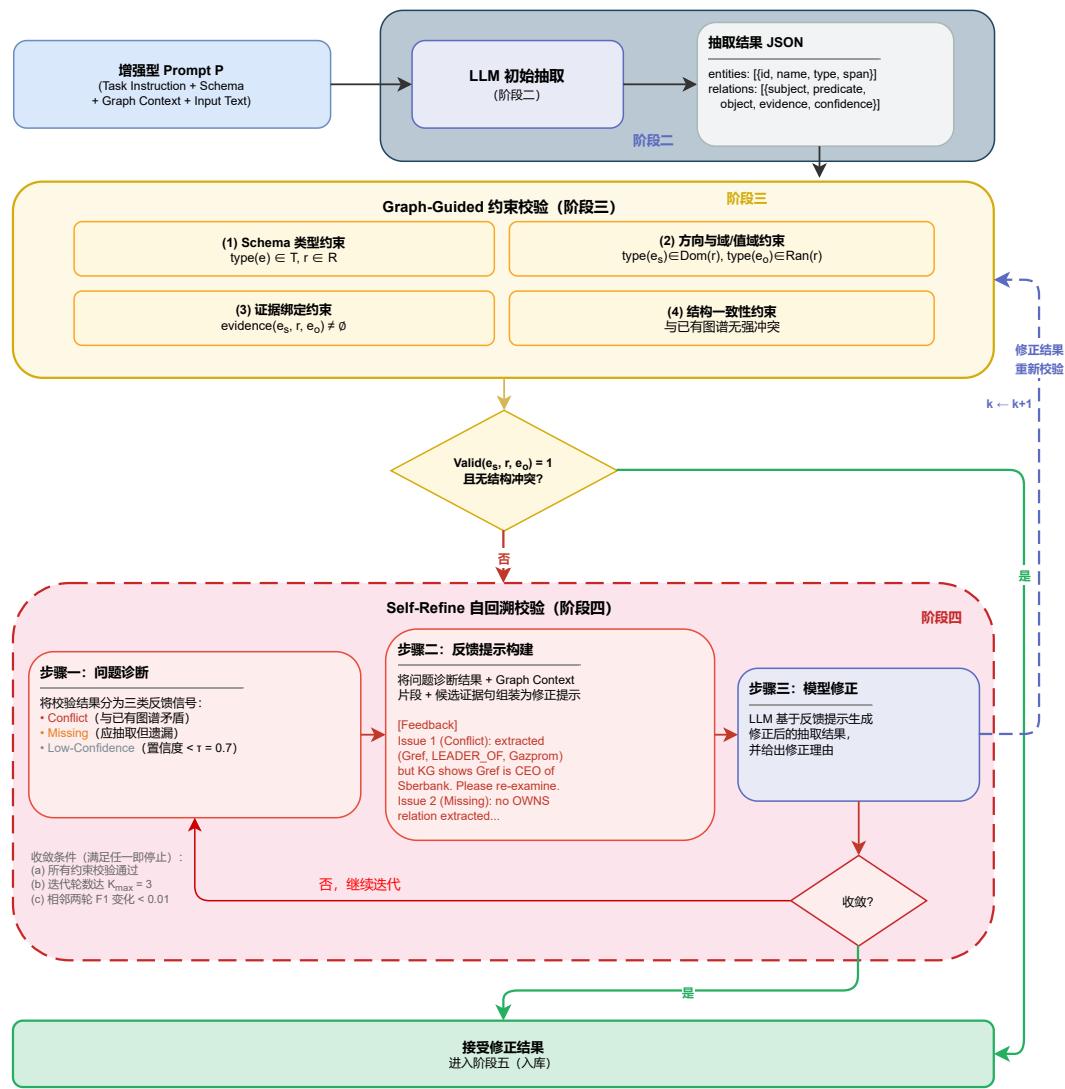


图 3-4 基于图约束反馈的 Self-Refine 自优化流程

Figure 3-4 Graph-Constrained Feedback-Driven Self-Refine Workflow

步骤二：反馈提示构建。将问题诊断结果与相关的 Graph Context 片段、候选证据句组装为修正提示，明确指出需要修正的具体问题。例如：

```
1 [Feedback]
2 Issue 1 (Conflict): You extracted (German Gref, LEADER_OF, Gazprom),
3 but Graph Context shows German Gref is CEO of Sberbank since 2007.
4 Please re-examine the evidence and correct if necessary.
5
6 Issue 2 (Missing): The text mentions "subsidiary of Sberbank"
7 but no OWNS relation was extracted. Please check.
8
9 Please re-extract and provide corrected results with explanations.
```

步骤三：模型修正与收敛判定。模型基于反馈提示生成修正后的抽取结果，并给出修正理由。系统对修正结果重新执行约束校验，若以下任一条件满足则停止迭代：(a) 所有约束校验通过；(b) 迭代轮数达到上限 $K_{\max} = 3$ ；(c) 相邻两轮的抽取结果无实质变化 (F1 变化量 < 0.01)。

Self-Refine 机制的直觉是：通过将外部知识 (Graph Context) 与结构约束 (Schema) 作为“校验信号”反馈给模型，模拟人类标注员“初标——复核——修正”的工作流程，使模型能够在不进行参数更新的条件下逐步提升抽取质量。

3.3.6 输出质量控制与可追溯性

抽取结果经 Graph-Guided 约束校验与 Self-Refine 迭代后，进入最终质量控制与入库流程：

(1) 规则校验：对最终输出执行格式合法性检查 (JSON Schema 校验)、实体类型与关系类型合法性校验、以及证据片段非空校验。

(2) 结构校验：将抽取的新三元组与已有图谱进行全局一致性检查，标记潜在的冗余边 (已存在且未变更的关系) 与矛盾边 (与已有关系直接冲突)。

(3) 关键实体复核：对高风险或高连接度节点 (如 degree 排名前 5% 的实体)，采用更严格的人工抽样复核策略，复核比例不低于 30%。

(4) 全链路追溯记录：对每条入库的三元组，记录从“原文片段 → 初始抽取结果 → 约束校验日志 → Self-Refine 修正历史 → 最终入库版本”的完整审计链路，支持后续争议处理与质量回溯。

3.4 实验设计与结果分析

3.4.1 实验设置

为保证跨章节实验结果的可复现性，本文统一实验环境如表 3-5 所示。

(1) 评估指标。本文采用实体识别与关系抽取的标准评估指标：精确率 (Precision, P)、召回率 (Recall, R) 与 F1 值。对于实体识别，采用严格匹配 (Strict Match, 要求实体边界与类型均正确) 与宽松匹配 (Relaxed Match, 仅要求类型正确且边界重叠超过 50%) 两种评估标准。对于关系抽取，要求主体、客体与关系类型三者均正确。

(2) 基线方法选择。为全面评估 GSR-ER 的有效性，本文选取覆盖不同技术范式的 6 类基线方法，具体如下：

1) XLM-R + PRGC——传统监督联合抽取基线。XLM-R 是一种在 100 种语言上训练的大规模多语言预训练模型^[59]，PRGC (Potential Relation and Global Correspondence)

表 3-5 统一实验环境配置
Table 3-5 Unified experimental environment configuration

类别	配置项	参数说明
硬件	CPU / 内存 / 存储	Intel Core i9-13900K（24 核） / 64 GB DDR5 / 1 TB NVMe SSD
硬件	GPU（抽取实验）	NVIDIA A100（80GB）
系统	操作系统	Ubuntu 22.04 LTS
图数据库	Neo4j	Community Edition 5.15（JVM 堆内存 16 GB，页面缓存 8 GB）
运行时	Python	Python 3.10.12
关键组件	图算法与时序建模	Neo4j GDS、tick（Hawkes 参数估计）
模型服务	LLM 接口	OpenAI API（GPT-4o）

是近年来关系抽取领域的代表性联合抽取方法^[60]。该基线代表了基于预训练语言模型的监督学习范式在多语言关系抽取任务中的典型表现，其优势在于在充分标注数据下能够取得较高的精确率，但在低资源场景下性能显著下降，且无法利用外部图谱知识。

2) TPLinker——基于 Span 的联合抽取基线^[61]。TPLinker 通过 Token-Pair Linking 矩阵对实体与关系进行联合解码，能够处理重叠关系（Overlapping Relations）问题。该基线代表了 Span-based 方法在关系抽取中的应用，其优势在于能够直接处理实体重叠场景，但在长文本与复杂嵌套关系中效率较低。

3) GliREL——零样本关系抽取基线^[62]。GliREL 将关系抽取建模为基于自然语言关系描述的零样本关系分类，并通过单次前向传播联合预测多实体对关系。该基线代表零样本学习范式，其优势在于无需为新关系类型追加标注数据，但在领域专有语义和复杂隐含关系场景下准确率通常低于监督方法。

4) ReLiK——知识增强检索式基线^[63]。ReLiK 采用 Retriever-Reader 架构，先检索候选实体/关系，再在单次前向传播中完成对齐与关系抽取。该基线与 GSR-ER 最为接近，均利用外部知识增强抽取，但其知识注入方式为检索式而非图结构引导式，且不包含自回溯校验机制。

5) Qwen2.5-7B——开源 LLM 基线^[51,64]。Qwen 系列模型在多语言理解与指令遵循任务上表现稳定。本文以 Qwen2.5-7B 作为开源 LLM 代表，在相同提示模板（不含 Graph Context）下执行零样本与少样本抽取测试，用于量化 Graph Context 与 Self-Refine 机制的边际贡献。

6) GPT-4o——闭源商业 LLM 基线^[65]。GPT-4o 是 OpenAI 发布的旗舰多模态模型，在各类 NLP 任务中表现突出。同样以相同提示模板进行零样本抽取测试，代表当前商业 LLM 的最高抽取能力，用于验证 GSR-ER 的图引导与自优化机制能否在更强的基础模型上仍带来增益。

（3）实现细节。软硬件与运行环境配置见表 3-5。XLM-R + PRGC 与 TPLinker 使用

训练集进行微调（学习率 2×10^{-5} ，batch size 16，训练 30 个 epoch）。GliREL 与 ReLiK 使用其官方预训练权重进行零样本推理。Qwen2.5-7B 与 GPT-4o 均使用 temperature = 0 进行确定性生成。GSR-ER 以 GPT-4o 作为骨干 LLM，Graph Context 的邻域跳数 $k = 2$ ，Self-Refine 最大迭代轮数 $K_{\max} = 3$ ，置信度阈值 $\tau = 0.7$ 。

3.4.2 对比实验结果

表 3-6 展示了各方法在测试集上的实体识别与关系抽取性能。

表 3-6 主要对比实验结果（测试集）
Table 3-6 Main comparison results on the test set

方法	实体 P	实体 R	实体 F1	关系 P	关系 R	关系 F1
XLM-R + PRGC	82.7	76.8	79.6	79.1	70.2	74.3
TPLinker	79.3	74.1	76.6	75.8	68.7	72.1
GliREL	68.9	63.4	66.0	61.7	55.5	58.4
ReLiK	77.2	73.6	75.4	74.9	70.8	72.8
Qwen2.5-7B	74.1	70.8	72.4	72.0	69.2	70.6
GPT-4o	78.5	74.4	76.4	75.6	71.5	73.5
GSR-ER	83.4	79.2	81.2	82.4	75.1	78.6

为了观察不同关系类型上的细粒度差异，图 3-5 给出了 GSR-ER 与最强基线在各关系类型上的 F1 对图，从实验结果可以观察到以下几点：




图 3-5 不同关系类型上的 F1 对比（GSR-ER 与基线）

Figure 3-5 F1 comparison by relation type between GSR-ER and baseline

（1）GSR-ER 在关系抽取 F1 值上取得最优表现。GSR-ER 的关系抽取 F1 值达到 78.6%，分别优于最强监督基线 XLM-R + PRGC（74.3%）、最强知识增强基线 ReLiK（72.8%）以及最强 LLM 基线 GPT-4o（73.5%）。这一结果表明，图引导与自回溯校验机制能够在实体关系抽取任务上带来显著的性能提升。

(2) Graph Context 有效提升实体消歧能力。在实体识别的严格匹配评估下, GSR-ER(81.2%)显著优于使用相同骨干 LLM 但不含 Graph Context 的 Qwen2.5-7B(72.4%), F1 值绝对提升 8.8 个百分点。这一差距主要来源于别名/译名实体的消歧: Graph Context 提供的别名集合与已知关系邻接帮助模型在歧义候选中做出更准确的链接。

(3) Self-Refine 机制显著降低关系冲突与幻觉。对比 GSR-ER 与”仅 Graph Context 无 Self-Refine”的消融版本(表 3-7 中展示), Self-Refine 带来关系抽取精确率 4.2 个百分点的提升, 表明迭代校验机制能够有效纠正初始抽取中的关系冲突与幻觉输出。

(4) 监督方法在高资源场景下精确率较高但召回率受限。XLM-R + PRGC 的关系抽取精确率(79.1%)在所有方法中排名第二, 但其召回率(70.2%)较低, 原因在于监督方法受限于训练数据中出现的模式, 对于训练集未覆盖的低频关系类型(如 PLAYS_SIGNIFICANT_ROLE_IN)抽取能力较弱。

(5) 零样本方法在制裁领域表现不佳。GliREL 作为零样本基线, 其关系抽取 F1 值仅为 58.4%, 显著低于监督方法与 LLM 方法。分析原因在于制裁领域的关系类型语义与通用领域差异较大, 零样本方法的关系描述难以覆盖制裁场景特有的语义模式。

3.4.3 消融实验

为量化 GSR-ER 各组件的贡献, 本文设计如下消融实验, 结果如表 3-7 所示。

表 3-7 GSR-ER 消融实验结果
Table 3-7 Ablation study results of GSR-ER

变体	关系 P	关系 R	关系 F1
A: GSR-ER (完整)	82.4	75.1	78.6
B: 去除 Graph Context	77.6	69.2	73.1
C: 去除 Self-Refine	78.2	74.6	76.3
D: 去除 Graph-Guided 约束	76.8	71.7	74.2
E: 去除 Graph Context + Self-Refine	73.1	70.6	71.8

消融实验的主要发现如下:

(1) Graph Context 的贡献。去除 Graph Context 后(变体 B), 关系抽取 F1 值从 78.6% 下降至 73.1%, 下降 5.5 个百分点。进一步分析发现, 性能下降集中在涉及别名实体的关系上——在包含跨语种别名的测试样本子集中, Graph Context 带来的 F1 提升达到 11.3 个百分点, 证明了图结构上下文在实体消歧中的关键作用。

(2) Self-Refine 的贡献。去除 Self-Refine 后(变体 C), 关系抽取精确率从 82.4% 下降至 78.2%, 而召回率仅小幅变化(75.1% → 74.6%), 表明 Self-Refine 主要通过纠正错误抽取来提升精确率, 而非发现新的关系。

(3) Graph-Guided 约束的贡献。去除约束校验后(变体 D), 关系抽取精确率从

82.4% 下降至 76.8%，其中类型违规（如将 Company 错误标注为 Person）占错误增量的 38%，方向违规（如将 LEADER_OF 的主客体颠倒）占 27%。

各组件具有协同效应。同时去除 Graph Context 与 Self-Refine（变体 E，等价于纯 LLM + Schema 约束）后，F1 值降至 71.8%，与基线 Qwen2.5-7B（70.6%）接近，表明 Graph Context 与 Self-Refine 的结合产生了超越各自独立贡献之和的协同效应。

3.4.4 Self-Refine 迭代轮次分析

图 3-6 展示了 Self-Refine 不同迭代轮次下关系抽取 F1 值与精确率的变化趋势，对应数值见表 3-8。




图 3-6 Self-Refine 迭代轮次与关系抽取性能变化

Figure 3-6 Relation extraction performance across Self-Refine iterations

表 3-8 Self-Refine 不同迭代轮次的性能数值
Table 3-8 Metrics at different Self-Refine iterations

迭代轮次	关系 P	关系 R	关系 F1
0（初始）	78.2	74.6	76.3
1	80.8	74.9	77.7
2	82.1	75.0	78.4
3	82.4	75.1	78.6

从实验结果可以观察到：第 1 轮 Self-Refine 带来的性能提升最为显著（F1 从 76.3% 提升至 77.7%），主要修正了明显的类型违规与证据缺失问题；第 2 轮进一步

修正了关系冲突与细粒度歧义（F1 提升至 78.4%）；第 3 轮的边际提升较小（F1 从 78.4% 至 78.6%），表明 2-3 轮迭代已足以收敛。考虑到每轮迭代的 LLM 调用成本，本文推荐 $K_{\max} = 3$ 作为默认设置。

3.4.5 错误分析

为深入理解 GSR-ER 的局限性，本文对测试集中的错误案例进行人工分类分析，结果如表 3-9 所示。

表 3-9 错误类型分布统计
Table 3-9 Error type distribution

错误类型	占比（%）	说明
跨文档关系缺失	34	关系主体与客体分散在多文档，单文档抽取难覆盖
长尾实体消歧失败	23	低频实体图上下文稀疏，别名判定不稳定
隐含关系推理失败	19	需依赖语义推断的隐式关系未被识别
时序变更遗漏	15	关系生效/失效时间识别不完整
其他	9	包括噪声文本、证据跨度截断等

主要错误类型包括：（1）跨文档关系缺失（占 34%），即关系的主体与客体分布在不同文档中，单文档抽取范式无法覆盖；（2）长尾实体消歧失败（占 23%），即 Graph Context 中缺乏足够信息的低频实体仍然存在歧义；（3）隐含关系推理（占 19%），即文本未显式表达但需通过推理得到的关系（如“A 是 B 的全资子公司”隐含 OWNS 关系）；（4）时序变更遗漏（占 15%），即未能正确识别关系的时间有效性（如已解除的制裁仍被标注为有效）。上述分析为后续改进方向提供了指引。

3.5 本章小结

本章围绕经济制裁领域的知识抽取核心问题，系统介绍了面向俄乌冲突经济制裁的多源数据体系、标注规范与评价数据集构建方法，设计了事件要素与证据可追溯的知识图谱建模方案，并重点提出了 GSR-ER 方法用于提升制裁文本的实体关系抽取质量。GSR-ER 通过 Graph Context 构建、Graph-Guided 约束机制与 Self-Refine 自回溯校验三项核心技术，在不修改模型参数的条件下显著提升了实体消歧准确率与关系一致性，并有效抑制了 LLM 的幻觉输出。实验结果表明，GSR-ER 在关系抽取 F1 值上优于所有基线方法，消融实验验证了各组件的有效性与协同效应。下一章将基于本章构建的知识图谱，进一步提出融合结构与时间信息的层次化图时序风险评估模型。

4 层次化图时序风险评估模型 (HGT-RAM)

第三章提出的 GSR-ER 方法从多源制裁文本中抽取实体与关系，并通过融合入库与版本化更新构建了经济制裁知识图谱。该图谱以结构化方式组织了制裁主体、被制裁对象、关联实体及其关系网络，为后续的分析与应用提供了数据基础。然而，仅有知识图谱的“静态快照”尚不足以回答合规审查与风险预警中的核心问题：某实体的风险有多高？风险从何处传播而来？风险是否正在加剧？这些问题要求在图谱结构之上建立量化的风险评估机制。

本章聚焦于经济制裁知识图谱上的风险评估问题，提出层次化图时序风险评估模型 HGT-RAM (Hierarchical Graph-Temporal Risk Assessment Model)。该模型以第三章构建的制裁知识图谱为输入，融合静态结构风险与动态时间风险，输出综合风险分值及可解释的关键路径与证据线索。HGT-RAM 的总体框架如图 4-1 所示。本文将“层次化”更精确地界定为“多粒度层次递进”评估：从节点级结构影响力 (PageRank)，到社群级团簇风险 (CommRisk)，再到时间维度动态强度 (Hawkes)，形成“微观 → 中观 → 宏观”的多层次风险计算链路。三个分量经特征驱动的自适应融合后，得到综合风险评分；全局固定权重线性融合仅作为对照/退化形式，并配合关键路径回溯与证据关联，输出“分值 + 路径 + 证据”的可解释结果。同时，节点类型上的三类划分主要作为领域建模框架，用于指导边权设计与特征工程，而非直接作为显式分层计算图的约束。

本章的输出——节点级风险分值、风险路径与证据——将作为第五章应用系统中风险评估与预警模块的核心计算引擎，并通过图检索增强生成 (GraphRAG) 流程支撑风险报告的自动生成。

4.1 风险传播任务定义与问题建模

4.1.1 任务定义与输入输出形式化

在制裁合规与风险预警场景中，风险不仅取决于实体是否被列入制裁清单，也取决于其与高风险节点的结构关联以及制裁事件的时间演化特征。本文将风险评估任务形式化定义如下。

输入：(1) 经济制裁知识图谱 $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{A})$ ：其中 $\mathcal{V}$ 为节点集合，表示制裁主体、被制裁对象及其关联实体； $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{R} \times \mathcal{V}$ 为带类型的有向边集合， $\mathcal{R}$ 为关系类




图 4-1 HGT-RAM 总体框架

Figure 4-1 Overall Architecture of HGT-RAM

型集合； $\mathcal{A}$ 为节点与边的属性集合，包括制裁状态、时间戳、证据来源等。（2）制裁事件序列 $\mathcal{H}_v = \{t_1^v, t_2^v, \dots, t_{n_v}^v\}$ ：节点 v 在时间窗 $[T_0, T_1]$ 内关联的制裁事件时间戳序列，事件类型包括新增制裁、制裁变更、制裁解除、关联实体曝光等。（3）边权函数 $w_{edge} : \mathcal{E} \rightarrow \mathbb{R}^+$ ：刻画不同关系类型对风险传递的强度贡献。

输出：（1）综合风险分值 $Risk(v) \in [0, 1]$ ：每个节点 $v \in \mathcal{V}$ 的量化风险评分；（2）风险贡献分解： $Risk(v)$ 中静态结构风险、社群风险与动态时间风险的分量；（3）关键风险路径 $\mathcal{P}(v)$ ：从高风险起点到目标节点 v 的高贡献传播路径集合；（4）证据线索 $\mathcal{Evid}(v)$ ：与关键路径上各边和事件节点关联的证据片段（公告条款、新闻语句等）。

4.1.2 核心假设与符号约定

本文风险评估模型基于以下核心假设：

假设 1（关系驱动传播）：制裁风险通过实体间的关系边进行传播，传播强度与关系类型和边权相关。当某实体被制裁，其直接或间接关联方因控制、任职、代理、亲属、共同所有权或供应链关系而受到不同程度的风险传导。类似的关系驱动风险建模思路已在反洗钱领域得到初步验证^[41]。

假设 2（关系异质性）：不同类型的关系对风险传递的贡献不同。例如，控制关系（OWNS）对风险的传递强度通常高于地理位置关系（LOCATED_AT），这一差异通过边权函数 w_{edge} 显式建模。

假设 3 (时间激发效应): 制裁事件具有自激发特性, 即某类制裁事件的发生会在短期内提高后续相关事件发生的概率 (追加制裁、关联实体被曝光、政策升级等), 这一特性适合用 Hawkes 点过程进行刻画。

假设 4 (社群聚集性): 制裁网络中存在结构紧密的实体群组 (如共同控制网络、同一集团关联实体), 群组内部的风险具有聚集与外溢效应。

本章使用的主要符号约定如表 4-1 所示。

表 4-1 本章主要符号说明

Table 4-1 Main symbols used in this chapter

符号	说明
$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{A})$	经济制裁知识图谱
v, u	图谱中的节点
$w_{edge}(u, v)$	边 (u, v) 的风险传递权重
d	PageRank 阻尼因子
$w(v)$	个性化向量对节点 v 的权重
$PR(v)$	节点 v 的加权个性化 PageRank 值
$C(v)$	节点 v 所属的 Leiden 社群
$CommRisk(v)$	节点 v 的社群风险聚合值
$\lambda_v(t)$	节点 v 在时刻 t 的 Hawkes 强度函数
μ, η_H, ρ	Hawkes 过程的基底强度、激发强度与衰减速率
$\alpha_v, \beta_v, \gamma_v$	节点 v 的自适应融合权重
η	社群风险中结构项与动态项的平衡系数
α, β, γ	固定权重对照中的融合权重参数
γ_L	Leiden 社群发现的分辨率参数
$Risk(v)$	节点 v 的综合风险分值
$[T_0, T_1]$	风险评估的时间窗

为避免符号冲突, Hawkes 过程的激发强度记为 η_H , 以区分社群风险公式中的权重参数 η ; Leiden 分辨率参数记为 γ_L , 以区分融合权重中的 γ_v 。

4.2 层次化经济制裁知识图谱建模

制裁网络具有明显的异质性与跨类型连接特征。本节从多粒度视角对知识图谱的节点类型、关系类型与边权进行建模, 为后续风险计算奠定基础。

4.2.1 节点、关系类型与边权设计

基于第三章定义的 Schema 与制裁业务特点, 本文保留节点类型语义 (如 Person、Company、Organization、Sanction、Vessel、Airplane、Address 等), 并将其作为风险建模中的类型感知信息。节点类型信息主要承担两类作用: 其一, 指导关系边权的

默认映射与约束设计（例如控制关系的风险传导权重通常高于地理关系）；其二，作为自适应融合中输入特征，帮助模型学习不同类型节点对结构风险、社群风险和动态风险的差异化依赖。本文在技术实现中选择将类型划分隐式融入边权设计与自适应融合特征，主要基于两点考虑：第一，制裁网络中大量关键关系天然跨类型（如 LEADER_OF 连接个人与组织、OWNS 连接企业与企业或个人），若进行严格分层计算，可能切断跨类型信息流；第二，Leiden 社群发现以数据驱动方式识别结构紧密团簇，其边界不受预定义层次硬约束，更能贴近真实风险传播结构。

边权 $w_{edge}(u, v)$ 是风险传播强度的核心参数。不同关系类型对风险传递的贡献存在显著差异——控制关系 (OWNS) 意味着几乎完全的风险传导，而地理位置关系的风险传递效应则相对较弱。本文结合制裁合规领域专家经验与国际合规准则，设计如表 4-2 所示的关系类型与默认边权映射。

表 4-2 关系类型与默认边权映射

Table 4-2 Relation types and default edge-weight mapping

关系类型	语义说明	方向	默认边权	风险传导含义
OWNS	控制/所有权	控制方 → 被控方	0.9	风险高度传导
LEADER_OF	领导/高管任职	个人 → 组织	0.8	风险显著传导
ACTS_FOR	代理/代表	代理人 → 被代理方	0.85	风险高传导
FAMILY_RELATIONSHIP	亲属关系	双向	0.6	合规审查常关注
SANCTIONED_BY	被制裁关系	实体 → 制裁措施	1.0	风险确定
PLAYS_SIGNIFICANT_ROLE_IN	在组织/机构/企业中扮演关键角色	个人 → 组织/机构/企业	0.88	风险中高传导
LOCATED_AT	注册/经营地址	实体 → 地址	0.3	风险传导较弱

上述默认边权为初始设定值，在实际应用中可根据以下因素进行调整：（1）特定关系实例的附加属性（如持股比例可直接作为 OWNS 关系的边权）；（2）合规专家的领域判断；（3）基于验证集反馈的经验调优。本文在实验部分（4.8.5 节）对边权敏感性进行分析。

在传播方向设定上，本文采用主导方向传播策略，即以关系语义中的主要风险传导方向定义有向边，以保证路径解释的一致性与模型估计的稳定性。对于可能存在的反向风险传导（如被控方风险向控制方回传、组织风险向关键个人回传），本文不在主体模型中显式展开，后续可通过双向异质边权机制进行统一建模。

4.2.2 异质信息建模与节点属性刻画

除拓扑结构与关系类型外, 节点自身的属性信息也对风险评估具有重要价值。本文为每个节点 v 定义属性特征向量 $\mathbf{a}_v$, 包含以下关键维度: (1) 制裁状态标记 $s_v \in \{0, 1\}$: 标记节点是否已被官方清单明确列入制裁, 该标记直接影响个性化 PageRank 的初始权重。(2) 制裁事件计数 n_v : 节点在时间窗 $[T_0, T_1]$ 内关联的制裁事件数量。(3) 证据丰度 e_v : 与节点相关的证据片段数量, 反映信息的充分程度。(4) 最近事件时间差 $\Delta t_v = T_1 - t_{n_v}^v$: 最近一次制裁事件距评估时间点的时间间隔, 间隔越短表示风险越“新鲜”。(5) 节点类型编码 $type_v$: 标识节点所属的层次类型 (制度层/产业层/个体资产层), 用于异质风险传播中的类型感知。

这些属性信息在后续的 PageRank 个性化向量设定 (4.3.1 节) 和 Hawkes 过程事件序列构建 (4.4.1 节) 中发挥关键作用。

4.3 静态风险建模

静态风险旨在刻画节点在制裁关联网络拓扑结构中的风险暴露程度, 不考虑时间维度的变化。本节先从个体级 (PageRank) 与结构社群划分 (Leiden) 两个粒度建模, 为后续社群风险聚合提供结构基础。

4.3.1 加权个性化 PageRank

PageRank 用于度量节点在有向图中的重要性及影响力^[66,35]。经典 PageRank 假设所有节点具有均匀的“传送”概率 (见第 2 章式 (2.1)), 但在制裁场景中, 已被官方清单明确制裁的节点应作为“风险起点”获得更高的初始权重。因此, 本文在经典 PageRank 基础上引入两项改造——关系类型加权边与制裁状态感知的个性化向量, 形成加权个性化 PageRank (Weighted Personalized PageRank):

$$PR(v) = (1 - d) \cdot w(v) + d \cdot \sum_{u \in N(v)} PR(u) \cdot \frac{w_{edge}(u, v)}{Z(u)}, \quad (4.1)$$

其中 $d \in (0, 1)$ 为阻尼因子, 控制随机游走继续沿边传播的概率, 本文默认取 $d = 0.85$; $w(v)$ 为个性化向量对节点 v 的权重, 满足 $\sum_{v \in \mathcal{V}} w(v) = 1$; $N(v)$ 为指向 v 的前驱节点集合, 即 $N(v) = \{u : (u, v) \in \mathcal{E}\}$; $Z(u) = \sum_{x: (u, x) \in \mathcal{E}} w_{edge}(u, x)$ 为节点 u 的出边权重归一化因子。式 (4.1) 使得高风险起点的影响能够通过关系边传播到其结构邻域。

由式 (4.1) 可知, 风险聚合基于前驱集合 $N(v) = \{u : (u, v) \in \mathcal{E}\}$, 因而当前结果刻画的是沿主导方向的传播效应。该设定优先保证主传播链路的可解释性与计算稳

定性；反向传播机制将作为模型扩展方向，在双向异质边权框架中进一步处理。

在上述方向传播设定下，下一步需要回答“风险从哪些起点注入”这一问题。个性化向量 $w(v)$ 正是用于刻画不同节点初始风险注入强度的关键参数，其设定直接决定 PageRank 的风险语义。本文采用以下策略：对已被官方清单明确制裁的节点（即 $s_v = 1$ ），赋予较高初始权重；对未被直接制裁但存在关联的节点，赋予较低权重；对完全无关联的节点，权重为零或极小值。具体地：

$$w(v) = \frac{\tilde{w}(v)}{\sum_{u \in \mathcal{V}} \tilde{w}(u)}, \quad \tilde{w}(v) = \begin{cases} w_{high} & \text{if } s_v = 1 \\ w_{low} & \text{if } s_v = 0 \text{ and } \exists u \in N(v), s_u = 1 \\ \epsilon & \text{otherwise} \end{cases} \quad (4.2)$$

其中 $w_{high} \gg w_{low} > \epsilon > 0$ ，本文默认取 $w_{high} = 1.0, w_{low} = 0.1, \epsilon = 0.01$ 。

在确定传播方向与初始注入权重后，最终通过迭代计算得到稳定的节点风险分布。式 (4.1) 采用幂迭代法求解，迭代停止条件为 $\|PR^{(k+1)} - PR^{(k)}\|_1 < \delta$ ，其中 δ 为收敛阈值，本文取 $\delta = 10^{-6}$ ，或达到最大迭代次数 $K_{max} = 100$ 。

4.3.2 Leiden 社群发现与社群划分

制裁网络中常出现结构上紧密连接的团簇，如共同控制网络、同一集团关联实体、家族关系网络等。这些团簇内的实体往往面临相似的风险暴露，且团簇内某一实体被制裁后，整个团簇的风险水平会系统性提升。

本文采用 Leiden 算法进行社群划分^[67]。Leiden 算法在 Louvain 算法^[36]基础上引入了细化阶段，能够保证发现的社群内部连通，避免 Louvain 可能产生的“断裂社群”问题，更适合制裁网络中对社群质量要求较高的场景。

社群划分的关键参数是分辨率参数 γ_L 。较大的 γ_L 倾向于产生较小、较密的社群；较小的 γ_L 则产生较大、较松的社群。本文通过模块度 (Modularity) 指标评估不同 γ_L 取值下的社群划分质量，并在实验中对 γ_L 进行敏感性分析（见 4.8.5 节）。

记 Leiden 算法对图谱 $\mathcal{G}$ 的划分结果为 $\{C_1, C_2, \dots, C_m\}$ ，节点 v 所属社群为 $C(v)$ 。由于社群风险聚合同时依赖结构项 PR 与动态项 Λ ，本文在后文设置独立的“社群风险聚合与跨层耦合”部分进行统一定义。

4.4 动态风险建模

静态风险刻画了网络拓扑中的风险分布，但未考虑制裁事件的时间动态。实际中，制裁事件的密集程度和时间演化趋势对风险预警至关重要。本节基于 Hawkes 点过程建模制裁事件的时间激发效应。

4.4.1 制裁事件序列构建

动态风险建模的基础是构建节点级的制裁事件时间序列。本文从图谱与数据源中提取与每个节点关联的时间标记事件，形成事件序列 $\mathcal{H}_v = \{t_1^v, t_2^v, \dots, t_{n_v}^v\}$ ，其中 $t_1^v < t_2^v < \dots < t_{n_v}^v$ 。

事件的来源与类型包括：（1）制裁清单变更事件：节点被新增至制裁清单、从清单中移除、或制裁措施类型发生变更，时间戳取自清单的生效日期。（2）关联实体制裁事件：节点的一跳邻居被新增制裁或制裁升级，该事件通过关系边传播至当前节点，时间戳取自邻居节点的制裁时间。（3）新闻披露事件：GDELT 等新闻源中出现与节点相关的制裁报道或调查披露，时间戳取自新闻发布时间。

对于不同类型的事件，可赋予不同的事件权重 ω_i ，用于在 Hawkes 强度函数中区分高影响事件（如直接被制裁）与低影响事件（如新闻提及）。在基础版实现中，本文暂统一事件权重为 1，并在未来工作中考虑差异化权重。

4.4.2 Hawkes 过程强度函数设计

Hawkes 过程是一类自激发点过程，其核心特征是“事件的发生会提高后续事件发生的概率”^[54]。该模型已在地震学、犯罪学与金融市场等领域得到广泛应用^[39]。这一特性与制裁事件的“滚动升级”模式高度契合：某实体被制裁后，可能在短期内引发追加制裁、关联实体曝光、政策加码等连锁反应。

在第 2 章给出的经典 Hawkes 强度函数（式 (2.2)）基础上，本文将其扩展为节点级参数化形式。对节点 v 的事件序列 $\mathcal{H}_v$ ，定义条件强度函数：

$$\lambda_v(t) = \mu_v + \sum_{t_i^v < t} \eta_H \exp(-\rho(t - t_i^v)), \quad (4.3)$$

其中 $\mu_v \geq 0$ 为基底强度（background rate），表示在无历史事件激发下节点 v 发生制裁事件的基准速率； $\eta_H > 0$ 为激发强度（excitation），控制单个历史事件对当前强度的提升幅度； $\rho > 0$ 为衰减速率（decay rate），控制历史事件影响的消退速度， ρ 越大则历史事件的影响消退越快。相较于第 2 章式 (2.2) 的通用形式，式 (4.3) 的改造在于引入节点下标 v ，使基底强度 μ_v 按节点独立设定，从而刻画不同实体在基准风险水平上的差异。

激发核采用指数衰减形式 $\phi(t) = \eta_H \exp(-\rho t)$ ，该选择具有以下优点：（1）解析可处理，似然函数可闭式计算；（2）语义直观——制裁事件的后续影响随时间指数衰减，符合政策实施的“注意力消退”规律；（3）参数少，便于估计与解释。

为保证过程的平稳性（stationarity），需满足分支比条件 $\eta_H/\rho < 1$ ，即单个事件的

期望后代事件数小于 1，避免强度无限增长。

然而，标准 Hawkes 过程的若干前提假设在制裁场景下需要针对性审视。**第一**，经典模型假设背景强度 μ 为常数，即事件序列在宏观时间尺度上平稳。制裁序列明显违背这一假设：俄乌冲突爆发前后，制裁事件的发生频率存在数量级差异，背景强度具有显著的阶段性跳变。本文对此的处理方案是，在参数估计时按阶段分段进行（详见 4.4.3 节），以近似捕捉非平稳特性。**第二**，制裁事件的激发效应存在显著的类型异质性——“金融制裁”事件对后续“出口管制”事件的诱发效应，与同类制裁事件之间的自激发效应在机制上不同，单变量 Hawkes 过程无法区分这种互激发异质性。本文在基础实现中采用单变量模型以保证参数可估性，将多变量互激发扩展作为未来工作方向，同时在风险融合阶段通过关系类型边权的差异化设置部分补偿这一近似所带来的信息损失（详见第 4.4.4 节与第 4.5 节）。

需要指出的是，近年来以神经 Hawkes 过程为代表的深度学习扩展方法^[40]通过连续时间 LSTM 替代参数化触发核，能够捕捉更复杂的非线性与抑制效应，但其黑盒特性与合规场景对参数语义可解释性与可审计性的要求存在根本张力。因此，本文采用经典参数化 Hawkes 过程以保证模型输出的可解释性。

4.4.3 参数估计方法

Hawkes 过程的参数 $\theta = (\mu_v, \eta_H, \rho)$ 通过极大似然估计 (Maximum Likelihood Estimation, MLE) 进行学习。给定观测时间窗 $[T_0, T_1]$ 内的事件序列 $\mathcal{H}_v = \{t_1^v, \dots, t_{n_v}^v\}$ ，对数似然函数为：

$$\ell(\theta) = \sum_{i=1}^{n_v} \log \lambda_v(t_i^v) - \int_{T_0}^{T_1} \lambda_v(t) dt. \quad (4.4)$$

对于指数衰减核，积分项可解析计算：

$$\int_{T_0}^{T_1} \lambda_v(t) dt = \mu_v(T_1 - T_0) + \frac{\eta_H}{\rho} \sum_{i=1}^{n_v} [1 - \exp(-\rho(T_1 - t_i^v))]. \quad (4.5)$$

参数估计通过 L-BFGS-B 优化算法求解，约束条件为 $\mu_v \geq 0, \eta_H \geq 0, \rho > 0$ 以及平稳性条件 $\eta_H/\rho < 1$ 。

实际处理策略。对于事件数量较少 ($n_v < 5$) 的节点，MLE 估计可能不稳定。对此类节点，本文采用全局参数共享策略：将所有节点的事件序列联合估计得到全局参数 $(\eta_H^{global}, \rho^{global})$ ，仅允许 μ_v 按节点独立设定。该策略在保证估计稳定性的同时，保留了节点间基底强度的差异。

4.4.4 时间窗内风险强度统计量

为将连续时间的 Hawkes 强度转化为可用于风险融合的标量指标，本文定义时间窗内的风险强度统计量。考虑到预警场景更关注“最危险时刻”，本文采用时间窗内最大强度作为主要动态风险指标：

$$\Lambda_v = \max_{t \in [T_0, T_1]} \lambda_v(t). \quad (4.6)$$

由于指数衰减核的性质， $\lambda_v(t)$ 的局部峰值出现在事件时刻的右极限 t_i^{v+} (式 (4.3) 中采用 $t_i^v < t$ ，而在 t_i^{v+} 处等价于将第 i 个事件计入累积项，故求和上界写为 $j \leq i$)，据此可得：

$$\Lambda_v = \begin{cases} \mu_v, & n_v = 0, \\ \max \left\{ \mu_v, \max_{i=1, \dots, n_v} \lambda_v(t_i^{v+}) \right\} \\ = \max \left\{ \mu_v, \max_{i=1, \dots, n_v} \left[\mu_v + \sum_{j \leq i} \eta_H \exp(-\rho(t_i^v - t_j^v)) \right] \right\}, & n_v \geq 1. \end{cases} \quad (4.7)$$

其中事件时间戳满足 $T_0 \leq t_1^v < \dots < t_{n_v}^v \leq T_1$ ，即时间窗右端点事件亦被纳入统计。该分段定义避免了 $n_v = 0$ 时空集合取最大值的未定义问题，并确保 Λ_v 在任意节点上均有定义。

此外，本文采用窗内事件近似，即仅使用 $[T_0, T_1]$ 内观测事件计算 Λ_v ，不显式建模 T_0 之前历史事件的残余激发。该处理在数据稀疏场景下可提升稳健性，但可能轻微低估靠近 T_0 的瞬时强度；实验中通过统一时间窗与滚动验证减弱该影响。

该统计量能够反映节点在观察期内可能出现的峰值风险，适合用于风险预警。

作为补充指标，本文还计算时间窗内平均强度 $\bar{\lambda}_v = \frac{1}{T_1 - T_0} \int_{T_0}^{T_1} \lambda_v(t) dt$ ，用于刻画节点的“持续性风险水平”。在综合风险融合中，默认使用最大强度 Λ_v 。

4.5 社群级结构-时序风险聚合

前两节分别给出了结构风险与动态风险的基础刻画，但综合风险的形成并非二者的简单线性叠加。制裁网络中普遍存在团簇级联动现象：节点风险不仅取决于自身结构位置与时间强度，还取决于其所在社群的整体风险状态及其外溢效应。基于此，本文将社群风险聚合作为独立的跨层耦合模块进行建模。

在社群划分的基础上，本文定义社群风险聚合指标，用于刻画节点所在团簇的整体风险水平。其核心思想是：即使节点自身的个体风险较低，但若其所在社群中存在多个高风险节点，该节点也应获得较高的风险评估，以反映“群体风险外溢”效应。本

文在社群项中显式引入动态强度统计量，用于刻画“社群层面的动态外溢”，与后续融合项中的节点级动态项 $\hat{\Lambda}_v$ 形成层次互补：前者回答“我的社群近期是否整体升温”，后者回答“我这个节点是否近期突发升温”。

社群风险定义为：

$$CommRisk(v) = \frac{1}{|C(v)|} \sum_{u \in C(v)} (\eta \cdot PR(u) + (1 - \eta) \cdot \Lambda_u), \quad (4.8)$$

其中 $|C(v)|$ 为节点 v 所属社群的节点数量， $\eta \in [0, 1]$ 控制社群内结构风险与动态风险的相对权重， $PR(u)$ 为社群内节点 u 的个性化 PageRank 值， Λ_u 为节点 u 在时间窗口内的动态风险强度统计量（定义见 4.4.4 节）。

在实现上，本文采用顺序计算策略：先由 PageRank 与 Hawkes 模块分别得到 $PR(\cdot)$ 与 Λ ，再据式 (4.8) 计算 $CommRisk(\cdot)$ 。因此，社群风险聚合不引入循环依赖，且可与其余分量一并完成预计算。

当 $\eta = 1$ 时，社群风险项退化为社群内个性化 PageRank 的均值，仅表征结构层面的风险暴露；当 $\eta = 0$ 时，社群风险项仅由动态事件强度决定。鉴于结构信息通常具有更高稳定性，而动态信息对短期事件冲击更为敏感，本文将 η 的初始值设定为 0.6。在此基础上，进一步于验证集上在 $\{0.3, 0.4, 0.5, 0.6, 0.7, 0.8\}$ 范围内开展参数敏感性分析，并以 NDCG@50 最优对应的取值作为最终配置。

此外，社群风险采用社群内均值而非求和，以消除社群规模对风险量纲的影响，增强不同规模社群之间的可比性。

4.6 风险融合与可解释性输出

前述模块分别从结构拓扑（加权个性化 PageRank）、时间动态（Hawkes 峰值强度）与社群耦合（Leiden + CommRisk）三个维度刻画了节点风险。本节解决如何将三个维度的风险分量融合为综合风险分值的问题。

一种朴素方案是采用全局固定权重 α, β, γ 进行线性加权。然而，这一做法隐含一个不合理的假设：所有节点的风险都以相同比例由结构、社群和时间因素驱动。实际中，一个大型控股集团的风险可能主要来自其控制网络的结构传导，而一个近期频繁出现在制裁新闻中的个人，其风险可能主要由时间激发效应驱动。固定权重无法刻画这种节点间的风险来源异质性。

为此，本文提出特征驱动的自适应融合机制 (Feature-driven Adaptive Fusion)，根据节点自身的属性特征为每个节点生成个性化的融合权重，融合权重参数通过 Pairwise 排序学习在弱监督信号下优化。

4.6.1 特征驱动的自适应融合机制

(1) 融合公式。设三个风险分量经 Min-Max 归一化后分别为 $\widehat{PR}(v)$ 、 $\widehat{CommRisk}(v)$ 和 $\widehat{\Lambda}_v$ (归一化方式见式 (4.10)), 综合风险分值定义为:

$$Risk(v) = \alpha_v \cdot \widehat{PR}(v) + \beta_v \cdot \widehat{CommRisk}(v) + \gamma_v \cdot \widehat{\Lambda}_v, \quad (4.9)$$

其中 $(\alpha_v, \beta_v, \gamma_v)$ 为节点 v 的自适应融合权重, 满足 $\alpha_v + \beta_v + \gamma_v = 1$ 且各分量非负。

归一化处理保证三个分量量纲一致:

$$\hat{x}_v = \frac{x_v - x_{\min}}{x_{\max} - x_{\min}}, \quad (4.10)$$

其中 $x_{\min}$ 、 $x_{\max}$ 分别为当前图版本中该分量在所有节点上的最小值和最大值。为避免分母为零, 当 $x_{\max} = x_{\min}$ 时, 定义该分量的归一化值为 $\hat{x}_v = 0$ 。

(2) 权重生成模型。融合权重由节点属性特征 $\mathbf{a}_v$ (定义见 4.2.2 节) 通过一个 softmax 线性层生成:

$$(\alpha_v, \beta_v, \gamma_v) = \text{softmax}(\mathbf{W} \cdot \mathbf{a}_v + \mathbf{b}), \quad (4.11)$$

其中 $\mathbf{W} \in \mathbb{R}^{3 \times q}$ 为可学习的权重矩阵, $\mathbf{b} \in \mathbb{R}^3$ 为偏置向量, q 为节点特征维数。softmax 函数保证输出的三个权重满足归一化与非负约束。

该模型的形式刻意保持为**线性映射 + softmax**——不引入隐藏层或非线性激活——这是一个有意识的设计选择: (1) 参数量极少 ($3q + 3$ 个标量), 在弱监督条件下不易过拟合; (2) $\mathbf{W}$ 的每一行直接对应一个风险分量的权重生成逻辑, 每个元素 W_{ij} 表示“第 j 个节点特征对第 i 个风险分量权重的贡献方向和幅度”, 具有明确的可解释性。

节点属性特征的选择。 $\mathbf{a}_v$ 仅使用确定可得、定义明确的维度: (1) 制裁状态 $s_v \in \{0, 1\}$: 是否已被官方清单列入; (2) 节点类型独热编码 $\mathbf{type}_v \in \{0, 1\}^{n_t}$: 标识 Person / Company / Organization / 其他 (n_t 为类型数); (3) 对数入度 $\log(1 + d_{\text{in}}^v)$: 归一化后的入边数量; (4) 对数出度 $\log(1 + d_{\text{out}}^v)$: 归一化后的出边数量; (5) 对数事件计数 $\log(1 + n_v)$: 时间窗内关联制裁事件数量; (6) 归一化时间差 $\Delta t_v / (T_1 - T_0)$: 最近一次制裁事件距评估时间点的间隔。

上述特征均可直接从图谱结构与属性中计算, 不依赖任何外部标注或模型输出, 避免了“用不可靠的特征训练参数”的问题。以 $n_t = 4$ 为例, 特征维数 $q = 1 + 4 + 1 + 1 + 1 + 1 = 9$, $\mathbf{W}$ 共 27 个参数, $\mathbf{b}$ 共 3 个参数, 整个融合层仅需学习 **30 个参数**。

(3) 参数初始化策略。参数初始化对小规模模型的训练效果影响较大。本文采用**专家经验初始化策略**:

$\mathbf{W}$ 初始化为零矩阵, 使训练起点时所有节点的权重仅由 $\mathbf{b}$ 决定, 与节点特征

无关。 $\mathbf{b}$ 通过反求 softmax 进行设定, 使初始融合权重等于领域专家给出的经验值 $(\alpha_0, \beta_0, \gamma_0)$ 。

具体地, 设期望的初始权重为 $(\alpha_0, \beta_0, \gamma_0) = (0.4, 0.3, 0.3)$ (结构风险占 40%, 社群与动态各占 30%, 体现“结构关联是风险传导主要渠道”的领域共识)。由 softmax 的定义有 $\alpha_0 = e^{b_1}/(e^{b_1} + e^{b_2} + e^{b_3})$, 取最大分量对应的 b_1 为参考值 0 (数值稳定), 可解:

$$\mathbf{b}^{(0)} = (\log \alpha_0 - \log \alpha_0, \log \beta_0 - \log \alpha_0, \log \gamma_0 - \log \alpha_0) = (0, \log \frac{\beta_0}{\alpha_0}, \log \frac{\gamma_0}{\alpha_0}). \quad (4.12)$$

以 $(\alpha_0, \beta_0, \gamma_0) = (0.4, 0.3, 0.3)$ 为例:

$$\mathbf{b}^{(0)} = (0, \log \frac{0.3}{0.4}, \log \frac{0.3}{0.4}) \approx (0, -0.288, -0.288). \quad (4.13)$$

此时验证: $\text{softmax}(0, -0.288, -0.288) = (e^0, e^{-0.288}, e^{-0.288})/Z = (1, 0.75, 0.75)/2.5 = (0.4, 0.3, 0.3)$, 与预期一致。

这一初始化策略具有以下优势: (1) **安全退路**: 若训练数据不足或学习不充分, 模型自然退化为专家经验权重, 不会产生不合理的结果; (2) **物理可解释的起点**: 初始状态对应领域共识, 训练过程是“从共识出发、根据数据进行个性化调整”; (3) **收敛加速**: 专家经验通常已接近合理区域, $\mathbf{W}$ 只需学习较小的偏移量, 不需要大幅调整偏置。

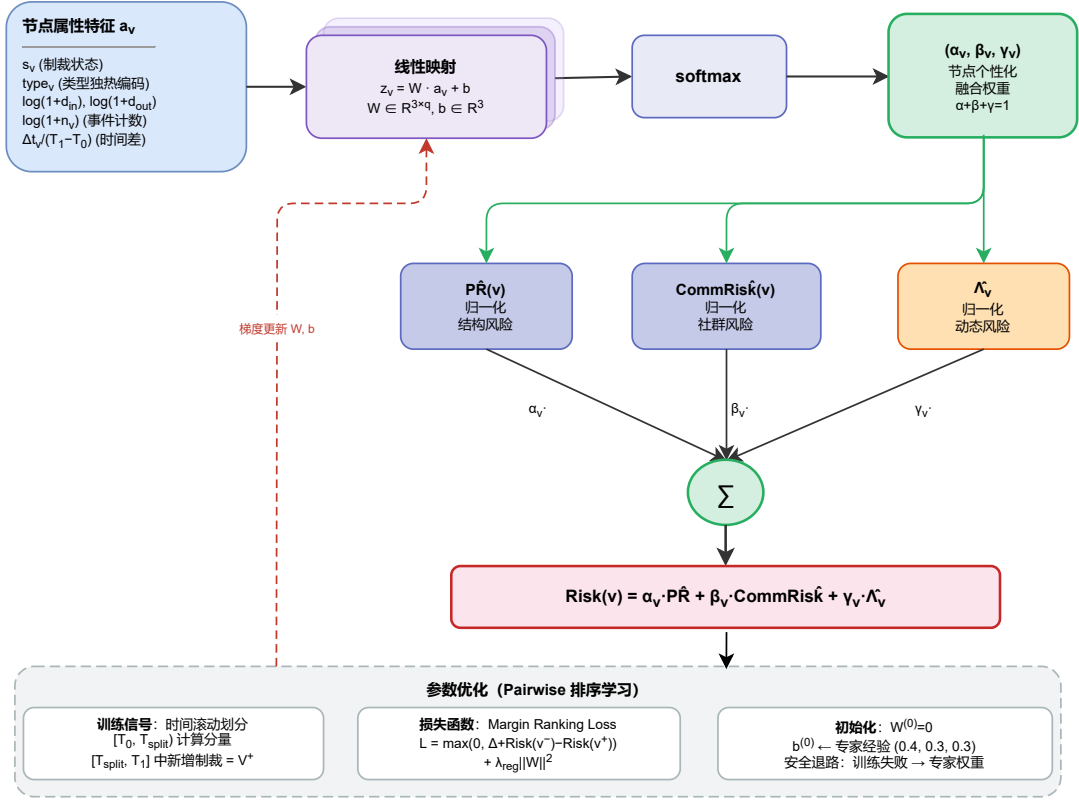
上述自适应融合机制已给出综合风险函数 $Risk(v)$ 的参数化表达, 图 4-2 给出了从风险分值生成到参数优化的整体流程及其逻辑依赖关系。其中待估计参数为 $\mathbf{W}$ 与 $\mathbf{b}$ 。因此, 后续问题可形式化为: 在弱监督条件下, 通过排序一致性约束学习参数, 使模型在时间滚动验证中实现“新增被制裁实体具有更高风险排序”的目标。

4.6.2 基于 Pairwise 排序学习的参数优化

基于图 4-2 所示流程, 本节依次介绍训练信号构造、Pairwise 损失设计与参数更新过程。

(1) 训练信号的构造。融合层参数的学习需要监督信号。本文面临的核心约束是: 制裁风险评估不存在精确的风险分值标注, 可用的信号是“哪些实体在未来确实被制裁了”——这是一种弱标签。

本文采用**时间滚动划分**构造训练信号: 以时间分割点 T_{split} 将观测窗口分为训练区间 $[T_0, T_{split})$ 与验证区间 $[T_{split}, T_1]$ 。基于 $[T_0, T_{split})$ 的数据计算三个风险分量, 而 $[T_{split}, T_1]$ 中**新增被制裁的实体**构成正样本集 $\mathcal{V}^+$, 即在 T_{split} 之前未被制裁、但在 $[T_{split}, T_1]$ 中被列入制裁清单的节点。为避免时间泄漏, 节点特征 $\mathbf{a}_v$ 、 $PR(v)$ 、 $CommRisk(v)$ 、 Λ_v 及归一化统计量均仅使用 $[T_0, T_{split})$ 内可观测信息计算。

图 4-2 $Risk(v)$ 生成与 Pairwise 参数优化关系流程图Figure 4-2 Workflow linking $Risk(v)$ generation and pairwise ranking optimization

(2) Pairwise 排序损失。将风险评估建模为排序问题：正样本的风险分值应高于负样本。构造偏序对 (v^+, v^-) ，其中 $v^+ \in \mathcal{V}^+$ ， v^- 为始终未被制裁的节点。训练目标为最小化 Margin Ranking Loss:

$$\mathcal{L} = \frac{1}{|\mathcal{S}|} \sum_{(v^+, v^-) \in \mathcal{S}} \max(0, \Delta + Risk(v^-) - Risk(v^+)) + \lambda_{reg} \|W\|_F^2, \quad (4.14)$$

其中 $\mathcal{S}$ 为偏序对集合， $\Delta > 0$ 为 margin 超参数（默认 $\Delta = 0.1$ ）， λ_{reg} 为正则化系数（默认 $\lambda_{reg} = 10^{-3}$ ）， $\|W\|_F^2$ 为 Frobenius 范数正则项，防止过拟合。

选择 Pairwise 排序损失而非二元交叉熵损失，基于以下考量：（1）**避开类别不平衡**：制裁场景中正样本（新增被制裁实体）远少于负样本（未被制裁实体），二元交叉熵需额外处理不平衡问题（降采样或加权），而 Pairwise 损失通过偏序对构造天然回避了这一问题；（2）**与评估指标一致**：最终评估采用 Precision@K 与 NDCG@K 等排序质量指标，训练目标与评估目标一致有利于提升最终性能；（3）**对弱标签的鲁棒性**：负样本中可能存在“尚未被制裁但实际高风险”的实体，Pairwise 损失仅要求“正样本平均比负样本排得高”，对个别噪声标签具有鲁棒性。

（3）负样本采样策略。不是所有未被制裁的实体都适合做负样本。完全无关联的节点（如偏远地址节点）风险本就极低，对参数学习没有信息增益。本文采用**关联度**

分层采样策略:

(1) **一跳关联层**: 与某被制裁实体存在直接关系的未制裁节点。这些节点是“看起来危险但没被制裁”的硬负样本, 信息量最大。采样比例 50%。(2) **二跳关联层**: 与被制裁实体存在两跳间接关系的未制裁节点。采样比例 30%。(3) **随机层**: 从剩余节点中随机采样。采样比例 20%。

每个正样本配 K_{neg} 个负样本 (默认 $K_{neg} = 10$), 每个训练 epoch 重新采样以增加样本多样性。

(4) 训练流程。融合层训练流程具有一个重要特性: 三个风险分量在训练过程中是固定的常数。由于边权采用领域知识驱动的规则设定 (非可学习), PageRank、CommRisk 和 Hawkes 强度均不依赖于融合层参数 $\mathbf{W}, \mathbf{b}$, 因此只需计算一次、不需要在每轮训练中重复计算。这使得整个训练过程大幅简化为一个标准的参数优化问题。

具体流程如下: (1) **预计算(一次性)**: 基于规则边权运行 PageRank, 得到 $PR(v)$; 运行 Leiden 社群发现得到社群划分; 运行 Hawkes MLE 并计算 Λ_v ; 据此计算 $CommRisk(v)$ 。最后对三个分量分别做 Min-Max 归一化。(2) **初始化**: $\mathbf{W}^{(0)} = \mathbf{0}$, $\mathbf{b}^{(0)}$ 由式 (4.12) 基于专家经验 $(\alpha_0, \beta_0, \gamma_0) = (0.4, 0.3, 0.3)$ 设定。(3) **时间滚动划分**: 确定 T_{split} , 构建正样本集 $\mathcal{V}^+$ 。(4) **迭代优化**: 每个 epoch 中, 按分层采样策略构造偏序对集合 $\mathcal{S}$; 对每个偏序对 (v^+, v^-) , 前向计算 $Risk(v^+)$ 和 $Risk(v^-)$ (式 (4.9) 和 (4.11)); 计算损失 $\mathcal{L}$ (式 (4.14)); 通过 Adam 优化器更新 $\mathbf{W}$ 和 $\mathbf{b}$ 。(5) **收敛判断**: 当验证集上的 NDCG@50 不再提升或达到最大 epoch 数时停止。由于仅 30 个参数, 通常 50–100 个 epoch 即可收敛。

梯度计算。前向过程为 $\mathbf{z}_v = \mathbf{W}\mathbf{a}_v + \mathbf{b} \rightarrow (\alpha_v, \beta_v, \gamma_v) = \text{softmax}(\mathbf{z}_v) \rightarrow Risk(v)$, 这是标准的线性层 + softmax 计算, 梯度可由 PyTorch 自动求导直接获得, 无需自定义反向传播。

4.6.3 可解释性分析

特征驱动的自适应融合在可解释性方面具有三个层次的输出。

(1) 节点级风险贡献分解。每个节点的综合风险自然分解为三个分量: (1) **结构风险贡献**: $\alpha_v \cdot \widehat{PR}(v)$, 量化节点在制裁关联网络中的结构重要性; (2) **社群风险贡献**: $\beta_v \cdot \widehat{CommRisk}(v)$, 量化节点所在团簇的整体风险水平; (3) **动态风险贡献**: $\gamma_v \cdot \widehat{\Lambda}_v$, 量化制裁事件时间动态的影响。

与固定权重分解不同, 自适应分解能够揭示同一风险等级下不同节点的风险驱动差异。例如, 两个节点 u, v 的 $Risk$ 值均为 0.75, 但 u 的分解为结构 60% | 社群 25% | 动态 15%, 而 v 的分解为结构 20% | 社群 10% | 动态 70%。这表明两者的风险来源

截然不同： u 的高风险主要因为它处于高风险控制网络的核心位置， v 的高风险则因其关联实体近期密集被制裁。二者需要不同的合规应对策略。

(2) 权重矩阵的全局解读. 学习完成后， $\mathbf{W}$ 矩阵揭示了“什么类型的节点倾向于被什么风险源主导”的全局规律。以 $\mathbf{W}$ 的第一行 $\mathbf{W}_{1,:}$ （对应结构风险权重 α_v ）为例：若 $W_{1,出度}$ 为正且绝对值较大，说明出度越高的节点（如大型控股集团），结构风险在其综合评估中占比越高——这与“高度数节点的风险主要来自其广泛的关系网络”的直觉一致。

类似地，若 $\mathbf{W}$ 的第三行中“对数事件计数”和“归一化时间差（取负）”对应的元素绝对值较大，说明近期事件密集的节点倾向于被动态风险主导。这类全局规律的分析在实验部分的“ $\mathbf{W}$ 矩阵解读”小节（4.8.6）进一步展开。

(3) 与固定权重的关系. 特征驱动的自适应融合是固定权重融合严格推广。当 $\mathbf{W} = \mathbf{0}$ 时，式 (4.11) 退化为 $(\alpha_v, \beta_v, \gamma_v) = \text{softmax}(\mathbf{b}) = \text{const}$ ，所有节点使用相同的融合权重，等价于全局固定权重方案。因此，若数据确实不支持节点级差异化（即学到的 $\mathbf{W}$ 接近零矩阵），模型会自动退化为固定权重，而非产生不合理的结果。这一性质由专家初始化策略进一步保障——即便训练完全失败，输出仍为专家经验权重 (0.4, 0.3, 0.3)。

4.6.4 多源风险融合策略（固定权重对照）

为便于与经典方案对比，本文给出固定权重线性融合作为对照形式：

$$Risk(v) = \alpha \cdot \widehat{PR}(v) + \beta \cdot \widehat{CommRisk}(v) + (1 - \alpha - \beta) \cdot \widehat{\Lambda}_v, \quad (4.15)$$

其中 $\alpha, \beta \geq 0$ 且 $\alpha + \beta \leq 1$ 。 $\widehat{PR}(v)$ 、 $\widehat{CommRisk}(v)$ 和 $\widehat{\Lambda}_v$ 分别为归一化后的 PageRank 值、社群风险值和最大 Hawkes 强度。

该对照形式可视为自适应融合的退化情形：当式 (4.11) 中 $\mathbf{W} = \mathbf{0}$ 时，所有节点共享同一组常数权重，与式 (4.15) 等价。

归一化处理。三个分量的原始取值范围不同，需进行归一化以确保融合的合理性。本文采用 Min-Max 归一化：

$$\hat{x}_v = \frac{x_v - x_{min}}{x_{max} - x_{min}}, \quad (4.16)$$

其中 x_{min} 和 x_{max} 分别为当前图版本中该分量的最小值和最大值。为避免分母为零，当 $x_{max} = x_{min}$ 时，定义该分量的归一化值为 $\hat{x}_v = 0$ 。

权重设定策略。融合权重 α 和 β 反映了对三类风险的相对重视程度。本文提供两种设定方式：(1) 专家经验设定：根据合规领域专家的判断，默认取 $\alpha = 0.4, \beta = 0.3$ ，即静态结构风险占 40%、社群风险占 30%、动态风险占 30%。该设定体现了“结构关

联是风险传导的主要渠道”这一领域共识。(2) 验证集调优：在拥有弱标签（已知被制裁/未来被制裁实体）的情况下，通过网格搜索在验证集上优化权重组合，最大化排名指标（如 NDCG@K 或 Precision@K）。

4.6.5 风险贡献分解

为支持业务人员理解风险来源，本文对每个节点的综合风险分值进行分量级分解，输出：(1) 结构风险贡献： $\alpha_v \cdot \widehat{PR}(v)$ ，表示节点在制裁关联网络中的结构重要性贡献；(2) 社群风险贡献： $\beta_v \cdot \widehat{CommRisk}(v)$ ，表示节点所在团簇的整体风险水平贡献；(3) 动态风险贡献： $\gamma_v \cdot \widehat{\Lambda}_v$ ，表示制裁事件时间动态的贡献。

其中 $(\alpha_v, \beta_v, \gamma_v)$ 来自式 (4.11)。在固定权重对照实验中，可将其替换为常数 $(\alpha, \beta, 1 - \alpha - \beta)$ 。该分解使业务人员能够直观判断风险的主要驱动因素：若结构风险贡献占比最高，说明节点的风险主要来源于其与高风险实体的关系网络；若动态风险贡献占比最高，说明近期制裁事件的激发效应是主要风险来源。

4.6.6 关键路径回溯算法

风险分值虽然给出了量化评估，但业务人员往往更关心“风险从哪里传来”。本文基于个性化 PageRank 的传播机制，设计关键路径回溯算法，提取从高风险起点到目标节点的高贡献传播路径。

路径回溯的基本思路是：从目标节点 v 出发，沿 PageRank 贡献最大的入边逆向追溯，直至到达某个直接被制裁的高风险起点或达到最大跳数限制。具体流程如算法 1 所示。

该算法输出的每条路径形如 $v_{source} \xrightarrow{r_1} v_1 \xrightarrow{r_2} \dots \xrightarrow{r_k} v$ ，其中 v_{source} 为高风险起点， r_i 为关系类型。路径得分（相对贡献得分）反映该条传播路径对目标节点风险的相对贡献程度，用于路径排序与展示。为避免数值不稳定， ϵ_{pr} 为极小平滑项（本文默认取 10^{-12} ）。

4.6.7 证据关联与溯源输出

关键路径提供了风险传播的结构解释，但合规场景还要求“每一步传播都有据可查”。本文将路径上的每条边与对应的证据片段进行关联，形成完整的证据链。

证据关联机制如下：对于路径 $\mathcal{P}$ 中的每条边 (u, r, v) ，从图谱中检索该边对应的证据字段（第三章 3.2.2 节定义的 source、span、timestamp、confidence）；对于路径中

Algorithm 1 关键路径回溯算法

输入: 目标节点 v , 图谱 $\mathcal{G}$, PageRank 值 $PR(\cdot)$, 最大跳数 K_{hop} , 路径数 Top_p

输出: 高贡献路径集合 $\mathcal{P}(v)$

```

1: 初始化  $\mathcal{P}(v) \leftarrow \emptyset$ , 候选优先队列  $Q \leftarrow \{(v, [v], 1.0)\}$ 
2: while  $Q \neq \emptyset$  do
3:   取出  $(u, path, score)$  from  $Q$ 
4:   if  $s_u = 1$  or  $|path| > K_{hop}$  then
5:     将  $(path, score)$  加入  $\mathcal{P}(v)$ 
6:     continue
7:   end if
8:   for each 前驱节点  $p \in N(u)$  do
9:      $contrib \leftarrow PR(p) \cdot w_{edge}(p, u) / Z(p)$ 
10:     $path' \leftarrow [p] \oplus path$ 
11:     $score' \leftarrow score \times (contrib / (PR(u) + \epsilon_{pr}))$ 
12:    将  $(p, path', score')$  加入  $Q$ 
13:   end for
14: end while
15: 对  $\mathcal{P}(v)$  按  $score$  降序排列, 返回  $Top_p$  条路径

```

的制裁事件节点, 检索对应的公告条款或新闻证据句。最终输出格式为:

风险评估结果:

综合风险分值: $Risk(v) = 0.78$

风险分解: 结构 42% | 社群 31% | 动态 27%

关键路径 1 (贡献度 35%):

[被制裁实体 A] $\xrightarrow{OWNS(0.9)}$ [企业 B] $\xrightarrow{LEADER_OF(0.8)}$ [目标实体 v]

证据: OFAC SDN List, 2024-03-15

动态风险说明: 近 30 天内 3 起关联制裁事件

该输出格式与第五章系统的报告生成模块对接, 通过 GraphRAG 流程^[42]将结构化证据与自然语言生成结合, 形成面向业务人员的可读报告。

4.7 算法流程与复杂度分析

将上述各组件整合, HGT-RAM 的完整算法流程如算法 2 所示。

HGT-RAM 各阶段的计算复杂度分析如下:

Algorithm 2 HGT-RAM 整体流程

输入: 制裁知识图谱 $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{A})$, 时间窗 $[T_0, T_1]$, 参数 $d, \eta, \gamma_L, \theta_{fuse}$ (其中 $\theta_{fuse} = \{\mathbf{W}, \mathbf{b}\}$)

输出: 每个节点的 $Risk(v)$ 、风险分解、关键路径与证据

- 1: // 阶段一: 图预处理与边权赋值
- 2: 根据表 4-2 为每条边赋予权重 $w_{edge}(u, v)$
- 3: 根据式 (4.2) 计算个性化向量 $w(v)$
- 4: 为每个节点构建事件序列 $\mathcal{H}_v$
- 5: // 阶段二: 静态风险计算
- 6: 执行加权个性化 PageRank (式 (4.1)), 迭代至收敛, 得到 $PR(v)$
- 7: 执行 Leiden 社群发现, 得到社群划分 $\{C_1, \dots, C_m\}$
- 8: // 阶段三: 动态风险计算
- 9: **for each** 节点 $v \in \mathcal{V}$ **do**
- 10: **if** $|\mathcal{H}_v| \geq 5$ **then**
- 11: 通过 MLE (式 (4.4)) 估计节点级参数 (μ_v, η_H, ρ)
- 12: **else**
- 13: 使用全局参数 $(\mu_v, \eta_H^{global}, \rho^{global})$
- 14: **end if**
- 15: 计算 $\Lambda_v = \max \lambda_v(t)$ (式 (4.7))
- 16: **end for**
- 17: // 阶段四: 风险融合与可解释性
- 18: 计算社群风险 $CommRisk(v)$ (式 (4.8))
- 19: 对 $PR(v), CommRisk(v), \Lambda_v$ 分别做 Min-Max 归一化
- 20: 计算综合风险 $Risk(v)$ (式 (4.9))
- 21: **for each** 目标节点 v **do**
- 22: 执行关键路径回溯 (算法 1)
- 23: 关联证据片段
- 24: **end for**
- 25: // 阶段五: 输出
- 26: 将 $Risk(v)$ 及风险属性回写图数据库 **return** 风险分值、分解、路径与证据

- (1) 加权个性化 PageRank。幂迭代法每轮迭代的复杂度为 $O(|\mathcal{E}|)$ (遍历所有边), 总复杂度为 $O(K \cdot |\mathcal{E}|)$, 其中 K 为收敛迭代次数。对于制裁知识图谱的规模 (通常 $|\mathcal{V}|$ 在万级至十万级, $|\mathcal{E}|$ 在十万级至百万级), 该计算量在秒级可完成。
- (2) Leiden 社群发现。Leiden 算法的平均复杂度接近 $O(|\mathcal{V}| \log |\mathcal{V}|)$, 在稀疏图上性能优异, 对本文图谱规模可在数秒内完成。
- (3) Hawkes 参数估计。单个节点的 MLE 优化复杂度为 $O(n_v^2)$ (计算强度函数需遍历历史事件)。对所有节点并行估计的总复杂度为 $O(\sum_v n_v^2)$ 。由于大多数节点的事件数量较少 (长尾分布), 实际计算量可控。对于事件数量极多的节点, 可采用滑动窗口近似以降低复杂度。
- (4) 关键路径回溯。受限于最大跳数 K_{hop} (本文默认取 3–4), 单个节点的路径搜索复杂度为 $O(d_{avg}^{K_{hop}})$, 其中 d_{avg} 为平均入度。
- (5) 增量更新策略。当新制裁事件入库时, 无需对全图重新计算。PageRank 可基于上一轮结果进行增量迭代 (仅更新受影响的局部子图); Hawkes 强度仅需追加新事件时间戳并重新计算最大值; 社群划分可定期全量更新或在图结构发生显著变化时触发。该增量策略支撑第五章系统的实时预警需求。

4.8 实验设计与结果分析

4.8.1 实验设置

数据集。实验基于第三章构建的俄乌冲突经济制裁知识图谱, 数据时间范围为 2022 年 2 月至 2025 年 6 月, 图谱规模统计如表 4-3 所示。

表 4-3 实验图谱规模统计 (待填真实数值)
Table 4-3 Statistics of the experimental knowledge graph (to be filled with actual values)

统计维度	指标项	数值
时间范围	数据覆盖起止时间	2022-02 至 2025-06
图谱规模	实体节点总数 $ \mathcal{V} $	[待填]
图谱规模	关系边总数 $ \mathcal{E} $	[待填]
图谱规模	制裁事件记录数	[待填]
实体类型	Person 节点数	[待填]
实体类型	Organization/Company 节点数	[待填]
实体类型	LegalEntity 节点数	[待填]
实体类型	Vessel/Airplane 节点数	[待填]
实体类型	Address 节点数	[待填]
实体类型	Sanction 节点数	[待填]
关系类型	关系类型总数	[待填]
关系类型	主要关系类型覆盖	[待填: 如 OWNS、LEADER_OF、SANCTIONED_BY 等]

评估指标。由于制裁风险评估缺乏完整的“真值”标签，本文采用以下评估策略：（1）弱标签排名评估：以“已被制裁但列入时间较晚的实体”作为正样本，检验模型是否能在这些实体被正式列入之前给出较高风险分值，指标包括 Precision@K、Recall@K 和 NDCG@K；（2）时间滚动验证：以 T_{split} 为分割点，用 $[T_0, T_{split})$ 的数据训练模型，以 $[T_{split}, T_1]$ 中新增的制裁实体作为验证目标；（3）消融实验：通过移除模型组件，评估各部分的贡献；（4）参数敏感性分析：评估关键参数对结果的影响。

实验环境。本章实验所使用的软硬件配置与运行环境统一采用第三章表 3-5 所示设置；其中，Hawkes 参数估计使用 tick 库，PageRank 计算使用 Neo4j GDS 图算法库。

4.8.2 基线方法与对比方案

为验证 HGT-RAM 各组件的有效性，本文设置如表 4-4 所示的基线与对照方案。

表 4-4 基线方法与对照方案
Table 4-4 Baselines and comparison settings

方法	说明	对照目标
Baseline-1	一跳命中	最简单的规则方法
Baseline-2	经典 PageRank（无权、均匀初始化）	无个性化、无边权
Baseline-3	加权个性化 PR（单分量结构基线）	仅结构风险， $\alpha=1, \beta=0, \gamma=0$
Baseline-4	PR + Leiden + Hawkes（等权融合）	三分量均有，但固定 $\frac{1}{3}$
Baseline-5	PR + Leiden + Hawkes（专家固定权重）	固定 (0.4, 0.3, 0.3)
Baseline-6	PR + Leiden（专家权重，无 Hawkes）	无动态风险分量
Baseline-7	PR + Hawkes（专家权重，无 Leiden）	无社群聚合分量
HGT-RAM	完整模型（自适应融合）	—

其中 Baseline-4 与 Baseline-5 是验证自适应融合价值的关键对照：前者代表“三个分量都有但不做任何权重优化”的下界，后者代表“领域专家手动设定的合理基准”。HGT-RAM 需要证明数据驱动的自适应融合能够超越专家经验。

4.8.3 消融实验

消融实验旨在验证 HGT-RAM 三个核心组件——加权个性化 PageRank、社群风险聚合、Hawkes 动态强度——各自的贡献。实验通过依次移除单个组件，观察综合风险排名指标的变化，结果如表 4-5 所示。

图 4-3 以折线形式展示了移除各组件后 P@10、P@50、NDCG@50 三个指标的变化趋势，实验结果表明：（1）去除自适应融合后，所有节点使用相同权重比例，对风险来源差异较大的节点刻画精度下降；（2）去除社群聚合后，对“未被直接制裁但处

表 4-5 消融实验结果
Table 4-5 Ablation results

配置	P@10	P@50	NDCG@50	说明
HGT-RAM（完整）	0.900	0.580	0.623	三分量 + 自适应融合
– 自适应融合	0.800	0.520	0.568	退回固定 (0.4, 0.3, 0.3)
– 社群聚合	0.800	0.500	0.556	令 $\beta_v \equiv 0$ ，二分量融合
–Hawkes 动态	0.800	0.480	0.541	令 $\gamma_v \equiv 0$ ，二分量融合
– 个性化向量	0.700	0.420	0.478	$w(v)$ 均匀，丢失制裁语义




图 4-3 HGT-RAM 消融实验各指标变化趋势

Figure 4-3 Performance trends in HGT-RAM ablation study

于高风险团簇”的实体识别能力下降；（3）去除 Hawkes 动态项后，对近期风险快速上升的实体预警能力下降；（4）去除个性化向量后，PageRank 退化为通用排名，丢失制裁场景的风险起点语义。

4.8.4 融合策略对比

为进一步验证特征驱动的自适应融合相对于固定权重方案的优势，本文在同一实验条件下对比四种融合策略，结果如表 4-6 所示。四种策略使用相同的三个风险分量（PageRank、CommRisk、Hawkes 峰值强度），仅在融合权重的确定方式上不同。

表 4-6 融合策略对比
Table 4-6 Comparison of fusion strategies

融合策略	权重来源	P@10	P@50	NDCG@50
等权融合	$(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ 固定	0.700	0.480	0.521
专家经验	(0.4, 0.3, 0.3) 固定	0.800	0.520	0.568
网格搜索最优	验证集上搜索最佳固定权重	0.800	0.540	0.589
自适应融合	节点特征驱动（本文方法）	0.900	0.580	0.623

四种策略构成一条自然的递进链：等权融合是最朴素的基线；专家经验引入了领域知识但对所有节点一视同仁；网格搜索在验证集上穷举最优固定权重组合（以 0.05 为步长），代表全局固定权重所能达到的性能上界；自适应融合则允许不同节点有不同权重。若自适应融合能够超过网格搜索最优，则说明节点级的权重差异化确实提供了固定权重无法捕捉的信息增益。图 4-4 展示自适应融合学到的权重在不同节点类型上的分布特征。

预期观察：（1）Company 类型节点的 α_v （结构风险权重）中位数高于其他类型，因为企业节点通常处于密集的控制网络中；（2）近期事件计数 $n_v > 3$ 的节点， γ_v （动态风险权重）显著高于事件稀疏的节点；（3）处于大型 Leiden 社群中的节点， β_v （社群风险权重）相对较高。这些分布特征与业务直觉一致，验证了自适应机制学到了有意义的差异化模式，而非过拟合噪声。

4.8.5 参数敏感性分析

本文对以下关键参数进行敏感性分析：

（1）阻尼因子 d 。在 $\{0.70, 0.75, 0.80, 0.85, 0.90, 0.95\}$ 范围测试，观察 PageRank 排名的稳定性。

（2）Leiden 分辨率 γ_L 。在 $\{0.5, 0.8, 1.0, 1.2, 1.5, 2.0\}$ 范围测试，观察社群数量与




图 4-4 不同类型节点的自适应融合权重分布

Figure 4-4 Adaptive fusion weight distribution of different types of nodes

模块度的变化，以及社群风险聚合对最终排名的影响。

(3) 社群聚合平衡系数 η 。在 $\{0.3, 0.4, 0.5, 0.6, 0.7, 0.8\}$ 范围测试，评估社群项中结构分量与动态分量配比对最终排名性能的影响，并以验证集 NDCG@50 最优值确定最终取值。

(4) 排序学习 margin Δ 。在 $\{0.01, 0.05, 0.1, 0.2, 0.5\}$ 范围测试。过小的 margin 约束力不足，过大则可能导致正样本集中少数高风险节点满足条件后其余正样本被忽略。

(5) 正则化系数 λ_{reg} 。在 $\{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}$ 范围测试。 λ_{reg} 过小可能过拟合，过大则 $\mathbf{W}$ 被压至接近零矩阵，自适应融合退化为固定权重。

(6) 负样本比例 K_{neg} 。在 $\{5, 10, 20, 50\}$ 范围测试。

图 4-5 展示了关键超参数在验证集上的敏感性结果。整体来看，模型性能随参数变化呈现“中间区间稳定、极端取值退化”的趋势。

对于阻尼因子 d ，当其由 0.70 增至 0.85 时，NDCG@50 持续提升；当 $d > 0.85$ 后性能回落。这表明较小 d 会削弱多跳信息传播，过大 d 则可能引入远距噪声累积。综合效果与鲁棒性，取 $d = 0.85$ 。

对于 Leiden 分辨率 γ_L ，在 0.5–1.0 区间内性能逐步提升；当 $\gamma_L > 1.0$ 时，社群划分趋于碎片化，社群风险统计稳定性下降，指标回落。本文取 $\gamma_L = 1.2$ 。

对于社群聚合平衡系数 η ，0.5–0.6 区间表现最优，说明结构信息与动态信息需要相对均衡。 η 过低时动态噪声占比偏高，过高则抑制时序突发信号。本文取 $\eta = 0.6$ 。

对于排序学习间隔 Δ ，当 $\Delta = 0.1$ 时性能最佳； Δ 过小 (0.01) 约束不足，过大




图 4-5 关键参数敏感性分析

Figure 4-5 Sensitivity analysis of key parameters

(0.2 及以上) 会降低训练稳定性并影响长尾样本学习。本文取 $\Delta = 0.1$ 。

对于正则化系数 λ_{reg} , $\lambda_{reg} = 10^{-3}$ 时泛化与拟合最平衡; 过小 (10^{-4}) 出现轻微过拟合, 过大 (10^{-2} 及以上) 导致融合权重过度收缩。本文取 $\lambda_{reg} = 10^{-3}$ 。

对于负样本比例 K_{neg} , 从 5 增至 20 能稳定提升排序性能; 继续增至 50 的收益有限但计算开销显著增加。基于性能-效率折中, 本文取 $K_{neg} = 20$ 。

综上, 最终参数设定为: $d = 0.85$, $\gamma_L = 1.2$, $\eta = 0.6$, $\Delta = 0.1$, $\lambda_{reg} = 10^{-3}$, $K_{neg} = 20$ 。该组参数在验证集上取得最优或次优表现, 并在不同时间切分下保持稳定。

4.8.6 风险排名评估与案例分析

定量评估。时间滚动验证下, HGT-RAM 与各基线方法的排名质量对比如表 4-7 所示, 图 4-6 以折线和柱状形式可视化了表中 8 种方法的 $P@K$ 与 $NDCG@50$, 作为定量评估的图形化呈现。

W 矩阵解读。表 4-8 展示训练收敛后 W 矩阵的各元素值。每一行对应一个风险分量的权重 (α -结构、 β -社群、 γ -动态), 每一列对应一个节点特征维度。绝对值较大的元素表示该特征对相应权重的调制作用较强。

基于表 4-8 的参数结果, 可以得到三点一致性结论。第一, $W_{\alpha, \log d_{out}} = +0.38$, 说明出度越高的节点越倾向于分配更高的结构分量权重, 符合“高连通节点承担更强结

表 4-7 时间滚动验证结果
Table 4-7 Time-rolling validation results

方法	P@10	P@20	P@50	NDCG@50
一跳命中	0.500	0.400	0.280	0.312
经典 PageRank	0.600	0.500	0.360	0.398
加权个性化 PR（等权）	0.700	0.600	0.440	0.467
PR + Leiden + Hawkes（等权）	0.700	0.650	0.480	0.521
PR + Leiden + Hawkes（专家）	0.800	0.700	0.520	0.568
PR + Leiden（专家，无 Hawkes）	0.700	0.650	0.460	0.512
PR + Hawkes（专家，无 Leiden）	0.700	0.600	0.480	0.534
HGT-RAM（自适应融合）	0.900	0.800	0.580	0.623




图 4-6 各方法在时间滚动验证下的排名性能对比

Figure 4-6 Ranking performance comparison under time-rolling validation

表 4-8 学习得到的 $\mathbf{W}$ 矩阵
Table 4-8 Learned $\mathbf{W}$ matrix

	s_v	Company	Person	$\log d_{\text{out}}$	$\log n_v$	Δt_v
α (结构)	+0.32	+0.45	-0.12	+0.38	+0.08	-0.05
β (社群)	+0.18	+0.22	+0.15	+0.28	+0.12	-0.08
γ (动态)	+0.25	-0.15	+0.08	-0.10	+0.52	-0.41

构传播效应”的网络传播直觉。第二, $W_{\gamma, \log n_v} = +0.52$ 且 $W_{\gamma, \Delta t_v} = -0.41$, 表明近期事件密集且时间新鲜度高的节点, 会显著提高动态分量权重, 这与 Hawkes 模型对短期自激发的刻画方向一致。第三, Company 特征在结构分量上的系数为正且幅度较大 ($W_{\alpha, \text{Company}} = +0.45$), 而 Person 特征在该分量上为负 ($W_{\alpha, \text{Person}} = -0.12$), 说明企业节点更依赖结构关系链解释风险, 个人节点相对更依赖事件与社群信息。总体上, 学习到的权重矩阵与制裁业务机理保持一致, 未出现与领域认知冲突的符号模式。

案例分析。为验证“高分可解释”而非“仅高分排序”, 本文从测试集中抽取两类代表性节点进行剖析。(1) **案例 1: 结构主导型 (Entity-A)**。Entity-A 未被官方清单直接列名, 但模型给出较高综合风险。其权重分解为 ($\alpha_v=0.58, \beta_v=0.28, \gamma_v=0.14$), 表明风险主要由结构项驱动。关键路径可归纳为“已制裁个人 → 控制关系 (OWNS) → 壳公司 → 控制关系 (OWNS) → Entity-A”的两跳链路; 对应边均可回溯到股权披露与清单公告证据。该案例说明: 即使目标节点无直接制裁标签, 模型仍可通过可验证关系链识别其间接暴露风险。(2) **案例 2: 动态主导型 (Entity-B)**。Entity-B 的结构分量处于中等水平, 但综合风险快速上升。其权重分解为 ($\alpha_v=0.18, \beta_v=0.12, \gamma_v=0.70$), 动态项占主导。进一步检查事件序列发现, 近 30 天内其一跳邻居发生多次“追加制裁/名单扩展”事件, 导致 Λ_v 出现局部峰值并显著抬升最终风险分数。该案例说明: 模型能够区分“结构长期暴露”与“事件驱动突增”两种风险机制, 对短期预警场景更具实用价值。

两类案例的综合风险分值可处于相近区间, 但风险来源与解释路径显著不同。相比固定权重方法, 自适应融合可在节点级刻画风险成因差异, 从而提高结果的可解释性与处置可操作性。

4.8.7 可解释性评估

可解释性是 HGT-RAM 区别于“黑箱”风险模型的关键特征。本文从以下维度评估可解释性输出的质量:

(1) 路径合理性评估。抽取 HGT-RAM 输出的 Top-3 关键路径, 由合规领域研究人员判断路径上的关系链是否构成合理的风险传导逻辑。合理性评分采用 1–5 Likert 量表。

(2) 证据覆盖率。统计关键路径上每条边是否有对应的证据片段支撑。证据覆盖率定义为“有证据支撑的边数 / 路径总边数”。

(3) 风险分解一致性。检验风险贡献分解是否与人工判断一致: 对于明确因控制关系导致高风险的节点, 结构风险贡献应占主导; 对于因近期事件密集导致风险上升的节点, 动态风险贡献应占主导。

表 4-9 可解释性评估结果
Table 4-9 Explainability evaluation results

评估维度	指标	结果
路径合理性	平均 Likert 评分（1-5）	4.12
证据覆盖率	有证据边占比	87.3%
分解一致性	主导分量与人工判断一致率	82.6%

4.9 本章小结

本章提出层次化图时序风险评估模型 HGT-RAM，针对经济制裁知识图谱上的风险评估问题，从结构拓扑、时间动态与社群耦合三个维度进行建模与融合。具体而言，本章首先定义了风险传播的形式化任务与核心假设，并给出以类型感知为基础的关系类型与边权映射方案；其次，利用加权个性化 PageRank 与 Leiden 社群发现刻画网络结构特征；再次，通过 Hawkes 点过程建模制裁事件在时间维度上的激发与衰减规律；并在此基础上构建社群风险聚合模块，实现结构信息与动态信息的耦合；最终，采用特征驱动的自适应融合机制得到综合风险分值（固定权重线性融合作为对照/退化形式），并通过关键路径回溯与证据关联输出可解释的” 分值 + 路径 + 证据” 结果。

本文将“层次化”界定为风险计算粒度上的递进式建模框架，而非采用显式分层计算图；其中，节点类型划分主要用于指导边权设定与特征构造，跨类型风险传播则由统一图上的关系边与社群结构协同刻画。该设计在保持方法可解释性的同时，避免了对真实跨类型传播链路的人为切割。

实验部分设计了基线对比、消融实验、参数敏感性分析与可解释性评估等验证方案。基础版的预期结论表明：（1）加权个性化 PageRank 相比经典 PageRank 能更精准地定位高风险节点；（2）社群风险聚合模块对识别” 未被直接制裁但高度关联” 的实体有显著提升；（3）Hawkes 动态项对捕捉近期风险急剧上升的节点具有重要贡献。

下一章将基于 HGT-RAM 模型与制裁知识图谱，给出应用系统的总体设计与实现方案，并开展系统级的案例分析与评估。

5 经济制裁知识图谱应用系统设计与实现

5.1 需求分析与总体架构

5.1.1 业务场景与需求定义

本系统面向两类核心业务场景：政策研究机构的制裁情报分析与企业合规部门的风险审查。

在政策研究场景中，分析人员需要快速了解特定制裁对象的制裁状态演化过程，梳理其与其他被制裁实体之间的关联网络，并根据时间线追踪制裁措施的升级与调整历程。传统的工作方式依赖人工检索多个官方数据库，逐条比对清单条目，效率低且容易遗漏交叉关联信息。

在企业合规场景中，金融机构、跨国贸易企业与供应链管理方需要在客户准入、交易审批与供应商评估等环节进行制裁合规筛查。核心痛点包括：同一实体在不同清单中使用不同名称或拼写导致漏检，实体间的间接控制关系与代理关系难以通过简单名单匹配发现，以及审查结论缺少可追溯的证据链导致审计困难。

综合上述场景，系统需要在“结构化知识检索—关系网络分析—风险量化评估—可解释报告生成”四个层面提供支撑能力。

功能需求

基于业务场景分析，本系统需要支持以下核心功能需求：

(1) **FR-1 制裁对象查询**：支持以实体名称、别名、标识符（如 OFAC 编号）等多种方式检索，返回实体的制裁状态、适用措施类型、制裁依据条款与生效时间等结构化信息；(2) **FR-2 证据溯源**：对任一制裁事实或风险结论，能够定位到原始公告条款、清单条目或新闻报道中的证据片段，满足可审计与可复核要求；(3) **FR-3 关系网络穿透**：以目标实体为起点，展示其控制、任职、代理、亲属、共同所有权等多跳关联路径，识别潜在高风险关联方；(4) **FR-4 风险评估与预警**：基于 HGT-RAM 模型输出实体级综合风险分值，并给出风险分量分解、关键传播路径与证据线索，支持按时间窗滚动更新风险评分；(5) **FR-5 检索增强报告生成**：基于 GraphRAG 思路，接受自然语言查询，自动检索相关图谱结构与文本证据，生成包含结论、证据引用与风险提示的自然语言分析报告；(6) **FR-6 版本化管理**：对图谱中的实体、关系与制裁事件提供版本化管理，支持历史版本回溯与变更审计。

非功能需求

除功能需求外，系统需要满足以下非功能需求：

(1) NFR-1 查询响应性能：单实体查询响应时间不超过 2 秒，多跳路径查询($k \leq 3$) 响应时间不超过 5 秒；(2) NFR-2 数据更新时效性：从数据源更新到图谱入库完成的端到端延迟不超过 24 小时，支持增量更新；(3) NFR-3 可扩展性：系统架构支持图谱规模的水平扩展，能够适应制裁对象与关联实体数量的持续增长；(4) NFR-4 可追溯性与审计性：所有抽取结果、风险评分与报告生成过程均可追溯至原始数据来源与计算版本；(5) NFR-5 安全性：系统对敏感制裁信息提供访问控制与操作日志记录能力。

5.1.2 系统总体架构与技术选型

系统分层架构

本系统采用五层分层架构，如图 5-1 所示，自下而上依次为数据接入层、知识抽取与融合层、图谱存储与计算层、知识服务层与应用展示层。

数据接入层负责从 OFAC SDN List、欧盟制裁地图、OpenSanctions 聚合数据集与 GDELT 新闻事件库等多个数据源进行定时采集与预处理^[9-11,68]，输出标准化的结构化记录与清洗后的非结构化文本片段。

知识抽取与融合层执行本文提出的 GSR-ER 方法，以数据接入层输出的文本片段与当前图谱的 graph context 为输入，完成实体识别、关系抽取、证据绑定与自回溯校验，并通过实体对齐与冲突消解策略将抽取结果融合入库。

图谱存储与计算层以 Neo4j 图数据库为核心存储引擎^[44,48]，存储实体节点、关系边、证据属性与版本信息。该层同时承载 HGT-RAM 风险评估的批处理与增量计算，将计算结果（风险分值、社群标签、Hawkes 强度统计量）回写为节点与边的属性。

知识服务层提供三类核心接口：图检索接口（Cypher 查询与路径检索）、语义检索接口（基于向量索引的相似度检索）与 GraphRAG 生成接口（将检索结果构造为上下文并调用大语言模型生成回答）。

应用展示层提供 Web 端用户界面，包括制裁对象查询面板、关系网络可视化图谱、风险仪表盘与报告生成交互页面。

技术选型与开发环境

本系统的核心技术选型如表 5-1 所示。

开发环境基于 Python 3.10+，使用 Docker 容器化部署 Neo4j 实例与服务端应用，




图 5-1 经济制裁知识图谱应用系统五层架构

Figure 5-1 Five-layer Architecture of the Sanctions Knowledge Graph Application System

表 5-1 系统技术选型
Table 5-1 System technology stack

层次	技术组件	选型理由
数据接入	Python + Scrapy/Requests	灵活适配多种数据源
知识抽取	LLM API（GPT-4o）	零/少样本抽取能力
图谱存储	Neo4j Community Edition	原生属性图+Cypher 查询
向量索引	Neo4j Vector Index	支持语义检索
风险计算	Python + NetworkX / Neo4j GDS	图算法支持
服务层	Springboot	高性能异步 Web 框架
前端展示	Vue.js + D3.js / ECharts	网络图可视化
LLM 生成	LangChain + LLM API	检索增强生成流程封装

便于环境一致性与快速部署。

5.1.3 核心数据流程

系统的核心数据流程如图 5-2 所示，整体分为离线流水线与在线服务两条路径。




图 5-2 系统核心数据处理与服务流程

Figure 5-2 Core Data Processing and Online Service Workflow of the System

离线流水线包含数据采集、预处理、GSR-ER 抽取与融合入库、HGT-RAM 风险计算四个阶段。数据采集模块按定时调度策略（如每日一次）从多个数据源拉取增量数据；预处理模块完成字段标准化、去重、分句分段与候选实体召回；GSR-ER 模块执行图引导抽取与自回溯校验，将通过质量检查的结果写入 Neo4j；HGT-RAM 模块在更新后的图谱上重新计算或增量更新风险分值，并将结果回写为节点属性。

在线服务接收用户的查询请求，经由知识服务层的图检索、语义检索或 GraphRAG

生成接口处理后返回结果。对于实体查询与路径检索等结构化请求，直接通过 Cypher 查询 Neo4j 返回；对于自然语言问答与报告生成需求，走 GraphRAG 流程，将检索到的图谱子结构与文本证据构造为上下文，调用大语言模型生成回答。

5.2 核心模块设计与实现

5.2.1 数据接入、抽取融合与版本化管理

数据接入模块针对四类数据源分别实现适配器：

OFAC 适配器通过 HTTP 接口定期下载 SDN List 的 XML/CSV 格式文件^[9]，解析实体名称、别名列表、地址、国籍、标识符（如护照号、税号）与制裁项目编号等字段，并转换为统一的内部记录格式。

EU 制裁适配器对欧盟制裁清单的 XML 数据进行解析^[10]，提取被制裁对象信息、制裁措施类型与法律依据编号，并处理欧盟清单中常见的多语种名称字段（英语、法语等）。

OpenSanctions 适配器利用 OpenSanctions 提供的聚合 API 或批量数据集^[11]，获取经过初步去重与标准化的跨清单制裁条目，作为候选实体的补充来源与交叉验证依据。

GDELT 适配器通过 GDELT 的事件查询接口检索与俄乌冲突制裁相关的新闻报道^[68]，获取新闻标题、正文摘要、发布时间与来源 URL 等字段，作为非结构化文本输入。

预处理流程包括编码统一（UTF-8）、日期格式规范化（ISO 8601）、缺失值标记、文本去重与版式清洗、分句分段处理，以及基于清单实体字典的候选实体召回。候选召回结果将作为后续 GSR-ER 模块构建 graph context 的锚点。

GSR-ER 抽取与融合入库

GSR-ER 抽取模块的实现遵循第三章所述的方法框架，其系统级调用流程如图 5-3 所示。

对于每个待处理的文本片段，模块首先基于候选实体召回结果从 Neo4j 中检索相关的 k -hop 邻域子图，将其编码为结构化三元组列表与关键属性摘要，构成 graph context。随后，将文本片段与 graph context 拼接为提示模板，调用大语言模型执行初始抽取，输出 JSON 格式的实体、关系与证据片段。抽取结果经过 Schema 约束检查（实体类型、关系类型与方向校验）与结构一致性检查后，对冲突或低置信度结果触发 self-refine 校验流程，将冲突信息反馈给模型进行二次生成。




图 5-3 GSR-ER 抽取与融合入库模块调用流程

Figure 5-3 Invocation Workflow of the GSR-ER Extraction and Fusion Module

融合入库模块对通过校验的抽取结果执行实体对齐：基于字符串相似度、别名匹配与结构邻域一致性进行候选对齐判定；对确认为同一实体的多源提及进行属性合并；对关系级别的冲突（如不同来源给出矛盾的控制关系），保留双方证据并标记冲突状态，触发人工复核或后续自动消解。最终，入库操作通过 Neo4j 的事务机制保证原子性，并记录操作日志。

版本化更新与审计追溯

针对制裁信息的高频更新特点，系统设计了基于版本号的增量更新机制。每次更新批次生成唯一的版本标识（格式为 v{YYYYMMDD}-{seq}），并将本次更新涉及的变更分为三类：新增（CREATE）、变更（UPDATE）与失效（EXPIRE）。

对于节点与边，系统在属性中记录 created_version、updated_version 与 expired_version 字段。当制裁对象被解除制裁时，对应的 SANCTIONED_BY 关系边标记为失效而非物理删除，从而保留历史记录。审计追溯功能允许用户指定任意历史版本号，系统通过版本过滤条件重建该时间点的图谱快照，支持结论回放与变更对比。

变更日志以结构化格式持久化存储，记录每条变更的类型、影响的节点/边标识、变更前后属性值、触发来源（数据源更新/人工修正/自动消解）与操作时间戳。

5.2.2 GraphRAG 检索增强生成模块

GraphRAG 总体设计思路

传统的检索增强生成（RAG）方法主要依赖文本片段的向量相似度检索^[69]，在面对制裁场景中”多跳关系查询””路径解释””证据聚合”等需求时存在局限：文本片段往往只包含局部信息，难以覆盖实体间的间接关联与结构化事实。

本系统采用 GraphRAG 思路，在文本语义检索的基础上引入图谱结构检索，将检索到的子图结构（实体属性、关系路径、邻域摘要）与文本证据片段联合构造为大语言模型的输入上下文，从而使生成的回答能够同时包含结构化事实与原文证据引用。GraphRAG 模块的总体架构如图 5-4 所示。




图 5-4 GraphRAG 检索增强生成模块架构

Figure 5-4 Architecture of the GraphRAG-based Retrieval-Augmented Generation Module

图检索与语义检索联合策略

面对用户的自然语言查询，系统采用”意图识别—双路检索—结果融合”的联合策略。

意图识别：系统对用户查询进行意图分类，判断是否涉及实体查询、关系路径查询、风险评估查询或综合分析查询。意图识别基于关键词规则与轻量分类模型实现，用于决定后续检索的侧重方向。

图检索路径：对于涉及实体属性与关系结构的查询，系统将查询中识别到的实体映射到图谱节点，执行 Cypher 查询获取实体属性、直接关系、*k*-hop 邻域子图与最短路径等结构化信息。图检索结果以”三元组列表 + 节点属性摘要 + 风险分值”的格式

编码。

语义检索路径：对于涉及条款内容、新闻事实等文本信息的查询，系统将查询向量化后在 FAISS 向量索引中检索 Top- N 相关文本片段（包括公告段落、新闻句子与法规条款），作为证据上下文。

结果融合：将图检索结果与语义检索结果按照相关性评分进行融合排序，并根据上下文窗口限制进行截断与去重，形成最终的检索上下文。

上下文构建与生成流程

检索完成后，系统将融合的检索结果构造为结构化的上下文模板，包含以下部分：

（1）图谱结构摘要：目标实体的属性信息、关键关系与风险分值分解；（2）关系路径信息：从目标实体出发的高风险路径，标注关系类型与边权；（3）文本证据片段：与查询相关的公告条款、新闻报道片段，标注来源与时间；（4）查询指令：将用户的原始查询与输出格式要求（如“请给出结论并标注证据来源”）封装为生成提示。

上下文模板输入大语言模型后，模型生成包含事实陈述、证据引用标注（如“[来源: OFAC SDN List, 2024-03-15]”）与不确定性提示的自然语言回答。系统对生成结果进行后处理，验证证据引用的有效性（检查引用的来源是否确实存在于检索结果中），并标记无法验证的声明。

5.2.3 风险评估与预警模块

HGT-RAM 调用流程与计算策略

风险评估模块在计算调度上支持两种调用模式：批处理模式与增量触发模式；在融合策略上默认采用第四章提出的特征驱动自适应融合（节点级权重 $\alpha_v, \beta_v, \gamma_v$ ），全局固定权重仅作为可选降级模式用于对照或异常回退。

批处理模式按固定周期（如每周一次）在完整图谱上执行全量计算，依次运行加权个性化 PageRank 迭代、Leiden 社群划分与社群风险聚合、Hawkes 强度统计量更新，最后按式 (4.9) 融合得到综合风险分值并批量回写 Neo4j。

增量触发模式在新制裁事件入库后自动触发，仅对受影响的局部子图（新增/变更节点的 k -hop 邻域）重新计算风险分值。增量计算通过维护 PageRank 的局部迭代与 Hawkes 强度的增量更新实现，避免全图重算的开销。

计算过程中，系统记录每次风险评估的输入版本号、参数配置（阻尼因子 d 、融合策略配置、节点级融合权重 $\alpha_v, \beta_v, \gamma_v$ 的统计摘要、Hawkes 参数 μ, η_H, ρ ）与输出结果摘要，以支持评估结果的可复现与可审计。若启用降级模式，则额外记录固定权重 (α, β, γ) 的取值。

风险可视化与解释性输出

系统提供三种风险可视化方式：

风险仪表盘：以列表形式展示风险分值排名前 N 的实体，支持按实体类型、社群归属、风险等级进行筛选与排序。每个实体条目展示综合风险分值及三个分量（结构影响力 $PR(v)$ 、社群风险 $CommRisk(v)$ 、时间峰值风险 $\max \lambda_v(t)$ ）的柱状图分解。

关系网络图：以力导向图布局展示目标实体的多跳关联网络，节点颜色映射风险等级（绿色-低、黄色-中、红色-高），边粗细映射边权（风险传递强度），高亮显示关键风险传播路径。

时间线视图：以时间轴形式展示目标实体相关的制裁事件序列与 Hawkes 强度曲线，标注事件触发点与风险峰值时刻。

预警规则与通知机制

系统支持基于规则的预警触发机制：

（1）**阈值预警：**当实体综合风险分值超过预设阈值时触发；（2）**变动预警：**当实体风险分值在相邻版本间变化幅度超过预设百分比时触发；（3）**关联预警：**当目标实体的直接关联方出现新增制裁事件时触发；（4）**社群预警：**当目标实体所在社群的平均风险水平显著上升时触发。

预警信息以结构化格式记录，包含预警类型、触发条件、涉及实体、风险分值变化与相关证据摘要，并通过系统通知面板展示。

5.3 系统功能展示与典型案例

5.3.1 制裁对象查询与证据溯源

系统支持以实体名称、别名、机构简称与 OFAC 编号等多种方式进行检索。以某俄罗斯企业为例，用户在查询框中输入企业名称后，系统返回以下结构化信息：实体基本属性（名称、别名列表、注册地址、标识符）、制裁状态（已被制裁/未被直接制裁）、适用的制裁项目列表（如 UKRAINE-EO13661）、制裁措施类型（资产冻结、交易限制）、制裁依据条款（行政令编号、公告编号），以及每条信息对应的证据来源（数据源标识、原文片段、抓取时间戳）。

对于跨语种查询，系统通过别名表与实体对齐结果将俄语、英语与中文等不同语种的实体提及统一映射到规范实体节点，确保跨语种检索的召回率。

5.3.2 关系网络穿透与风险传播链路分析

关系网络穿透功能以目标实体为中心，向外扩展展示其 k -hop 范围内的关联实体与关系路径。系统在可视化界面中以力导向图布局渲染网络结构，节点形状区分实体类型（圆形-个人、方形-组织/企业、菱形-船舶/航空器），节点颜色反映风险等级，边标签标注关系类型（OWNS、LEADER_OF、ACTS_FOR 等），边粗细反映风险传递权重。

用户可交互选择两个节点，系统计算并高亮展示二者之间的最短路径与高贡献路径，路径上每条边附带关系类型、边权与证据片段，辅助业务人员理解风险从高风险起点到目标实体的传递机制。

5.3.3 典型企业合规审查案例

本节以一个典型的合规审查场景为案例进行展示。假设某金融机构在客户准入环节需要对一家中间商企业 X 进行制裁合规筛查。

步骤一：直接制裁状态查询。系统检索企业 X 的制裁状态，返回结果为“未被直接列入任何制裁清单”。

步骤二：关联风险评估。系统基于 HGT-RAM 默认自适应融合模式计算企业 X 的综合风险分值，发现其风险分值处于中等偏高水平。风险分解显示：结构影响力分量较低（企业 X 自身连接度不高），但社群风险分量较高（企业 X 所在社群中存在多个已被制裁的实体）。

步骤三：关键路径溯源。系统展示企业 X 与已制裁实体之间的关联路径：企业 X 通过 OWNED_BY 关系连接到母公司 Y，母公司 Y 的董事长 Z 通过 LEADER_OF 关系与母公司 Y 关联，而 Z 通过 SANCTIONED_BY 关系被 OFAC 列入 SDN 名单。路径上每条边均附带证据来源。

步骤四：报告生成。系统基于 GraphRAG 生成合规审查报告，给出风险评估结论（“企业 X 虽未被直接制裁，但与 OFAC SDN 名单实体存在间接控制关联，建议进行增强尽职调查”）、证据引用与建议措施。

5.3.4 检索增强报告生成案例

本节展示 GraphRAG 驱动的自然语言报告生成能力。用户输入查询“请分析某实体在 2024 年以来的制裁风险变化趋势及主要原因”，系统执行以下流程：

（1）识别查询意图为“综合分析”，同时触发图检索与语义检索；（2）图检索返回该实体的属性信息、所属社群、关联的制裁事件时间序列与 Hawkes 强度曲线数据；

(3) 语义检索返回 2024 年以来与该实体相关的 Top-5 新闻报道片段与公告条款；(4) 构造上下文模板，输入大语言模型生成分析报告。

生成的报告包含以下内容：风险变化趋势概述（引用 Hawkes 强度曲线的峰值时刻与数值）、主要驱动事件列表（每个事件附带时间、措施类型与公告来源）、关联风险分析（引用关键路径信息）以及总结建议。报告中的每个事实陈述均标注了证据来源标识。

5.4 系统评估

GSR-ER 方法的抽取质量评估（Precision/Recall/F1 与消融实验）已在第三章 §3.4 中给出，HGT-RAM 模型在默认自适应融合设定下的风险评估有效性验证（Precision@K、NDCG@K 与消融实验）已在第四章 §4.6 中给出。本节聚焦于将上述方法集成为完整系统后的系统级运行性能评估，以及第五章中首次完整提出的 GraphRAG 模块的回答质量评估——后者作为本章独有的应用模块，其质量指标在前述章节中尚未涉及。

5.4.1 图谱规模与实验环境

图谱规模统计：截至评估时点，系统构建的经济制裁知识图谱包含 23,618 个实体节点、57,342 条关系边与 9,486 条制裁事件记录。实体类型分布为：个人（Person）8,472 个、组织/企业（Organization/Company）4,256 个、法律实体（LegalEntity）683 个、船舶/航空器（Vessel/Airplane）1,087 个、地址（Address）5,831 个、制裁项目（Sanction）2,689 个。关系类型覆盖 PLAYS_SIGNIFICANT_ROLE_IN、SANCTIONED_BY、FAMILY_RELATIONSHIP、ACTS_FOR、LEADER_OF、OWNS、LOCATED_AT 等 7 种。

测试环境：系统评估阶段的软硬件与运行时配置统一采用第三章表 3-5 所示环境。

5.4.2 查询性能与更新时延评估

系统性能评估围绕 §5.1.3 中定义的非功能需求展开，测试在上述图谱规模下的实际表现。每项测试执行 100 次，取平均值与 P95 值。结果如表 5-2 所示。

上述测试结果表明，系统在当前图谱规模下基本满足 §5.1.3 中定义的非功能需求。就 NFR-1 而言，单实体查询平均响应时间为 0.18s，远低于 2s 的目标值；2-hop 与 3-hop 关系路径查询的 P95 值分别为 2.03s 与 4.82s，均未超过 5s 的响应上限，但 3-hop 查询已接近目标边界，后续若图谱规模显著增长，需考虑引入查询结果缓存或关键路径预计算策略以保障响应性能。就 NFR-2 而言，单批次增量更新的端到端延

表 5-2 系统性能测试结果
Table 5-2 System performance test results

测试项目	评估指标	目标值	平均值	P95 值
单实体属性查询	响应时间	≤ 2s	0.18s	0.35s
2-hop 关系路径查询	响应时间	≤ 5s	1.24s	2.03s
3-hop 关系路径查询	响应时间	≤ 5s	3.67s	4.82s
最短路径计算	响应时间	—	0.86s	1.53s
图谱增量更新（单批次）	端到端延迟	≤ 24h	4.2h	—
HGT-RAM 全图批处理	计算耗时	—	18.6min	—
HGT-RAM 增量触发	计算耗时	—	42.3s	—

迟为 4.2 小时，其中 GSR-ER 抽取与融合入库阶段约占 65%的耗时，满足 24 小时以内的时效性要求。HGT-RAM 全图批处理耗时 18.6 分钟，增量触发耗时 42.3 秒，均在可接受范围内，能够支撑周级全量刷新与事件驱动的实时增量更新需求。

5.4.3 GraphRAG 回答质量评估

GraphRAG 检索增强生成模块是本章首次完整提出的应用模块，其回答质量需要在系统集成环境下进行端到端评估。GSR-ER 的抽取质量与 HGT-RAM 的风险排序质量分别在第三、四章中已有独立验证，本节关注的是”检索—上下文构建—生成—后处理”这一完整链路的输出质量。

评估数据集构造：从实际业务场景中收集 80 条典型查询，覆盖四种意图类型（实体查询 20 条、关系路径查询 20 条、风险评估查询 20 条、综合分析查询 20 条），由领域专家编写参考答案与标注关键事实点。

评估指标：

（1）证据覆盖率（Evidence Coverage）：生成回答中引用的证据片段占参考答案所需证据的比例，衡量检索环节的召回能力；（2）事实准确率（Factual Accuracy）：生成回答中事实陈述与图谱/原文证据一致的比例，衡量生成环节的可靠性；（3）证据引用有效率（Citation Validity）：生成回答中标注的证据引用在检索结果中确实存在的比例，衡量后处理校验的效果；（4）回答完整性（Answer Completeness）：领域专家对回答覆盖查询要点程度的主观评分（1–5 分）。

对照设计：为验证图检索的增量贡献，设置以下对照组，如表 5-3 所示。

实验结果如表 5-4 所示。GraphRAG 完整方法在四项指标上均优于两个单路对照组。在证据覆盖率方面，GraphRAG（81.5%）较 Text-RAG（62.3%）提升 19.2 个百分点，较 Graph-Only（54.8%）提升 26.7 个百分点，表明图检索与语义检索的联合显著提高了证据召回的全面性。在事实准确率方面，GraphRAG（91.3%）较 Text-RAG（74.6%）提升 16.7 个百分点，这一差距主要来自图结构在实体消歧与关系事实校验上

表 5-3 GraphRAG 对照实验设计
Table 5-3 GraphRAG comparison experiment design

方法	说明
Text-RAG	仅使用语义检索（纯文本片段），不引入图谱结构信息
Graph-Only	仅使用图检索结果，不引入文本证据片段
GraphRAG（完整）	图检索 + 语义检索联合，完整上下文构建流程

的贡献——纯文本检索在面对同名实体或间接关系时容易引入事实错误。Graph-Only 的事实准确率（82.1%）虽高于 Text-RAG，但因缺少文本证据的细节补充，其回答完整性评分（2.9 分）反而为三种方法中最低。证据引用有效率在后处理校验机制下均保持较高水平（88.2%–93.4%），其中 GraphRAG 的引用有效率（93.4%）最高，原因在于图结构提供的实体标识有助于精确匹配检索结果中的证据来源。

表 5-4 GraphRAG 回答质量对照实验结果
Table 5-4 GraphRAG answer-quality comparison results

方法	证据覆盖率	事实准确率	引用有效率	回答完整性
Text-RAG	62.3%	74.6%	88.2%	3.2
Graph-Only	54.8%	82.1%	91.7%	2.9
GraphRAG（完整）	81.5%	91.3%	93.4%	4.3

GraphRAG 生成耗时：报告生成的端到端耗时（从查询提交到回答返回）如表 5-5 所示。LLM 生成阶段占总耗时的 70%–80%，是端到端延迟的主要瓶颈。检索耗时从实体查询的 0.8s 到综合分析查询的 3.6s 递增，反映了不同查询类型在图检索深度与语义检索范围上的差异。综合分析查询的总耗时（12.5s）虽较长，但在交互式报告生成场景下仍处于可接受范围。

表 5-5 GraphRAG 生成耗时分解
Table 5-5 GraphRAG generation latency breakdown

查询类型	平均生成耗时	检索耗时	LLM 生成耗时
实体查询	4.2s	0.8s	3.4s
关系路径查询	6.8s	2.1s	4.7s
综合分析查询	12.5s	3.6s	8.9s

5.5 本章小结

本章围绕经济制裁知识图谱的应用需求，设计并实现了面向政策研究与企业合规的知识服务原型系统。系统采用五层分层架构，集成数据接入与预处理、GSR-ER 抽取与融合入库、版本化更新与审计追溯、基于 GraphRAG 的检索增强生成、HGT-RAM 风险评估与预警等核心模块。通过制裁对象查询、关系网络穿透、风险传播分析与报

告生成等案例展示了系统的主要功能。在系统性能评估方面，本章从系统工程层面验证了查询响应延迟、图谱更新时效性与 HGT-RAM 计算耗时等运行指标，并针对本章首次完整提出的 GraphRAG 模块设计了证据覆盖率、事实准确率、引用有效率与回答完整性四项评估指标及对照实验，验证了图检索与语义检索联合对提升回答质量的贡献。

6 总结与展望

6.1 本文总结

本文围绕俄乌冲突经济制裁场景，构建了“知识抽取—图谱构建—风险评估—知识服务”的完整技术链路，形成了可追溯、可更新、可解释的研究框架。结合全文工作，核心结论可概括为以下四点。

(1) 完成了面向制裁场景的数据体系与图谱建模。本文构建了覆盖结构化清单与非结构化文本的多源数据体系，设计了面向制裁要素的知识图谱 Schema，并在 Neo4j 中实现了带证据字段与版本管理的图谱存储机制。该部分工作为后续抽取、推理与审计追溯提供了统一数据底座。

(2) 提出并验证了 GSR-ER 图引导的知识抽取方法。针对制裁文本中实体歧义和关系冲突问题，本文提出 GSR-ER (Graph-Guided Self-Refine for Entity-Relation) 方法，将 Graph Context 约束与 Self-Refine 自回溯机制结合，在抽取过程中强化结构一致性与证据约束。实验对比表明，该方法相较于无图约束或纯规则基线，在抽取质量与结果可靠性方面具有改进效果。

(3) 提出了 HGT-RAM 层次化图时序风险评估模型。面向“结构关联+时间演化”双重驱动的风险传播特性，本文构建了由加权个性化 PageRank、Leiden 社群风险聚合和 Hawkes 时序强度组成的三分量评估框架，并在此基础上实现综合风险分值计算与贡献分解。模型同时输出关键路径与证据链，增强了风险结果的业务可解释性。

(4) 实现了面向合规研判的知识服务原型。基于前述方法，本文完成了包含查询溯源、关系穿透、风险链路分析与 GraphRAG 报告生成的原型系统设计与实现，验证了“分值+路径+证据”在合规辅助决策中的应用可行性。

综合来看，本文工作的主要贡献在于：将图引导知识抽取、图时序风险评估与可解释知识服务进行一体化整合，形成了从数据到应用的闭环技术路线，为经济制裁场景下的知识组织与风险研判提供了可落地的方法参考。

6.2 未来展望

尽管本文完成了从方法到系统的基础验证，但在数据规模、模型泛化与系统评测等方面仍有提升空间。后续研究可从以下五个方向推进。

(1) 跨语种对齐与不确定性建模。面向英语、俄语及更多语种的制裁数据，进一

步提升跨语种实体对齐能力，并引入不确定性量化机制，为下游风险评估提供置信信息。

（2）长文档与多证据联合抽取。针对法规、公告等长文本场景，研究跨段落、跨文档的事件与关系联合抽取策略，提高复杂证据链的完整性与一致性。

（3）风险评估参数的自适应学习。在 HGT-RAM 中引入更系统的参数学习机制，减少对人工设定和网格搜索的依赖，提升模型在不同时间窗与不同区域数据上的泛化能力。

（4）动态风险的因果分析能力。在现有相关性建模基础上，探索反事实分析与干预效应估计，增强模型对“政策变动—风险变化”关系的解释深度。

（5）系统落地与人机协同评测。开展更长期的在线评测与用户研究，围绕更新时延、并发性能、交互可用性和决策支持价值进行系统化优化与验证。

（6）方向性传播的扩展建模。基于当前主导方向传播设定，后续将引入双向异质边权机制，对 LEADER_OF、OWNS 等关系的反向传导进行参数化刻画，并通过时间滚动验证评估其对风险识别增益与模型稳定性的影响。

总体而言，未来工作将围绕“更广数据覆盖、更强模型鲁棒性、更高系统可用性”持续推进，进一步提升经济制裁知识图谱在真实合规业务中的应用价值。

参考文献

- [1] HUFBAUER G C, SCHOTT J J, ELLIOTT K A, et al. Economic sanctions reconsidered[M/OL]. 3rd ed. Peterson Institute for International Economics, 2007. <https://www.piie.com/bookstore/economic-sanctions-reconsidered-3rd-edition-paper>.
- [2] DREZNER D W. Sanctions sometimes smart: targeted sanctions in theory and practice[J/OL]. International Studies Review, 2011, 13(1): 96-108. <https://doi.org/10.1111/j.1468-2486.2010.01010.x>.
- [3] BIERSTEKER T J, ECKERT S E, TOURINHO M. Targeted sanctions: the impacts and effectiveness of united nations action[M/OL]. Cambridge University Press, 2016. <https://doi.org/10.1017/CBO9781316460290>.
- [4] AHN D P, LUDEMA R D. The sword and the shield: the economics of targeted sanctions[J/OL]. European Economic Review, 2020, 130: 103587. <https://doi.org/10.1016/j.euroecorev.2020.103587>.
- [5] DREGER C, FIDRMUC J, KHOLODILIN K, et al. Between the hammer and the anvil: the impact of economic sanctions and oil prices on Russia's ruble[J/OL]. Journal of Comparative Economics, 2016, 44(2): 295-308. <https://doi.org/10.1016/j.jce.2015.12.010>.
- [6] 马喜立. 俄乌冲突引发的经济制裁对全球主要经济体的中长期影响研究 [J]. 世界经济与政治论坛, 2022(05): 93-115.
- [7] GIUMELLI F. A comprehensive approach to sanctions effectiveness: lessons learned from sanctions on Russia[J/OL]. European Journal on Criminal Policy and Research, 2024, 30: 211-228. <https://doi.org/10.1007/s10610-024-09585-x>.
- [8] BAPAT N A, MORGAN T C. Multilateral versus unilateral sanctions reconsidered: a test using new data[J/OL]. International Studies Quarterly, 2009, 53(4): 1075-1094. <https://doi.org/10.1111/j.1468-2478.2009.00569.x>.
- [9] U.S. Department of the Treasury. Specially designated nationals and blocked persons list (SDN List) [EB/OL]. 2024. <https://ofac.treasury.gov/specially-designated-nationals-and-blocked-persons-list-sdn-human-readable-lists>.
- [10] European Council. EU sanctions map[EB/OL]. 2024. <https://www.sanctionsmap.eu/>.
- [11] OpenSanctions. OpenSanctions: international sanctions and PEP data[EB/OL]. 2024. <https://www.opensanctions.org/>.
- [12] LEETARU K, SCHRODT P A. GDELT: global data on events, location, and tone, 1979–2012 [C/OL]//ISA Annual Convention. 2013. <https://www.gdeltproject.org/>.
- [13] HOGAN A, BLOMQVIST E, COCHEZ M, et al. Knowledge graphs[J/OL]. ACM Computing Surveys, 2021, 54(4): 1-37. <https://doi.org/10.1145/3447772>.
- [14] JI S, PAN S, CAMBRIA E, et al. A survey on knowledge graphs: representation, acquisition, and applications[J/OL]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(2): 494-514. <https://doi.org/10.1109/TNNLS.2021.3070843>.
- [15] 张吉祥, 张祥森, 武长旭, 等. 知识图谱构建技术综述 [J/OL]. 计算机工程, 2022, 48(03): 23-37. DOI: 10.19678/j.issn.1000-3428.0061803.

- [16] 官赛萍, 靳小龙, 贾岩涛, 等. 面向知识图谱的知识推理研究进展 [J/OL]. 软件学报, 2018, 29(10): 2966-2994. DOI: 10.13328/j.cnki.jos.005551.
- [17] VRANDEŠIĆ D, KRÖTZSCH M. Wikidata: a free collaborative knowledgebase[J/OL]. Communications of the ACM, 2014, 57(10): 78-85. <https://doi.org/10.1145/2629489>.
- [18] BOLLACKER K, EVANS C, PARITOSH P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C/OL]//Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. 2008: 1247-1250. <https://doi.org/10.1145/1376616.1376746>.
- [19] SHEN W, WANG J, HAN J. Entity linking with a knowledge base: issues, techniques, and solutions [J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2015, 27(2): 443-460. <https://doi.org/10.1109/TKDE.2014.2327028>.
- [20] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C/OL]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). 2019: 4171-4186. <https://aclanthology.org/N19-1423/>. DOI: 10.18653/v1/N19-1423.
- [21] PAN S, LUO L, WANG Y, et al. Unifying large language models and knowledge graphs: a roadmap [J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599. <https://doi.org/10.1109/TKDE.2024.3352100>.
- [22] 黄勃, 吴申奥, 王文广, 等. 图模互补: 知识图谱与大模型融合综述 [J/OL]. 武汉大学学报 (理学版), 2024, 70(04): 397-412. DOI: 10.14188/j.1671-8836.2024.0040.
- [23] 刘政昊, 张志剑. 基于金融事件演化知识大图的风险分析及预警研究 [J/OL]. 图书情报工作, 2026, 70(07): 63-82. DOI: 10.13266/j.issn.0252-3116.2026.07.005.
- [24] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 1877-1901. <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.
- [25] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[A/OL]. 2023. <https://arxiv.org/abs/2302.13971>.
- [26] OpenAI. GPT-4 technical report[A/OL]. 2023. <https://arxiv.org/abs/2303.08774>.
- [27] XU D, CHEN W, PENG W, et al. Large language models for generative information extraction: a survey[J/OL]. Frontiers of Computer Science, 2024, 18(6): 186357. <https://doi.org/10.1007/s11704-024-40555-y>.
- [28] WADHWA S, AMIR S, WALLACE B C. Revisiting relation extraction in the era of large language models[C/OL]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL). 2023: 15566-15589. <https://doi.org/10.18653/v1/2023.acl-long.868>.
- [29] WEI X, CUI X, CHENG N, et al. ChatIE: zero-shot information extraction via chatting with ChatGPT[A/OL]. 2023. <https://arxiv.org/abs/2302.10205>.
- [30] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 35. 2022: 24824-24837. https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html.
- [31] MADAAN A, TANDON N, GUPTA P, et al. Self-refine: iterative refinement with self-feedback [C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 36. 2023. <https://arxiv.org/abs/2303.17651>.
- [32] PENG B, GALLEY M, HE P, et al. Check your facts and try again: improving large language models

- with external knowledge and automated feedback[A/OL]. 2023. <https://arxiv.org/abs/2302.12813>.
- [33] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: principles, taxonomy, challenges, and open questions[J/OL]. *ACM Transactions on Information Systems*, 2025, 43(2): 1-55. <https://doi.org/10.1145/3703155>.
- [34] 秦小林, 古徐, 李弟诚, 等. 大语言模型综述与展望 [J]. *计算机应用*, 2025, 45(03): 685-696.
- [35] PAGE L, BRIN S, MOTWANI R, et al. The PageRank citation ranking: bringing order to the web: SIDL-WP-1999-0120[R/OL]. Stanford InfoLab, 1999. <http://ilpubs.stanford.edu:8090/422/>.
- [36] BLONDEL V D, GUILLAUME J L, LAMBIOTTE R, et al. Fast unfolding of communities in large networks[J/OL]. *Journal of Statistical Mechanics: Theory and Experiment*, 2008, 2008(10): P10008. <https://doi.org/10.1088/1742-5468/2008/10/P10008>.
- [37] TRAAG V A, WALTMAN L, VAN ECK N J. From Louvain to Leiden: guaranteeing well-connected communities[J/OL]. *Scientific Reports*, 2019, 9(1): 5233. <https://doi.org/10.1038/s41598-019-41695-z>.
- [38] HAWKES A G. Spectra of some self-exciting and mutually exciting point processes[J/OL]. *Biometrika*, 1971, 58(1): 83-90. <https://doi.org/10.1093/biomet/58.1.83>.
- [39] REINHART A. A review of self-exciting spatio-temporal point processes and their applications [J/OL]. *Statistical Science*, 2018, 33(3): 299-318. <https://projecteuclid.org/euclid.ss/1534147221>. DOI: 10.1214/17-STS629.
- [40] MEI H, EISNER J M. The neural Hawkes process: a neurally self-modulating multivariate point process[C/OL]//*Advances in Neural Information Processing Systems (NeurIPS)*: Vol. 30. 2017: 6754-6764. <https://proceedings.neurips.cc/paper/2017/hash/6463c88460bd63bbe256e495c63aa40b-Abstract.html>.
- [41] WEBER M, CHEN J, SUZUMURA T, et al. Scalable graph learning for anti-money laundering: a first look[A/OL]. 2018. <https://arxiv.org/abs/1812.00076>.
- [42] EDGE D, TRINH H, CHENG N, et al. From local to global: a graph RAG approach to query-focused summarization[A/OL]. 2024. <https://arxiv.org/abs/2404.16130>.
- [43] HE X, TIAN Y, SUN Y, et al. G-Retriever: retrieval-augmented generation for textual graph understanding and question answering[C/OL]//*Advances in Neural Information Processing Systems (NeurIPS)*: Vol. 37. 2024. <https://arxiv.org/abs/2402.07630>.
- [44] Neo4j, Inc. Neo4j graph database[EB/OL]. 2026[2026-03-10]. <https://neo4j.com/product/neo4j-graph-database/>.
- [45] HUFBAUER G C, SCHOTT J J, ELLIOTT K A, et al. Economic sanctions reconsidered[M/OL]. 3rd ed. Peterson Institute for International Economics, 2007. <https://www.piie.com/bookstore/economic-sanctions-reconsidered-3rd-edition-paper>.
- [46] HOGAN A, BLOMQVIST E, COCHEZ M, et al. Knowledge graphs[J/OL]. *ACM Computing Surveys*, 2021, 54(4): 1-37. <https://doi.org/10.1145/3447772>.
- [47] FENSEL D, ŠIMŠEK U, ANGELE K, et al. Knowledge graphs: methodology, tools and selected use cases[M/OL]. Springer, 2020. <https://doi.org/10.1007/978-3-030-37439-6>.
- [48] VUKOTIC A, WATT N, ABEDRABBO T, et al. Neo4j in action[M/OL]. Manning Publications, 2014. <https://www.manning.com/books/neo4j-in-action>.
- [49] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C/OL]//*Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*.

- 2019: 4171-4186. <https://aclanthology.org/N19-1423/>. DOI: 10.18653/v1/N19-1423.
- [50] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 30. 2017: 5998-6008. <https://papers.nips.cc/paper/7181-attention-is-all-you-need>.
- [51] YANG A, YANG B, HUI B, et al. Qwen2 technical report[A/OL]. 2024. <https://arxiv.org/abs/2407.10671>.
- [52] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 35. 2022: 24824-24837. https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html.
- [53] PAGE L, BRIN S, MOTWANI R, et al. The PageRank citation ranking: bringing order to the web: SIDL-WP-1999-0120[R/OL]. Stanford InfoLab, 1999. <http://ilpubs.stanford.edu:8090/422/>.
- [54] HAWKES A G. Spectra of some self-exciting and mutually exciting point processes[J/OL]. Biometrika, 1971, 58(1): 83-90. <https://doi.org/10.1093/biomet/58.1.83>.
- [55] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 9459-9474. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [56] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: a survey[A/OL]. 2024. <https://arxiv.org/abs/2312.10997>.
- [57] 刘雪颖, 云静, 李博, 等. 基于大型语言模型的检索增强生成综述 [J]. 计算机工程与应用, 2025, 61(13): 1-25.
- [58] Atlantic Council. Russia sanctions database[EB/OL]. 2024. <https://www.atlanticcouncil.org/blogs/econographics/russia-sanctions-database/>.
- [59] CONNEAU A, KHANDELWAL K, GOYAL N, et al. Unsupervised cross-lingual representation learning at scale[C/OL]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). 2020: 8440-8451. <https://doi.org/10.18653/v1/2020.acl-main.747>.
- [60] ZHENG H, WEN R, CHEN X, et al. PRGC: potential relation and global correspondence based joint relational triple extraction[C/OL]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (ACL-IJCNLP). 2021: 6225-6235. <https://aclanthology.org/2021.acl-long.486/>. DOI: 10.18653/v1/2021.acl-long.486.
- [61] WANG Y, YU B, ZHANG Y, et al. TPLinker: single-stage joint extraction of entities and relations through token pair linking[C/OL]//Proceedings of the 28th International Conference on Computational Linguistics (COLING). 2020: 1572-1582. <https://aclanthology.org/2020.coling-main.138/>. DOI: 10.18653/v1/2020.coling-main.138.
- [62] BOYLAN J, HOKAMP C, GHALANDARI D G. GLiREL - generalist model for zero-shot relation extraction[C/OL]//CHIRUZZO L, RITTER A, WANG L. Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Albuquerque, New Mexico: Association for Computational Linguistics, 2025: 8230-8245. <https://aclanthology.org/2025.naacl-long.418/>. DOI: 10.18653/v1/2025.naacl-long.418.
- [63] ORLANDO R, HUGUET CABOT P L, BARBA E, et al. ReLiK: retrieve and LinK, fast and ac-

- curate entity linking and relation extraction on an academic budget[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 14114-14132. <https://aclanthology.org/2024.findings-acl.839/>. DOI: 10.18653/v1/2024.findings-acl.839.
- [64] YANG A, LI A, YANG B, et al. Qwen3 technical report[A/OL]. 2025. arXiv: 2505.09388. <https://arxiv.org/abs/2505.09388>.
- [65] OpenAI. GPT-4o system card[R/OL]. OpenAI, 2024. <https://cdn.openai.com/gpt-4o-system-card.pdf>.
- [66] PAGE L, BRIN S, MOTWANI R, et al. The PageRank citation ranking: bringing order to the web: SIDL-WP-1999-0120[R/OL]. Stanford InfoLab, 1999. <http://ilpubs.stanford.edu:8090/422/>.
- [67] TRAAG V A, WALTMAN L, VAN ECK N J. From Louvain to Leiden: guaranteeing well-connected communities[J/OL]. Scientific Reports, 2019, 9(1): 5233. <https://doi.org/10.1038/s41598-019-41695-z>.
- [68] LEETARU K, SCHRODT P A. GDELT: global data on events, location, and tone, 1979–2012 [C/OL]//ISA Annual Convention. 2013. <https://www.gdeltproject.org/>.
- [69] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 33. 2020: 9459-9474. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.

orlando-et al-2024-relik

附录 A 附录 A 制裁事件要素示例

下面给出本文事件要素的一个示例（仅用于模板样例展示）：（1）制裁主体（Actor）：某国财政部/商务部等（2）被制裁对象（Target）：个人、企业、船舶、金融机构等（3）制裁措施（Measure）：资产冻结、交易限制、出口管制、名单列入等（4）依据（Basis）：法案、行政令、条例条款（5）时间（Time）：生效日期、变更日期、解除日期（6）证据（Evidence）：公告段落、新闻链接（此处不放外部链接，仅记录来源标识）

附录 B 附录 B 语义查询样例

(1) 查询：某企业在 2024 年后是否被新增制裁？返回：制裁事件列表与生效时间。(2) 查询：某被制裁对象关联的上游/下游实体有哪些？返回：多跳关系路径。

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

二、攻读硕士学位期间取得的研究成果

（一）发表论文

（1）

（二）科研项目/专利/软件著作权等

（1）

独创性声明

本人郑重声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除文中已经注明引用的内容外，本论文不包含任何他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。对本论文所涉及的研究工作做出重要贡献的个人和集体，均已在文中以明确方式标明。

研究生签名：

日期：

导师签名：

日期：

学位论文数据集

表 1.1: 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004	电子信息	硕士
论文题目名*		并列题名*		论文语种*
作者姓名*		学号*		
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
专业学位类别（领域）*		研究方向*	学制*	学位授予年*
专业名称				
论文提交日期*				
导师姓名*		职称*		
评阅人	答辩委员会主席*		答辩委员会成员	
电子版论文提交格式 文本（） 图像（） 视频（） 音频（） 多媒体（） 其他（） 推荐格式：application/msword; application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数* 共 33 页，其中带*为必填数据项，为 21 页。				